Université Jean Monnet

Contributions aux méthodes d'estimation et à la théorie minimax

Habilitation à diriger les recherches

Soutenue publiquement le ... 2026 par

Mathieu Sart

devant le jury composé de :

Fabienne Comte	Université Paris Cité	Rapporteur
Yohann De Castro	Université de Lyon	Examinateur
Cécile Durot	Université Paris Nanterre	Examinateur
Anatoli Juditsky	Université Grenoble-Alpes	Examinateur
Matthieu Lerasle	ENSAE	Coordinateur
Oleg Lepski	Université Aix-Marseille	Rapporteur
Alexandre Tsybakov	ENSAE	Rapporteur

Remerciements

Introduction

Dans ce document, je regroupe les résultats statistiques les plus représentatifs apparaissant dans les articles dont la liste est détaillée dans la Section « Bibliographie personnelle » un peu plus bas. J'ignorerai en grande partie les trois les plus anciens qui étaient presque entièrement contenus dans ma thèse, sauf lorsqu'il s'agira de donner des éléments de bibliographie. Ce manuscrit donne ainsi une vue d'ensemble de ces travaux et les agrémente de quelques réflexions supplémentaires.

Organisation

Cette habilitation s'organise naturellement autour trois chapitres.

1. Le premier porte sur les procédures d'estimation basées sur des modèles. Il est lui même divisé en deux parties.
   — La première est relative à la ρ-estimation, un sujet sur lequel j'ai commencé à travailler à Nice avant de poursuivre en autonomie à l'ICJ.
   — La deuxième s'intéresse au problème de la construction d'une procédure polyvalente dans le modèle de déconvolution.

2. Le second chapitre tourne plutôt autour des questions de sélection d'estimateurs. On peut le subdiviser en trois parties.
   — Dans la première, je m'interroge sur ce que peuvent donner numériquement les idées de la ρ-estimation lorsque le modèle est composé de fonctions polynomiales par morceaux, où les morceaux sont libres de varier. Comme celle ci est très difficile à construire numériquement, je propose une procédure alternative, faisable numériquement, mais basée sur les mêmes principes, et avec des garanties théoriques similaires.
   — Dans la deuxième, je sélectionne un estimateur par projection afin d'étudier la problématique de l'estimation d'une densité f_0 non bornée sous la norme $\mathbb{L}^q$. L'objectif est de mieux comprendre le rôle de l'hypothèse $\|f_0\|_\infty < \infty$ dans les résultats, et de mettre en lumière de nouveaux exposants dans les vitesses minimax de convergence.
   — Dans la troisième, j'explore le problème de l'estimation non-paramétrique de la densité f_0 dans le cadre d'un problème inverse et pour la perte de Hellinger. Je montre en particulier l'importance d'une condition de minoration uniforme $\|1/f_0\|_\infty < \infty$ dans les résultats minimax.

3. Le dernier chapitre décrit mes contributions à la théorie de l'estimation optimale sur $\mathbb{R}$. Il contient deux grandes problématiques.

— La première porte sur la construction de procédures d'estimation optimales (et non presque optimales) pour estimer une densité « régulière » sur $\mathbb{R}$. Je développe ici une nouvelle façon de sélectionner les coefficients d'ondelettes pour répondre à cet enjeu lorsque la perte est $\mathbb{L}^1$. Je m'intéresse aussi au cas de la perte de Hellinger en utilisant une autre méthode d'estimation et montre la détérioration inévitable des vitesses minimax lorsque l'estimation est faite sur un domaine infini.

— La deuxième problématique part du principe que les fonctions à estimer vérifient souvent des contraintes de régularité *et* des contraintes de forme. Ce qui m'a intéressé était de découvrir les résultats théoriques associés. En particulier, si oui ou non, le mélange des deux contraintes conduit à des vitesses de convergence plus rapides que celles que l'on aurait sous ces deux mêmes contraintes, mais prises séparément.

Je donne aussi à la fin de ce chapitre quelques éléments sur l'estimation sous $\mathbb{L}^2$ et des perspectives.

Notations

Tout au long de ce manuscrit, n désigne un entier supérieur à 3. J'utilise la notation $|\cdot|$ à la fois pour représenter la valeur absolue d'un nombre et le cardinal d'un ensemble. Le symbole $+$ en indice représente la partie positive d'un nombre, $x_+ = \max\{x, 0\}$, sauf lorsqu'il s'agit du logarithme. On pose alors $\log_+(x) = \log(e + x)$. Pour toute distance d, tout élément x, et ensemble A, $d(x, A)$ représente la distance de x à A. Enfin, comme il est souvent d'usage dans la littérature, les notations $c, c', c_1, c_2, C, C' \dots$ font référence à des termes pouvant varier de ligne à ligne.

Bibliographie personnelle

Auteurs	Journal	Date	Titre
Mathieu Sart	Article soumis	2024	Adaptive and optimal estimation under shape and smoothness constraints
Mathieu Sart	Bernoulli	2025	Non-linear wavelet density estimation on the real line
Mathieu Sart	Electronic Journal of Statistics	2024	About the optimal estimation of a density with infinite support under Hellinger loss
Mathieu Sart	Bernoulli	2023	Density estimation under local differential privacy and Hellinger loss

Mathieu Sart	Electronic Journal of Statistics	2021	Minimax bounds for Besov classes in density estimation
Clément Marteau Mathieu Sart	Mathematical Statistics and Learning	2022	Deconvolution for some singular density errors via a combinatorial median of means approach
Mathieu Sart	Annales de l'Institut Henri Poincaré, Probabilités et Statistiques	2021	Estimating a density, a hazard rate, and a transition intensity via the ρ-estimation method
Mathieu Sart	ESAIM : Probability and Statistics	2017	Estimating the conditional density by histogram type estimators and model selection
Yannick Baraud Lucien Birgé Mathieu Sart	Inventiones Mathematicae	2017	A new method for estimation and model selection : ρ-estimation
Mathieu Sart	Bernoulli	2016	Robust estimation on a parametric model via testing
Mathieu Sart	Annales de l'Institut Henri Poincaré, Probabilités et Statistiques	2014	Estimation of the transition density of a Markov chain
Mathieu Sart	ESAIM : Probability and Statistics	2015	Model selection for Poisson processes with covariates

L'article suivant où je suis seul auteur est en cours de rédaction : bounds on chi-square statistics for localized bases with application to optimal estimation. Plus d'informations à son sujet dans la Section 3.7.

Table des matières

1 Méthodes basées sur des modèles **13**

1.1 Rho-estimation . . . 13

1.1.1 Un peu de bibliographie . . . 13

1.1.2 Test et heuristique. . . . 16

1.1.3 Bornes de risque. . . . 17

1.1.4 Modèle de régression. . . . 18

1.1.5 Autres cadres statistiques. . . . 20

1.1.6 Maximum de vraisemblance. . . . 23

1.2 Méthode combinatoire en déconvolution . . . 24

1.2.1 Introduction. . . . 24

1.2.2 La méthode combinatoire dans le cas direct. . . . 24

1.2.3 Hypothèses . . . 25

1.2.4 Procédure d'estimation. . . . 28

1.2.5 Résultats. . . . 30

2 Sélection d'estimateurs **33**

2.1 Programmation dynamique . . . 33

2.1.1 Collections de partitions. . . . 33

2.1.2 Algorithmie. . . . 34

2.2 Un ρ-estimateur modifié polynomial par morceaux . . . 35

2.2.1 Objectif. . . . 35

2.2.2 Simulations numériques dans la littérature. . . . 35

2.2.3 Motivations et cadre statistique. . . . 36

2.2.4 Max de vraisemblance. . . . 36

2.2.5 Collection de partitions. . . . 37

2.2.6 Heuristique. . . . 37

2.2.7 Résultats théoriques . . . 38

2.2.8 Une illustration numérique. . . . 40

2.3 Estimation d'une densité non bornée . . . 40

2.3.1 Espaces de Besov. . . . 41

2.3.2 Interprétation des paramètres. . . . 41

2.3.3 Estimation linéaire vs non linéaire. . . . 42

2.3.4 Motivations. . . . 43

2.3.5 Résultats minimax. 44
2.4 Modèle de confidentialité locale 45
2.4.1 Cadre statistique. 45
2.4.2 Motivations. 46
2.4.3 Mécanisme de confidentialité. 47
2.4.4 Histogrammes. 47
2.4.5 Heuristique. 48
2.4.6 Inégalité oracle. 49
2.4.7 Risque minimax. 50

3 Estimation optimale 53
3.1 Introduction 53
3.1.1 Estimation optimale. 53
3.1.2 Mélange de contraintes. 54
3.2 Ensembles de fonctions 55
3.2.1 Régularité mesurée via ondelettes. 55
3.2.2 Classes de Besov fortes. 56
3.2.3 Classes de Besov faibles. 56
3.2.4 Contraintes de forme. 56
3.2.5 Condition de domination. 57
3.3 Estimer avec des ondelettes 58
3.3.1 Une heuristique. 58
3.3.2 Comparaison avec la littérature. 60
3.3.3 Contrôle précis de l'erreur. 60
3.3.4 Procédure. 62
3.3.5 Résolutions initiales et finales. 62
3.4 Résultats pour la perte $\mathbb{L}^1$ 63
3.4.1 Estimation sous condition de régularité pure. 63
3.4.2 Mélange de contraintes. 66
3.5 Résultats minimax pour h^2 70
3.5.1 Régularité pure. 70
3.5.2 Unimodalité. 72
3.6 Deux arguments clefs 73
3.6.1 Avant l'inégalité oracle : le contrôle du processus empirique. 73
3.6.2 Après l'inégalité oracle : l'approximation pour les contraintes de forme. . . . 76
3.7 Les moindres carrés 77
3.8 Quelques perspectives 79

Chapitre 1

Méthodes basées sur des modèles

La Section 1.1 ci dessous présente dans les grandes lignes les articles [BBS17, Sar17, Sar21a]. La Section 1.2 porte sur [MS23]. Ces différents travaux ont toutes la même philosophie : il s'agit de construire, ou de développer, des procédures polyvalentes ou universelles d'estimation robustes et optimales (ou quasi optimales).

1.1. Rho-estimation

La ρ-estimation est un sujet dont le point de départ commence officiellement avec [BBS17] mais qui s'inscrit dans la lignée de travaux plus anciens. Il existe maintenant différents articles proches de ce sujet [BB16, Sar17, BB18, Sar21a, Che22, Lec23a, Lec23b, BC24a, Che24, Lec25, BRH25] et il dépasse le cadre de ce mémoire de tous les expliquer. Le but est plutôt d'expliquer succinctement la méthode avec les idées sous-jacentes, de faire sentir son intérêt mais aussi de décrire certaines de ses limites.

1.1.1. Un peu de bibliographie

Estimation sur un modèle. La première méthode à laquelle on pense pour résoudre un problème d'estimation statistique est probablement la méthode du maximum de vraisemblance. Cette dernière semble en effet relativement polyvalente. Elle est par ailleurs connue pour être optimale sous des hypothèses appropriées. Cependant, elle souffre d'un certain nombre de défauts : l'estimateur du maximum de vraisemblance peut ne pas exister, il peut manquer de robustesse, et il peut ne pas être optimal. Ces différents points sont connus depuis bien longtemps et je renvoie à [LC90] pour des arguments contre l'utilisation systématique et irréfléchie de cette approche. D'autres exemples sont à trouver dans la Section 2 de [Bir06], voir aussi le Théorème 3 de [BM93], ou la page 52 de [DL12].

Dans les années 1970, Lucien Le Cam puis Lucien Birgé proposèrent d'utiliser des tests robustes pour faire de l'estimation et éviter certaines des difficultés ci dessus. Deux papiers clefs sont [LeC73] et [Bir83]. Dans les années 2000, Lucien Birgé proposa une nouvelle version, plus générale, qu'il a appelé T-estimation dans [Bir06]. Le symbole T réfère à tests.

L'idée est de discrétiser un modèle $\mathcal{F}$ en un ensemble fini ou dénombrable $\mathcal{F}_{\text{dis}}$. Ensuite, on définit un test $T(f_1, f_2)$, entre deux fonctions f_1 et f_2 du modèle. Intuitivement, ce test indique lequel des deux éléments est le plus proche de la fonction à estimer. Ici, on dira que le test préfère f_2 à f_1 si $T(f_1, f_2) \geq 0$, et le contraire sinon. Il existe différents tests selon le problème considéré. Ils sont souvent basés sur une version « robustifiée » du test du rapport de vraisemblance (voir [Bir06] mais aussi [Bir13] pour des exemples). Pour estimer la fonction, Lucien Birgé proposa alors de minimiser

$$\text{crit}(f_1) = \sup_{\substack{f_2 \in \mathcal{F}_{\text{dis}} \\ T(f_1, f_2) \geq 0}} h(f_1, f_2) \tag{1.1}$$

pour $f_1 \in \mathcal{F}_{\text{dis}}$. Ce critère admet une version pénalisée pour faire de la sélection de modèle. Par souci de simplicité ici, je n'en parlerai pas. De même, pour simplifier, la fonction d'intérêt est une densité f_0 par rapport à la mesure de Lebesgue sur $\mathbb{R}^d$ et $\mathcal{F}_{\text{dis}}$ est composé de telles densités. Le symbole h ci dessus représente une distance entre f_1 et f_2, et je me restreint à l'exemple phare de la distance de Hellinger

$$h^2(f_1, f_2) = \frac{1}{2} \int \left(\sqrt{f_1(x)} - \sqrt{f_2(x)} \right)^2 \, \mathrm{d}x. \tag{1.2}$$

Il s'avère que cette approche permet de construire des estimateurs minimax, donc optimaux, même dans des cas où la méthode du maximum de vraisemblance échoue. Les estimateurs bénéficient automatiquement de propriétés de robustesse par rapport à la distance de Hellinger, ce qui n'est généralement pas vrai pour le max de vraisemblance.

Cette stratégie d'estimation souffre néanmoins de problèmes relatifs à sa complexité numérique. La minimisation du critère ci dessus revient essentiellement à calculer $h(f_1, f_2)$ et $T(f_1, f_2)$ pour toutes les fonctions f_1, f_2 du modèle discrétisé. Or, le cardinal de $\mathcal{F}_{\text{dis}}$ est excessivement grand, donnant à l'estimateur qui en résulte une saveur purement théorique (parfois cet ensemble est même abstrait). Il faut aussi pouvoir faire cette étape de discrétisation, ce qui implique une restriction sur le type de modèles que l'on peut considérer (ils doivent être au moins totalement bornés). Un point aussi un peu plus subtil est que la distance h doit être connue pour que la procédure puisse s'appliquer. Or, dans certains cas (modèle de régression à design aléatoire, densité conditionnelle), elle peut ne pas l'être. Je détaillerai cela un peu plus bas.

Sélection d'estimateurs. Une solution très simple pour pouvoir implémenter la procédure serait d'appliquer le critère précédent mais avec un ensemble $\mathcal{F}_{\text{dis}}$ remplacé par un autre, qui serait fini et pas trop grand. Pour que ce dernier soit pertinent, c'est à dire pas trop éloigné de la cible, il faudrait le choisir en fonction des données, autrement dit le remplacer par une collection d'estimateurs préliminaires. Dans l'approche de [Bir06], l'ensemble $\mathcal{F}_{\text{dis}}$ doit être déterministe. Ce n'est pas forcément toujours gênant d'un point de vue purement théorique en situation d'indépendance : on peut toujours faire du Hold-Out, c'est à dire couper l'échantillon en deux, utiliser une partie pour calculer les estimateurs et la seconde pour sélectionner parmi eux.

Il est néanmoins possible de faire de la sélection d'estimateurs sans Hold-Out, c'est à dire avec une collection $\mathcal{F}_{\text{dis}}$ composé d'estimateurs. C'est ce qu'a montré Yannick Baraud dans [Bar11] mais avec un test robuste différent de ceux de Lucien Birgé.

Quand j'ai commencé ma thèse, en 2010, une question qui m'a interpellée était de savoir la performance réelle de ces estimateurs. Il y avait certes des bornes de risque, mais elles faisaient toujours intervenir des constantes possiblement grandes. Elles n'étaient donc pas suffisantes pour juger de la qualité de ces estimateurs en pratique. Pour faire des simulations numériques, j'ai proposé à l'époque deux critères alternatifs à (1.1). Le premier est décrit dans [Sar14] et était à l'origine construit pour sélectionner une partition d'un estimateur par histogramme parmi une famille particulière mais très grande. Le second est décrit dans [Sar16] et est pour faire de l'estimation paramétrique.

Modification du critère. Pour pouvoir expliquer le cheminement qui a amené au critère de la ρ-estimation, plaçons nous dans le modèle de l'estimation de la densité conditionnelle. On a ainsi deux variables X, Y, supposées à valeurs réelles pour simplifier, et la fonction d'intérêt est la densité conditionnelle de $Y \mid X = x$ par rapport à la mesure de Lebesgue, notée $f_0(x, \cdot)$. Les données sont n copies indépendantes (X_i, Y_i) de (X, Y).

La distance de Hellinger entre deux densités conditionnelles f_1 et f_2 peut être définie de l'une des deux manières suivantes :

$$h_n^2(f_1, f_2) = \frac{1}{2n} \sum_{i=1}^{n} \int \left(\sqrt{f_2(X_i, y)} - \sqrt{f_1(X_i, y)} \right)^2 \mathrm{d}y$$
$$h_E^2(f_1, f_2) = \frac{1}{2} \int \left(\sqrt{f_2(x, y)} - \sqrt{f_1(x, y)} \right)^2 f_X(x) \, \mathrm{d}x \, \mathrm{d}y.$$

Ci dessus, f_X désigne la densité de X par rapport à Lebesgue.

Dans l'article [Sar14], j'ai proposé de revisiter le critère (1.1) pour des raisons de complexité numérique. Si on l'écrivait dans le contexte de l'estimation de la densité conditionnelle, il deviendrait

$$\mathrm{crit}'\,(f_1) = \sup_{f_2 \in \mathcal{F}} \left\{ \gamma h_n^2(f_1, f_2) + T(f_1, f_2) \right\}, \tag{1.3}$$

où $\gamma > 0$, où T est un test basé sur des idées similaires à [Bar11] (voir [Sar17] pour la formule explicite), et où $\mathcal{F}$ est un ensemble discrétisé. Le point de départ de ce critère venait du fait que l'on pouvait interpréter la procédure de Lucien Birgé comme un problème d'optimisation sous contrainte. Celui ci dessus peut donc être vu comme une version « multiplicateurs de Lagrange ».

J'ai montré dans l'article que ce critère convenait théoriquement et conduisait à des bornes de risque pour h_n^2 (pour l'estimation de la densité de transition d'une chaîne de Markov qui correspond au cas $Y_i = X_{i+1}$, et sans indépendance – cependant, on peut adapter les arguments pour qu'ils s'appliquent ici, voir [Sar17] par exemple).

Des arguments pour passer d'une perte empirique à une perte intégrée sont légion dans la littérature, notamment en régression. Je renvoie par exemple à [Bar02, CDL13]. Cependant, ils requièrent une condition de stabilité sur les modèles que l'on aimerait supprimer.

Or, on peut montrer qu'en estimation de densité conditionnelle, remplacer h_n^2 par h_E^2 dans (1.3) conduirait à une borne de risque sous h_E^2. Le problème, c'est qu'on ne peut en général le faire car h_E^2 fait intervenir la loi de X qui est souvent inconnue. Une valeur spécifique de γ avait été donnée dans l'article [Sar14], mais les calculs montraient que toutes les valeurs de γ dans un intervalle excluant 0 convenaient. Si jamais la procédure fonctionnait avec $\gamma = 0$, la distance de Helllinger h_E qui devrait

être dans (1.3) disparaitrait et on aurait un critère qui serait indépendant de f_X. On aurait alors automatiquement des bornes de risque pour la perte intégrée. Il s'avère que la procédure fonctionne bien avec $\gamma = 0$. C'est ainsi, qu'en cherchant à résoudre le problème de l'estimation de la densité conditionnelle, que le critère (1.3) s'est transformé pour devenir celui de la ρ-estimation.

1.1.2. Test et heuristique. Dans l'article originel de la ρ-estimation, [BBS17], le cadre statistique étudié est celui de l'estimation des distributions de variables aléatoires $X_1, \ldots, X_n$ indépendantes mais non forcément identiquement distribuées. Cependant, ici, pour éviter d'introduire de trop nombreuses notations, je me limite au cas où l'on observe n variables aléatoires $X_1, \ldots, X_n$ i.i.d de densité f_0 par rapport à la mesure de Lebesgue μ. Cela suffit pour introduire les concepts de base.

Il n'existe à ma connaissance pas beaucoup de formules dans la littérature pour définir un test adéquat $T(f_1, f_2)$ qui fonctionne avec un critère de la forme (1.3) et $\gamma = 0$. L'article [BBS17] a été écrit avec le test de [Bar11]. On peut trouver deux variantes dans [BB18]. Ici, je présente plutôt la formule de [Sar21a], ce qui aura l'avantage d'unifier la présentation de cette section avec celles à venir. Cette dernière peut être vue comme une extension d'une formule de [BB18] valable lorsque les fonctions f_1 et f_2 ne sont plus des densités. Relâcher cette condition peut être important dans certains cas comme je l'expliquerai dans la Section 2.2 du Chapitre 2. Dans d'autres, en revanche, le choix du test parmi ces différentes possibilités est secondaire.

L'idée de base est toujours de partir du fait que $T(f_1, f_2)$ est une sorte d'estimation de $h^2(f_0, f_1) - h^2(f_0, f_2)$. Ici, définissons tout d'abord pour toutes fonctions f_1 et f_2 positives et μ-intégrables,

$$T_E(f_1, f_2) = \int \psi\left(f_2/f_1\right) f_0 \, \mathrm{d}\mu - \frac{1}{4} \int \left(f_2 - f_1\right) \, \mathrm{d}\mu, \tag{1.4}$$

où ψ est définie pour $x \in [0, +\infty[$ par $\psi(x) = (\sqrt{x} - 1)/(\sqrt{x} + 1)$ et $\psi(+\infty) = 1$ et où les conventions $0/0 = 1$ et $x/0 = +\infty$ sont utilisées quand $x > 0$. Alors, $T_E(f_1, f_2)$ est, en un certain sens, une approximation de $h^2(f_0, f_1) - h^2(f_0, f_2)$. De manière plus précise, on a toujours,

$$\frac{1}{3} h^2(f_0, f_1) - 3h^2(f_0, f_2) \leq T_E(f_1, f_2) \leq 3h^2(f_0, f_1) - \frac{1}{3} h^2(f_0, f_2). \tag{1.5}$$

La preuve exacte de cette inégalité peut être trouvée dans [Sar21a]. L'intérêt de $T_E(f_1, f_2)$ réside dans le fait que l'on peut facilement l'estimer par sa version empirique

$$T(f_1, f_2) = \frac{1}{n} \sum_{i=1}^{n} \psi\left(f_2(X_i)/f_1(X_i)\right) - \frac{1}{4} \int \left(f_2 - f_1\right) \, \mathrm{d}\mu. \tag{1.6}$$

La valeur de cette quantité permet donc de déterminer la fonction la plus proche de la vraie densité f_0 inconnue, du moins à un facteur multiplicatif près.

Considérons maintenant une collection $\mathcal{F}$ de fonctions positives et intégrables. Le critère s'écrit

$$\mathrm{crit}(f_1) = \sup_{f_2 \in \mathcal{F}} T(f_1, f_2). \tag{1.7}$$

Si l'on fait les approximations $T(f_1, f_2) \approx T_E(f_1, f_2)$ et $T_E(f_1, f_2) \approx h^2(f_0, f_1) - h^2(f_0, f_2)$, on voit que

$$\mathrm{crit}(f_1) \approx h^2(f_0, f_1) - h^2(f_0, \mathcal{F}),$$

et cela justifie l'intérêt de minimiser ce critère.

Ainsi, le point important est d'avoir $T(f_1, f_2) \approx h^2(f_0, f_1) - h^2(f_0, f_2)$ pour obtenir des bornes de risque sous h^2. Le rôle de la distance de Hellinger h est, au fond, assez accessoire. On pourrait remplacer celle ci par n'importe quelle fonction de perte d, pourvu qu'on puisse estimer approximativement $d(f_0, f_1) - d(f_0, f_2)$. Pour plus d'informations à ce sujet en estimation de densité voir [DL12, Bar21]. De la même manière, le rôle du cadre statistique est plutôt secondaire pour la forme du critère. Cette question des cadres statistiques est discutée dans la Section 1.1.5.

1.1.3. Bornes de risque. Pour contrôler le risque de l'estimateur, il convient de contrôler, pour chaque densité f_1 possible, l'erreur

$$\mathcal{E}(f_1, f_2) = T(f_1, f_2) - T_E(f_1, f_2) \tag{1.8}$$

sur un événement de grande probabilité, et cela uniformément pour tout $f_2 \in \mathcal{F}$.

Cela peut se faire en considérant des hypothèses qui visent à contrôler la « taille » de l'ensemble $\mathcal{F}$. Les techniques probabilistes sous-jacentes proviennent de la concentration de la mesure ainsi que de la théorie des processus empiriques (inégalité de Talagrand, chaining, résultats à la Koltchinskii pour le contrôle d'espérance de supremum, dimension de Vapnik...).

Il est ainsi montré dans [BBS17] que des bornes de risque peuvent être établies si $\mathcal{F}$ est un ensemble dénombrable composé de densités vérifiant l'une des propriétés suivantes (je n'ai pas pris le même test, mais cela ne change rien aux preuves).

— Modèles totalement bornés. Dans ce cas, on contrôle l'erreur pour tout f_2 dans une version discrétisée $\mathcal{F}_{\text{dis}}$ adéquate de $\mathcal{F}$. On doit donc optimiser le critère sur $\mathcal{F}_{\text{dis}}$ à la place de $\mathcal{F}$. On retrouve alors essentiellement les mêmes résultats que [Bir06] avec sa notion de dimension métrique. Pour plus d'informations sur ce point, je renvoie à la Proposition 15 de [BBS17].

— Modèles ayant une entropie à crochets que l'on peut contrôler. Dans ce cas, une borne sur l'erreur est prouvée, uniformément pour tout $f_2 \in \mathcal{F}$ mais uniquement sous l'hypothèse que f_1 est aussi dans le modèle. Cela donne naturellement une borne de risque lorsque $f_0 \in \mathcal{F}$. On peut tout de même en déduire une lorsque $f_0 \notin \mathcal{F}$, mais uniquement en espérance et en faisant intervenir un terme de biais mesurant la distance entre f_0 et $\mathcal{F}$ à l'aide de la divergence de Kullback au lieu de la distance de Hellinger. On perd ainsi à priori en robustesse. Ce résultat est détaillé dans le Théorème 22 de [BBS17].

— Modèles dont les sous graphes forment une classe de Vapnik de dimension finie (Théorème 12 de [BBS17]). Pour plus d'informations sur cette notion de classe de Vapnik, je renvoie à [vdV13]. Elle est assez commode à utiliser, je donnerai un exemple dans la Section 1.1.4 ci dessous.

— Il est aussi possible d'utiliser la notion de « VC major class » (éventuellement weak VC major) pour contrôler le processus. Il s'agit d'un outil bien pratique pour travailler avec des contraintes de forme. Je renvoie ici au Théorème 2 de [BB16] et au Théorème 3.3 de [Sar21a]. L'avantage du dernier résultat est que le contrôle probabiliste de l'erreur est meilleur, grâce à une nouvelle inégalité maximale pour ces classes (Proposition A.2, [Sar21a]), conduisant à une amélioration de l'exposant du facteur logarithmique dans les bornes de risque (il devient 2 au lieu de 3).

Le point précédent explique donc qu'il peut avoir des facteurs logarithmiques dans les bornes de risque. Ils sont à la puissance 1 si on utilise la notion de « VC subgraph » et 2 ou 3 si on utilise

l'autre. A noter que l'on peut les utiliser pour obtenir des bornes minimax supérieures sur des classes de fonctions sur lesquelles on sait qu'il doit avoir un logarithme. L'exposant 1 est donc en un certain sens minimal. Cependant, ce logarithme peut parfois être indésirable. Or, comme ces deux notions peuvent être « faciles à vérifier » dans les exemples, on a envie de les utiliser même lorsqu'elles engendrent une perte de précision. En particulier, un certain nombre de résultats de la littérature sont sous optimaux. Il reste ainsi des questions ouvertes sur la théorie, la difficulté étant de savoir comment contrôler finement les déviations de (1.8) pour le problème ou exemple considéré.

1.1.4. Modèle de régression. Je propose d'illustrer le type de résultats que l'on peut attendre de la ρ-estimation en se plaçant dans le modèle de régression à design aléatoire. On a ainsi deux variables aléatoires X et Y et on suppose qu'il existe une fonction s_0 telle que $Y = s_0(X) + \varepsilon$. Ici, ε est une variable aléatoire de densité q_0 par rapport à Lebesgue. Par souci de simplicité, X et Y sont à valeurs réelles.

La densité de (X, Y) est $f_0(x, y) = q_0(y - s_0(x))f_X(x)$ où f_X est la densité X. On peut alors utiliser la ρ-estimation pour estimer cette densité si on a accès à un n-échantillon $(X_1, Y_1), \ldots, (X_n, Y_n)$ de (X, Y).

Considérons pour cela un sous ensemble S dénombrable dense d'un espace vectoriel de dimension d. Supposons que le statisticien modélise la loi des erreurs en supposant qu'elle soit à densité q. S'il connaissait f_X, il pourrait définir le modèle $\mathcal{F} = \{f_s,\ s \in S\}$ où

$$f_s(x, y) = q(y - s(x))f_X(x)$$

pour estimer f_0. Le critère (1.7) deviendrait

$$\mathrm{crit}(f_{s_1}) = \sup_{s_2 \in S} \frac{1}{n} \sum_{i=1}^{n} \psi\left(\frac{q(Y_i - s_2(X_i))}{q(Y_i - s_1(X_i))}\right). \tag{1.9}$$

Il faudrait ensuite minimiser $\mathrm{crit}(f_{s_1})$ pour $s_1 \in S$ (si un tel minimiseur n'existe pas, on prend un quasi minimiseur).

Un point important est que f_X n'intervient pas dans ce problème d'optimisation. Ainsi, bien que le modèle dépende de f_X, le statisticien n'en a en réalité pas besoin pour calculer l'estimateur. C'est ce qui fait aussi l'intérêt du critère de la ρ-estimation sur la procédure de T-estimation (dans laquelle la distance $h(f_{s_1}, f_{s_2})$ interviendrait. Cette dernière est inconnue si f_X n'est pas connue).

On peut alors montrer en utilisant le fait que les sous graphes du modèle ont une dimension de Vapnik finie :

Proposition 1 ([BBS17, BB18])**.** *Soit S un sous ensemble dénombrable dense d'un espace vectoriel de dimension d. Soit q_0 une densité unimodale et soit $\hat{f}_{\hat{s}}$ un estimateur obtenu en minimisant (1.9) sur S. Alors, pour tout $\xi > 0$ et probabilité $1 - e^{-\xi}$,*

$$h^2\left(f_0, f_{\hat{s}}\right) \leq C\left[\inf_{s \in S}\ h^2(f_0, f_s) + \frac{d \log_+(n/d)}{n} + \frac{\xi}{n}\right], \tag{1.10}$$

où $\log_+(x) = \log(e + x)$ et où $C > 0$ est une constante.

Quelques commentaires :

— Ce résultat annoncé dans [BBS17] était écrit sous l'hypothèse que q_0 est unimodale et symétrique. L'hypothèse q_0 symétrique était nécessaire car le test utilisé dans ce papier, qui était celui de [Bar11], contenait un terme qui dépendait de f_X. L'hypothèse de symétrie permettait simplement d'assurer que ce terme était nul et que le test ne dépende pas de f_X. Ici, le test (1.6) ne dépend pas de f_X et la preuve s'applique aussi à des modifications très mineures. Ce résultat peut aussi être trouvé dans [BB18].

— Le facteur logarithmique dans (1.10) est un peu dérangeant, il est dû à l'utilisation de la dimension de Vapnik pour les sous graphes du modèle.

— Il est possible de préciser ce résultat lorsque la modélisation de l'erreur est la bonne, i.e, $q_0 = q$. Dans ce cas,

$$h^2(f_0, f_s) = \int h^2\left(q(\cdot - s_0(x)), q(\cdot - s(x))\right) f_X(x)\,\mathrm{d}x,$$

où le h dans l'intégrale fait référence à la distance de Hellinger entre les deux densités translatées (petit abus de notation). La distance de Hellinger $h^2\left(q(\cdot - s_0(x)), q(\cdot - s(x))\right)$ dans l'intégrale se contrôle en fonction des propriétés de q. Si, par exemple, q est régulière en un certain sens (voir le Théorème 7.6 dans le Chapitre 1 de [IK81]),

$$h^2\left(q(\cdot - s_0(x)), q(\cdot - s(x))\right) \leq C' \left|s_0(x) - s(x)\right|^\beta, \tag{1.11}$$

où C' dépend de q et où $\beta = 2$. Pour des lois moins régulières, la valeur de β peut être différente (elle vaut 1 par exemple pour la loi uniforme). Si l'on met ce résultat dans (1.10), on obtient

$$h^2\left(f_0, f_{\hat{s}}\right) \leq C'' \left[\inf_{s \in S} \int \left|s_0(x) - s(x)\right|^\beta f_X(x)\,\mathrm{d}x + \frac{d \log_+(n/d)}{n} + \frac{\xi}{n}\right].$$

Il reste alors à contrôler le terme de droite de cette inégalité pour obtenir une borne sur le risque de l'estimateur.

— Il est à souligner que la fonction de perte naturelle pour la ρ-estimation est la distance de Hellinger entre les distributions sous-jacentes. Il peut malheureusement être délicat d'obtenir des bornes de risque pour une perte $\mathbb{L}^\beta$ intégrée entre $\hat{s}$ et s_0. Cela vient du fait que (1.11) a peu de chance d'être vraie dans l'autre sens en général (la distance de Hellinger entre des densités est bornée).

On peut néanmoins montrer que cela est possible dans certains cas, et que cela peut conduire in fine à des vitesses d'estimation plus rapides que les moindres carrés. A titre d'exemple, supposons la loi des erreurs uniforme sur $[-1/2, 1/2]$ et s_0 constante. Dans ce cas, en prenant un S adéquat, $|\hat{s} - s_0|$ tend vers 0 au moins à la vitesse $\log n/n$. C'est plus rapide que la vitesse $\sqrt{1/n}$ que l'on aurait via la moyenne empirique.

— Le résultat (1.10) n'est intéressant que si $q_0 \approx q$, ce qui peut sembler irréaliste. On peut aussi objecter qu'il faut que $s_0 \in S$, ou du moins que s_0 ne soit pas trop loin de cet ensemble. En fait, ces limitations sont dues au fait que je n'ai présenté les résultats que sur un seul modèle. On peut en réalité pénaliser le critère pour faire de la sélection de modèles. Tout ceci est détaillé dans l'article [BBS17].

— Les résultats associés à cette méthode diffèrent donc de celles des méthodes construites pour estimer une espérance conditionnelle (moindres carrés, méthodes basées sur les median of means...) sous des hypothèses sur les moments des erreurs. Ici, $s(x)$ n'est pas nécessairement $\mathbb{E}[Y \mid X = x]$. Même si cela était le cas, les erreurs n'admettent pas forcément de moment d'ordre deux.

1.1.5. Autres cadres statistiques. La ρ-estimation peut fonctionner dans divers cadres statistiques. Il y a deux points de vue.

Estimation indirecte. Le premier est celui décrit ci dessus pour estimer la fonction de régression. En modélisant correctement les données, la procédure produit un estimateur de la distribution sous-jacente à partir duquel on peut déduire un estimateur de la fonction d'intérêt. Ce raisonnement a été mis en place pour d'autres setups comme celui de la régression à design déterministe dans [BBS17]. Nettement plus récemment, on peut penser au problème de l'estimation de la fonction de régression dans les modèles exponentiels [BC24a, Che24], ou de mélange [Lec23b, Lec25].

L'avantage de ce type de raisonnement est que le processus empirique à contrôler est (1.8) et qu'il a déjà été étudié. L'inconvénient est que les bornes de risque s'écrivent naturellement pour l'estimateur de la distribution des données et non de l'estimateur de la fonction d'intérêt. Cela se voit dans l'inégalité (1.10) : on a une borne de risque entre f_0 et $\hat{f}_{\hat{s}}$ et il est délicat en général d'en déduire une borne de risque pour une fonction de perte plus classique (comme une norme $\mathbb{L}^\beta$) entre s_0 et $\hat{s}$.

Estimation directe. Il est aussi possible d'adapter la méthode pour estimer une « cible » f_0 qui n'est pas une densité ou une distribution, et d'évaluer le risque de l'estimateur à l'aide d'une distance de type Hellinger entre l'estimateur $\hat{f}$ et f_0. Cette distance étant une distance $\mathbb{L}^2$ entre des racines carrés, on ne pourra estimer que des fonctions positives. Néanmoins, il n'est pas nécessaire d'estimer d'abord la distribution sous-jacente des données et de faire une comparaison a posteriori de pertes pour obtenir une borne de risque entre f_0 et son estimateur. J'explique ainsi dans [Sar21a] que la procédure de la ρ-estimation peut être étendue pour estimer l'intensité f_0 d'une mesure aléatoire. Je propose d'expliquer le principe et un résultat dans le cadre de l'estimation du hazard rate en données censurées à droite.

Modèle. Soient donc $(T_1, C_1), \ldots, (T_n, C_n)$ n copies indépendantes d'un couple (T, C) de variables aléatoires à valeurs dans $[0, +\infty[\times[0, +\infty]$. Je suppose T indépendant de C. Par ailleurs, T admet une densité s_0 par rapport à la mesure de Lebesgue. L'objectif est d'estimer le hazard rate f_0 défini pour $t \geq 0$ par

$$f_0(t) = \frac{s_0(t)}{\mathbb{P}(T \geq t)}.$$

Je suppose que l'on observe une version censurée des T_i, la censure étant indiquée par C_i. Plus précisément, on observe $(X_i, D_i)_{1 \leq i \leq n}$ où $X_i = \min\{T_i, C_i\}$ et $D_i = \mathbb{1}_{T_i \leq C_i}$.

Naturellement, pour estimer f_0, on pourrait d'abord estimer la distribution de T, indiquée par s_0 et diviser l'estimateur par un estimateur de la fonction de survie $\mathbb{P}(T \geq t)$. Cependant,

les propriétés de f_0 et s_0 ne sont pas forcément les mêmes. Ici, on souhaite faire une modélisation sur f_0 et non sur s_0.

Procédure d'estimation. On introduit les distances de Hellinger empiriques et intégrées

$$h_n^2(f_1, f_2) = \frac{1}{2}\int_0^\infty \left(\sqrt{f_2(t)} - \sqrt{f_1(t)}\right)^2 G_n(t)\,\mathrm{d}t$$
$$h_E^2(f_1, f_2) = \frac{1}{2}\int_0^\infty \left(\sqrt{f_2(t)} - \sqrt{f_1(t)}\right)^2 G(t)\,\mathrm{d}t$$

où f_1 et f_2 sont des fonctions supposées positives et intégrables, et où

$$G_n(t) = \frac{1}{n}\sum_{i=1}^n \mathbb{1}_{X_i \geq t}$$
$$G(t) = \mathbb{P}\left(X \geq t\right).$$

Comme la fonction que l'on estime n'est pas une densité, il faut modifier la définition de $T_E(f_1, f_2)$ donnée par (1.4). Ici, on propose

$$T_E(f_1, f_2) = \int_0^\infty \psi\left(f_2(t)/f_1(t)\right) f_0(t) G_n(t)\,\mathrm{d}t - \frac{1}{4}\int_0^\infty \left(f_2(t) - f_1(t)\right) G_n(t)\,\mathrm{d}t. \tag{1.12}$$

On montre alors un analogue de (1.5) mais où h^2 est remplacé par h_n^2 dans (1.5). On a ainsi $T_E(f_1, f_2) \approx h_n^2(f_0, f_1) - h_n^2(f_0, f_2)$. Il reste encore à estimer $T_E(f_1, f_2)$ car sa définition fait intervenir f_0. Ce sera via

$$T(f_1, f_2) = \frac{1}{n}\sum_{i=1}^n \psi\left(f_2(X_i)/f_1(X_i)\right) \mathbb{1}_{D_i=1} - \frac{1}{4}\int_0^\infty \left(f_2(t) - f_1(t)\right) G_n(t)\,\mathrm{d}t. \tag{1.13}$$

Pour définir la procédure d'estimation, on considère maintenant un modèle $\mathcal{F}$, c'est à dire une collection de fonctions positives et intégrables. On définit le critère comme précédemment : pour tout $f_1 \in \mathcal{F}$, on pose

$$\mathrm{crit}(f_1) = \sup_{f_2 \in \mathcal{F}} T(f_1, f_2).$$

Le ρ-estimateur $\hat{f}$ sur le modèle est alors un estimateur qui minimise ce critère sur $\mathcal{F}$ (si jamais un tel élément n'existe pas, il faut prendre un quasi minimiseur, voir [Sar21a] pour plus de détails).

Borne de risque. On peut prouver une borne de risque uniforme pour tous les modèles $\mathcal{F}$ vérifiant la condition suivante.

Hypothèse 1. *Il existe un sous ensemble $\overline{\mathcal{F}}$ de $\mathcal{F}$ avec la propriété suivante : pour tout $\bar{f} \in \overline{\mathcal{F}}$, $f \in \mathcal{F}$, $u > 0$, l'ensemble $\left\{t \in [0, +\infty[, f(t) > u\bar{f}(t)\right\}$ est une union d'au plus $2d(\bar{f})$ intervalles.*

Théorème 2 ([Sar21a]). *Pour tout $\xi > 0$, il existe un évenement de probabilité au moins $1 - e^{-\xi}$ sur lequel on a : pour tout modèle $\mathcal{F}$ vérifiant l'Hypothèse 1 et tout ρ-estimateur $\hat{f}$ sur $\mathcal{F}$,*

$$h_n^2(f_0, \hat{f}) \leq C \inf_{\bar{f} \in \overline{\mathcal{F}}} \left\{ h_n^2(f_0, \bar{f}) + \frac{d(\bar{f})}{n} \log_+^2 \left(\frac{n}{d(\bar{f})} \right) + \frac{\xi}{n} \log_+(n/\xi) \right\}, \tag{1.14}$$

En particulier,

$$\mathbb{E}\left[h_n^2(f_0, \hat{f}) \right] \leq C' \inf_{\bar{f} \in \overline{\mathcal{F}}} \left\{ \mathbb{E}\left[h_n^2(f_0, \bar{f}) \right] + \frac{d(\bar{f})}{n} \log_+^2 \left(\frac{n}{d(\bar{f})} \right) \right\}. \tag{1.15}$$

Ci dessus, C et C' sont des constantes.

Quelques éléments sur ce théorème.

— Ce résultat correspond à une version affaiblie du Théorème 3.3 de [Sar21a]. Le théorème est écrit dans ce mémoire de cette facon pour faire le lien avec une autre hypothèse qui apparaitra dans la Section 1.2 pour une autre méthode d'estimation. Elle s'avère être très flexible et est vérifiée pour un certain nombre de modèles intéressants dont ceux ci dessous.

  — L'ensemble $\mathcal{F} = \mathcal{P}_{k,r}$ composé des fonctions positives polynomiales par morceaux de degré au plus r et sur au plus k intervalles. Il vérifie l'Hypothèse 1 avec $\overline{\mathcal{F}} = \mathcal{F}$ et $d(\bar{f})$ proportionnel à $(r+1)(k+1)$.

  — Soit $\mathcal{F}$ l'ensemble des fonctions positives, intégrables, et unimodales. Alors, l'Hypothèse 1 est vérifiée avec

$$\overline{\mathcal{F}} = \bigcup_{k=1}^{\infty} \mathcal{F} \cap \mathcal{P}_{k,0}$$

  et $d(\bar{f})$ proportionnel à la plus petite valeur de k pour laquelle $\bar{f} \in \mathcal{F} \cap \mathcal{P}_{k,0}$.

  — Soit $\mathcal{F}$ l'ensemble des fonctions positives, intégrables, et dont le carré est convexe. Alors, l'hypothèse 1 est vérifiée avec

$$\overline{\mathcal{F}} = \bigcup_{k=1}^{\infty} \mathcal{F} \cap \left\{ f^2,\ f \in \mathcal{P}_{k,1} \right\}$$

  et $d(\bar{f})$ proportionnel à la plus petite valeur de k correspondant à l'ensemble k de cette union contenant $\bar{f}$. Une version analogue existe naturellement si l'on remplace convexe par concave.

— A des fins illustratives, supposons que le hazard rate soit unimodal. Dans ce cas, on peut utiliser le modèle $\mathcal{F}$ donné par le point 2 ci dessus. On peut alors majorer le terme de droite de l'inégalité (1.15) et obtenir la vitesse d'estimation $(\log^2 n/n)^{2/3}$ si f_0 est de plus bornée et à support fini. Un raisonnement similaire peut être fait pour obtenir des vitesses de convergence pour un hazard rate dont la racine carrée est convexe, concave...

— Une lecture attentive du théorème montre que j'ai prouvé le résultat (1.14) sur un événement de probabilité $1 - e^{-\xi}$ qui ne dépend pas d'un modèle particulier $\mathcal{F}$. Ce point est important car il autorise $\mathcal{F}$ à être aléatoire. On peut donc faire de la sélection d'estimateurs. Je discuterai ce point plus en détail dans le chapitre suivant. A noter que les résultats sur les ρ-estimateurs écrits dans [BBS17, BB18, BB16] supposent le modèle $\mathcal{F}$ déterministe (et couvrent uniquement le problème de l'estimation des distributions sous-jacentes).

— Comme expliqué précédemment, le 2 sur le logarithme vient d'une inégalité exponentielle maximale que j'ai dû démontrer pour contrôler le processus empirique sous-jacent. Le lecteur trouvera aussi dans l'article une Hypothèse 1 plus faible (qui s'appuie sur la notion de classe de Vapnik).
— Le Théorème 2 donne une borne de risque pour la distance de Hellinger empirique h_n. On peut aussi en déduire des résultats en espérance pour la distance intégrée h_E en tronquant l'estimateur si on le souhaite.

1.1.6. Maximum de vraisemblance. Il est difficile de conclure cette partie sur la ρ-estimation sans parler de la connexion avec le maximum de vraisemblance. Je la décris dans le cadre de l'estimation de la densité f_0 (par rapport à Lebesgue) d'une variable X à partir de données i.i.d $X_1, \ldots, X_n$.

Considérons un modèle $\mathcal{F}$ composé de fonctions positives et intégrables (pas nécessairement des densités). Alors, la log vraisemblance s'écrit pour tout $f \in \mathcal{F}$ par

$$\mathscr{L}(f) = \frac{1}{n} \sum_{i=1}^{n} \log f(X_i) - \int f(x)\,\mathrm{d}x.$$

La convention $\log 0 = -\infty$ est utilisée si besoin. Le test donné par (1.6) s'écrit

$$T(f_1, f_2) = \frac{1}{n} \sum_{i=1}^{n} \tanh\left(\frac{\log f_2(X_i) - \log f_1(X_i)}{4}\right) - \frac{1}{4} \int (f_2(x) - f_1(x))\,\mathrm{d}x.$$

Un développement limité montre que $\tanh(x) \approx x$ lorsque $x \approx 0$. Donc,

$$T(f_1, f_2) \approx \frac{1}{4} \left(\mathscr{L}(f_2) - \mathscr{L}(f_1)\right). \tag{1.16}$$

Ainsi, le critère donné par (1.7) devient

$$\mathrm{crit}(f_1) \approx \frac{1}{4} \sup_{f_2 \in \mathcal{F}} \mathscr{L}(f_2) - \frac{1}{4} \mathscr{L}(f_1).$$

Minimiser le critère revient alors, approximativement, à maximiser la log vraisemblance.

A noter cependant que ce raisonnement est approximatif. En toute généralité, les deux approches divergent. En particulier, il existe des ρ-estimateurs dans des modèles où la méthode de maximum de vraisemblance ne fonctionne pas. Les ρ-estimateurs peuvent être aussi davantage robustes par rapport à des erreurs de modèle.

Les premiers résultats relatifs au lien ρ-max de vraisemblance sont à trouver dans [BBS17] et [Sar16]. Dans le premier, il est montré :
— Qu'un estimateur par histogramme est un ρ-estimateur (Proposition 23 de [BBS17]).
— Que la probabilité qu'un estimateur du maximum de vraisemblance sur un modèle paramétrique « régulier » soit un ρ-estimateur tend vers 1 lorsque $n \to +\infty$ si le modèle est vrai (Théorème 19 de [BBS17]).

Le papier [Sar16] ne porte pas sur la procédure de ρ-estimation à proprement parler, mais il s'appuie sur des idées communes. La motivation initiale était plutôt de tenter de rendre la T-estimation implémentable en pratique dans des modèles paramétriques de petite dimension. Ce papier contient des simulations numériques dans lesquelles on retrouve essentiellement le maximum de vraisemblance lorsque le modèle est vrai et assez régulier, même si n est petit. J'ai également montré après la thèse un résultat théorique sur le lien qui existait avec le maximum de vraisemblance que j'ai inclus dans la révision.

Par ailleurs, le maximum de vraisemblance coincide avec la ρ-estimation lorsque le modèle vérifie des propriétés de convexité. Ce résultat apparait dans les Théorèmes 3.6 et 3.7 de [Sar21a] dont la première version Hal remonte à 2017. Un résultat similaire a été trouvé indépendamment par Su Weijie et inclus par la suite dans la révision de [BB18] que j'ai découvert sur Arxiv en 2017. Cette correspondance entre les deux estimateurs est à la base de toute la seconde partie de l'article [Sar21a] sur la sélection d'estimateurs.

De manière plus précise, les Théorèmes 3.6 et 3.7 affirment essentiellement que les deux estimateurs coïncident si $\mathcal{F}$ est convexe (ou si $\mathcal{F} = \left\{f^2,\, f \in \mathscr{F}\right\}$ avec $\mathscr{F}$ ensemble convexe de fonctions positives). Il n'y a d'ailleurs pas besoin de supposer que le modèle soit vrai pour qu'il s'applique. Cela signifie que l'on peut étudier un estimateur du maximum de vraisemblance via les techniques de la ρ-estimation et réciproquement. Il y a un transfert de propriétés de part et d'autre (efficacité asymptotique, robustesse...). A noter que ces deux théorèmes ne sont pas vrais que pour le modèle de densité, mais sont valides dans un cadre plus général. Ils fonctionnent par exemple aussi pour le hazard rate.

1.2. Méthode combinatoire en déconvolution

1.2.1. Introduction. Je me place maintenant dans le cadre statistique de la déconvolution de la densité. Soit donc X une variable d'intérêt de densité f_0 par rapport à la mesure de Lebesgue. Soit ε une variable indépendante de X de densité q_0 connue et $Y = X + \varepsilon$. L'objectif est d'estimer f_0 sur un compact, disons $[0, 1]$, à partir de l'observation de n copies indépendantes $Y_1, \ldots, Y_n$ de Y.

La question qui m'intéresse est de savoir s'il ne serait pas possible de construire une approche, un peu générale, et basée sur des modèles pour estimer f_0. Le choix de ces modèles se fera ensuite en fonction des propriétés supposées de f_0, en suivant l'esprit de la section précédente.

Naturellement, le problème de la déconvolution de la densité peut être résolu via des approches spécifiques. Si l'on souhaite par exemple estimer f_0 en supposant qu'elle est régulière, on peut s'appuyer sur des estimateurs à noyaux ou des estimateurs par projection. Mais il en était de même en estimation directe.

L'approche par modèles permet d'avoir plus de polyvalence que les méthodes spécifiques. Le but ici est donc d'explorer ce sujet dans un contexte de problème inverse. Pour cela, il est naturel de partir de méthodes déjà étudiées dans le cas direct. Parmi les candidats, on peut penser à la méthode du maximum de vraisemblance, à la T ou ρ-estimation, à la méthode combinatoire due à Gabor Lugosi et Luc Devroye. C'est cette dernière qui est choisie ici.

1.2.2. La méthode combinatoire dans le cas direct. Cette méthode est décrite en détail dans [DL12] et conduit à des résultats pour la perte $\mathbb{L}^1$. Pour l'expliquer dans les grandes lignes,

supposons que les X_i soient observés. Considérons un modèle $\mathcal{F}$ qui est simplement une collection de densités (éventuellement dénombrable si l'on souhaite éviter tout problème de mesurabilité).

Définissons pour toutes densités f_1, f_2, l'ensemble $[f_1 > f_2] = \{x \in [0,1],\ f_1(x) > f_2(x)\}$ et posons $\mathcal{I} = \{[f_1 > f_2],\ f_1, f_2 \in \mathcal{F}\}$. On définit ensuite pour tout $f_1 \in \mathcal{F}$,

$$\mathrm{crit}(f_1) = \sup_{I \in \mathcal{I}} \left| \int_I f_1(x)\,\mathrm{d}x - \frac{1}{n}\sum_{i=1}^n \mathbb{1}_I(X_i) \right|. \tag{1.17}$$

Il reste alors à minimiser ce critère pour obtenir un estimateur de f_0.

En un mot, la raison pour laquelle cette approche fonctionne est dû à l'identité de Scheffé qui assure que

$$d_1(f_0, f_1) = 2 \sup_I \left| \int_I f_1(x)\,\mathrm{d}x - \int_I f_0(x)\,\mathrm{d}x \right|,$$

où le supremum est pris, au choix du lecteur, soit sur tous les ensembles mesurables, soit uniquement sur l'ensemble $[f_1 > f_0]$. Ainsi,

$$d_1(f_0, f_1) \approx 2 \sup_I \left| \int_I f_1(x)\,\mathrm{d}x - \frac{1}{n}\sum_{i=1}^n \mathbb{1}_I(X_i) \right|.$$

Minimiser le critère donné par (1.17) revient alors essentiellement à minimiser la distance entre f_1 et f_0. Il faut tout de même faire attention aux ensembles sur lequel le supremum dans (1.17) est pris, car pour minimiser le critère, ils doivent être connus. Par ailleurs, les bornes de risque de l'estimateur que l'on obtient dépendent de la complexité de cette famille. Elles sont d'autant plus grandes que cette dernière est riche.

Si, maintenant, les variables X_i ne sont plus observés, le critère (1.17) ne peut plus être utilisé. Une solution est alors de remplacer la moyenne empirique des X_i par un estimateur adéquat. C'est exactement ce qui est fait dans la suite.

Naturellement, on pourrait tout de même utiliser le critère avec les X_i remplacés par les Y_i. Cela conduirait à un estimateur de $f_0 * q_0$ de la forme $\hat{f} * q_0$. On aurait aussi une majoration de $d_1(f_0 * q_0, \hat{f} * q_0)$. Cette approche serait alors, philosophiquement, pas très éloignée de celle de la ρ-estimation où l'on estime d'abord la distribution des données sous-jacente pour obtenir un estimateur de la fonction d'intérêt (voir le paragraphe précédent estimation indirecte). Le problème est qu'il est difficile de relier $d_1(f_0 * q_0, \hat{f} * q_0)$ à $d_1(f_0, \hat{f})$. L'inégalité de Young assure que $d_1(f_0 * q_0, \hat{f} * q_0) \leq d_1(f_0, \hat{f})$ mais l'inégalité dans l'autre sens n'est pas vraie en général.

1.2.3. Hypothèses

Modèles. Dans cette partie, les modèles $\mathcal{F}$ sont composés de fonctions positives et intégrables à support dans $[0,1]$ et vérifient l'hypothèse suivante.

Hypothèse 2. *Chaque fonction $f \in \mathcal{F}$ peut être associée à un entier $d(f)$ de sorte que l'affirmation suivante soit vraie : pour tout $g \in \mathcal{F}$, l'ensemble $[f > g] = \{x \in [0,1], f(x) > g(x)\}$ est une union d'au plus $\min\{d(f), d(g)\}$ intervalles. De plus, il existe une collection au plus dénombrable $\dot{\mathcal{F}} \subset \mathcal{F}$ telle que : pour tout $f \in \mathcal{F}$ et $\varepsilon > 0$, il existe $\dot{f} \in \dot{\mathcal{F}}$ vérifiant $d_1(f, \dot{f}) \leq \varepsilon$ et $d(\dot{f}) \leq d(f)$.*

Cette hypothèse est en deux parties. La deuxième est purement technique. La première fait penser à l'Hypothèse 1 écrite à la page 21. Elle s'avère être suffisamment flexible pour traiter les modèles décrits en dessous cette hypothèse (mais avec $\mathcal{F}$ remplacé par $\overline{\mathcal{F}}$). On peut ainsi considérer des modèles composés de fonctions polynomiales par morceaux, unimodales, multimodales, convexes, concaves, convexes/concaves par morceaux...

Loi des erreurs. On note la transformée de Fourier d'une fonction $f \in \mathbb{L}^1(\mathbb{R}) \cap \mathbb{L}^2(\mathbb{R})$ par

$$f^\star(t) = \int e^{itx} f(x)\,\mathrm{d}x. \tag{1.18}$$

Cette même notation $f^\star$ est gardée si f est dans $\mathbb{L}^2(\mathbb{R}) \setminus \mathbb{L}^1(\mathbb{R})$.

Hypothèse 3. *La transformée de Fourier $q_0^\star$ de q_0 ne s'annule pas. De plus, il existe trois constantes κ_1, κ_2 et $\beta > 0$ telles que pour tout $t \in \mathbb{R}$,*

$$|q_0^\star(t)|^{-2} \leq \kappa_1 + \kappa_2 |t|^{2\beta}. \tag{1.19}$$

Cette hypothèse est supposée vraie dans la suite, mais avec $\beta < 1/2$. En un certain sens, elle revient à supposer que le problème inverse n'est pas trop éloigné du cas direct. Bien que la condition $\beta < 1/2$ puisse paraitre restrictive, il y a deux arguments qui expliquent ce choix.

Argument 1. Il semble plus facile d'estimer des probabilités de la forme $\mathbb{P}(X \in I)$ où I est un intervalle que d'estimer directement la densité. En effet, si on sait estimer ces probabilités, on pourra, à minima, s'en servir pour définir un estimateur par histogramme (sans même parler de la méthode combinatoire).

Lorsque $\beta < 1/2$, la fonction $\Phi_I(x) = \overline{\mathbb{1}_I^\star(x)}[q_0^\star(x)]^{-1}$ est de carré intégrable. On peut donc considérer sa transformée de Fourier $\Phi_I^\star$ et celle ci est aussi dans $\mathbb{L}^2(\mathbb{R})$. Elle est définie presque partout, et on choisit une bonne fois pour toute sa version de sorte que Φ_I soit bien définie sur $\mathbb{R}$. Le choix de cette version n'a pas d'impact sur les résultats.

Des calculs classiques montrent que $\mathbb{E}[\phi_I^\star(Y)] = \mathbb{P}(X \in I)$. Un estimateur naturel de cette probabilité est donc

$$Z_n(I) = \frac{1}{2\pi n} \sum_{j=1}^{n} \phi_I^\star(Y_j). \tag{1.20}$$

On peut montrer en particulier que $Z_n(I)$ estime la probabilité à la vitesse $n^{-1/2}$.

Lorsque $\beta > 1/2$, cette approche ne fonctionne plus, et je ne connais pas d'estimateur sans biais de $\mathbb{P}(X \in I)$. En fait, il n'est plus possible d'estimer la probabilité à la vitesse $n^{-1/2}$ lorsque $\beta > 1/2$ sans faire d'hypothèses supplémentaires sur la densité. Pour plus de détails, je renvoie à [DGJ11] et à [Mei09]. Ils proposent des estimateurs de $\mathbb{P}(X \in I)$ sous l'hypothèse que f_0 est régulière. Malheureusement, les vitesses d'estimation dépendent inévitablement de la régularité de f_0 (elle est en particulier utilisée pour contrôler le biais des estimateurs).

Ce point est problématique pour la construction d'une procédure universelle. Si l'on veut, par exemple, s'appuyer sur la procédure de [DL12] comme décrite dans la Section 1.2.2, ce qu'il faut c'est estimer ces probabilités $\mathbb{P}(X \in I)$, et cela pour de nombreux ensembles I. Si les estimateurs des probabilités requièrent que la fonction à estimer soit régulière, on sort de l'esprit d'une procédure universelle, et on ne pourrait avoir que des résultats que pour une fonction régulière.

Argument 2. Dans ce qui précède, j'explique que les résultats pour estimer une probabilité sont différents lorsque $\beta < 1/2$ et $\beta > 1/2$, et que cela pose problème pour construire une procédure basée sur des modèles. Mais, en fait, cela a des conséquences sur les bornes de risque que l'on peut avoir lorsque l'on estime une densité.

La manière la plus simple de voir les choses est de supposer que la densité f_0 à estimer est constante par morceaux. Considérons donc une partition m de $[0,1]$ en intervalles et définissons l'ensemble

$$\mathcal{F}_m = \left\{ f,\ f = \sum_{I \in m} a_I \mathbb{1}_I,\ a_I \geq 0,\ \|f * q_0\|_\infty \leq 2 \right\}$$

composé de fonctions constantes par morceaux sur m.

Proposition 3 ([MS23])**.** *Nous avons les bornes minimax supérieures et inférieures suivantes.*

1. *Supposons l'hypothèse (1.19) vérifiée avec $\beta < 1/2$. Alors, il est possible de construire un estimateur constant par morceaux $\hat{f}_m$ tel que*

$$\sup_{f_0 \in \mathcal{F}_m} \mathbb{E}\big[d_1(f_0, \hat{f}_m)\big] \leq c \frac{|m|^{\beta+1/2}}{\sqrt{n}}, \tag{1.21}$$

   où c ne dépend que $\kappa_1, \kappa_2, \beta$.

2. *Supposons que q_0 soit bornée et que $\sqrt{q_0}$ soit « suffisamment régulière ». Alors, il existe une partition m de $[0,1]$ en intervalles de cardinal 3 telle que si n est assez grand,*

$$\inf_{\hat{f}} \sup_{f_0 \in \mathcal{F}_m} \mathbb{E}\big[d_1(f_0, \hat{f})\big] \geq 0.14 \min\{1, 1/\|q_0\|_\infty\} \tag{1.22}$$

   où l'infimum est pris sur tous les estimateurs possibles de f_0.

L'inégalité (1.21) ressemble fortement à ce que l'on pourrait avoir dans le cas de l'estimation directe (qui correspondrait essentiellement à $\beta = 0$). On observe en particulier que le coté droit de cette inégalité ne dépend de m qu'à travers son cardinal. L'inégalité (1.22) montre qu'une telle inégalité ne peut être vraie en général et que tout majorant du risque doit, en un certain sens, dépendre de la finesse des intervalles contenues dans la partition. A noter que les hypothèses sur q_0 dans les deux items sont bien incompatibles. Je renvoie à l'article pour la définition précise de régularité.

Ici, ce que l'on souhaiterait, c'est de pouvoir construire, pour un maximum de modèles $\mathcal{F}$, un estimateur $\hat{f}$ dont le risque se majore par

$$\mathbb{E}\left[d_1(f_0, \hat{f})\right] \leq c\left[d_1(f_0, \mathcal{F}) + \zeta(\dim \mathcal{F})\varepsilon_n\right],$$

où c est un facteur ne dépendant éventuellement que de q_0, où ζ est une fonction, où $\dim \mathcal{F}$ est une certaine notion de dimension, et où ε_n ne dépend que de n (typiquement $\varepsilon_n = n^{-1/2}$). Il n'est pas possible d'obtenir en général une telle inégalité si l'on considère que $\dim(\mathcal{F}_m)$ doit être de l'ordre de $|m|$.

Naturellement, tout ce qui est écrit ici ne signifie pas qu'on ne peut construire une procédure universelle lorsque β est plus grand. Mais il faudrait alors que la notion de dimension dépende de la structure de l'ensemble de manière plus compliquée. Par exemple, $\dim \mathcal{F}_m$ devrait dépendre de la taille des intervalles constitutifs de m.

1.2.4. Procédure d'estimation. A partir de maintenant, l'Hypothèse 3 est vraie avec $\beta < 1/2$.

Estimateurs de probabilités. On sait que l'on peut estimer une probabilité de la forme $\mathbb{P}(X \in I)$ en utilisant l'estimateur $Z_n(I)$ défini par (1.20). On peut montrer que $\phi_I^\star(Y)$ admet un moment d'ordre 2, au moins lorsque $f_0 * q$ est bornée. En revanche, $\phi_I^\star(Y)$ n'admet pas de moments exponentiels. Cela pose problème pour obtenir une borne de déviation exponentielle de $Z_n(I)$ autour de son espérance $\mathbb{P}(X \in I)$. L'erreur entre $Z_n(I)$ et $\mathbb{P}(X \in I)$ est donc potentiellement grande et malheureusement trop grande pour que l'on puisse l'exploiter dans une procédure d'estimation de f_0 comme celle de [DL12].

Il convient donc de remplacer la moyenne empirique $Z_n(I)$ par une version « plus robuste » et pour laquelle des bornes de déviation exponentielles peuvent être établies sous la seule hypothèse d'un moment d'ordre 2. Différentes solutions sont possibles et on propose ici d'utiliser un estimateur « median of means ». Plus d'informations sur ces estimateurs peuvent être trouvées dans [DLLO16].

On construit ainsi dans l'article un tel estimateur de $\mathbb{P}(X \in I)$. Il dépend de $\phi_I^\star(Y_1), \dots, \phi_I^\star(Y_n)$ et d'un paramètre $\delta > 0$. Notons le $\widetilde{Z}_\delta(I)$. On peut montrer qu'il vérifie avec probabilité $1 - e^{-\delta}$,

$$\begin{aligned}\left|\widetilde{Z}_\delta(I) - \mathbb{P}(X \in I)\right| &\leq C_1 \sqrt{\mathbb{E}[(\phi_I^\star(Y))^2](1+\delta)/n} \\ &\leq C_2 \sqrt{\frac{\|f_0 * q_0\|_\infty \left[\kappa_1 |I| + c_\beta \kappa_2 |I|^{1-2\beta}\right](1+\delta)}{n}}.\end{aligned}$$

Dans ces inégalités, C_1, C_2 sont des constantes et c_β ne dépend que de β.

La supériorité de cet estimateur sur la moyenne empirique réside dans le fait que l'on peut contrôler son erreur avec une borne exponentielle. L'estimateur $\widetilde{Z}_\delta(I)$ dépend de δ, c'est à dire de la probabilité de l'événement sur lequel les deux inégalités ci dessus sont vraies. C'est quelque chose de tout à fait attendu et ce n'est pas forcément gênant pour ce que l'on souhaite faire ici.

Considérons maintenant $d \geq 1$ et l'ensemble $\mathcal{I}_d$ des unions d'au plus d intervalles de $[0,1]$ dont les points extrémaux sont dans $\mathbb{Q}$. On pose $\mathcal{I} = \bigcup_{d=1}^\infty \mathcal{I}_d$ et on associe à chaque union $I \in \mathcal{I}$ le plus petit entier d_I tel que $I \in \mathcal{I}_{d_I}$. Il est possible en utilisant des techniques de discrétisation adéquates de définir pour tout $I \in \mathcal{I}$ un estimateur $\widetilde{Z}(I)$ de $\mathbb{P}(X \in I)$ de sorte que la proposition suivante soit vraie.

Proposition 4 ([MS23]). *Il existe un événement de probabilité $1 - 1/n$ sur lequel on a pour tout $I \in \mathcal{I}$,*

$$\left|\widetilde{Z}(I) - \mathbb{P}(X \in I)\right| \leq C \sqrt{\frac{\|f_0 * q_0\|_\infty \left(\kappa_1 d_I + c_\beta \kappa_2 d_I^{2\beta+1}\right) \log n}{n}},$$

où C est une constante et où c_β ne dépend que de β.

La construction de $\widetilde{Z}(I)$ étant un peu lourde, elle est omise. Le point intéressant est que cette borne est uniforme en I, et cela est crucial pour exploiter l'approche de [DL12].

On peut comparer cette inégalité avec le cas direct. L'estimateur « moyenne empirique » $n^{-1} \sum_{i=1}^n \mathbb{1}_I(X_i)$ est alors l'estimateur naturel de $\mathbb{P}(X \in I)$. On peut prouver l'inégalité

suivante sur un événement de probabilité $1 - 1/n$ uniformément pour tout $I \in \mathcal{I}$,

$$\left| \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_I(X_i) - \mathbb{P}(X \in I) \right| \leq C' \left[\sqrt{\frac{d_I}{n}} + \sqrt{\frac{\log n}{n}} \right]$$

où C' est une constante. Il suffit simplement d'utiliser Vapnik et une inégalité exponentielle de McDiarmid [McD89]. Naturellement, en estimation directe on peut définir la moyenne empirique pour des ensembles I plus généraux que des unions d'intervalles. On peut alors avoir des bornes uniformes lorsque I parcourt d'autres types de collections. De manière très brutale, en utilisant l'inégalité de Hoeffding, on peut obtenir un contrôle uniforme de l'erreur pour toute collection $\mathcal{I}$ finie mais arbitraire d'ensembles I.

Un tel résultat semble beaucoup plus délicat à montrer en estimation indirecte. Pour contrôler la variance de $\Phi_I^\star(Y)$, il « faut » essentiellement majorer la norme 2 de $\mathbb{1}_I^\star / q_0^\star$. La transformée de l'indicatrice $\mathbb{1}_I^\star$ est facile à gérer si I est un intervalle ou une union d'intervalles. Ce n'est pas vrai en général. La (borne sur la) norme 2 que j'obtiens pour $\mathbb{1}_I^\star / q_0^\star$ dans le papier dépend de d si I est une union de d intervalles disjoints. Cela suggère que « l'erreur minimale » pour estimer $\mathbb{P}(X \in I)$ peut dépendre de la structure de l'ensemble I. Il est possible qu'elle augmente avec d. Ce phénomène ne se produit pas dans le cas de l'estimation directe puisque la variance de $\mathbb{1}_I(X)$ peut se majorer indépendamment de I.

Ces deux derniers paragraphes expliquent la forme de l'Hypothèse 2. En quelque sorte, on se ramène à des unions d'intervalles car on ne sait pas estimer des probabilités pour des ensembles I quelconques.

Procédure. Soit maintenant une collection $\mathcal{F}$ de fonctions positives et intégrables à support dans $[0, 1]$ vérifiant l'Hypothèse 2. On utilise alors l'estimateur du minimum de distance de [DL12] mais en remplaçant la moyenne empirique $n^{-1} \sum_{i=1}^{n} \mathbb{1}_I(X_i)$ par $\widetilde{Z}(I)$. De manière plus précise, on définit le critère pour $f \in \mathcal{F}$, par

$$\mathrm{crit}(f) = \sup_{I \in \mathcal{I}_{d(f)}} \left| \int_I f - \widetilde{Z}(I) \right|. \tag{1.23}$$

On définit $\tilde{f}$ comme n'importe quel estimateur de $\mathcal{F}$ vérifiant

$$\mathrm{crit}(\tilde{f}) \leq \inf_{f \in \mathcal{F}} \mathrm{crit}(f) + 1/n. \tag{1.24}$$

On renormalise ensuite l'estimateur :

$$\hat{f} = \min \left\{ 1, \left(\int \tilde{f} \right)^{-1} \right\} \tilde{f}. \tag{1.25}$$

Remarque : le supremum dans (1.23) porte sur les ensembles I de $\mathcal{I}_{d(f)}$ qui dépend de f. Luc Devroye et Gabor Lugosi considèrent plutôt un supremum sur tous les ensembles I de la forme $[f > g]$ où f et g parcourent le modèle. Ce raffinement est important pour démontrer le Théorème 5 ci dessous.

1.2.5. Résultats. Le risque $\mathbb{L}^1$ de l'estimateur $\hat{f}$ ci dessus peut être contrôlé de la manière suivante.

Théorème 5 ([MS23]). *Soit $\mathcal{F}$ une collection de fonctions positives, intégrables et à support dans $[0,1]$ vérifiant l'Hypothèse 2. Supposons l'Hypothèse 3 vérifiée avec $\beta < 1/2$. Alors,*

$$\mathbb{E}\left[d_1(f_0\mathbb{1}_{[0,1]},\hat{f})\right] \leq 5 \inf_{f\in\mathcal{F}} \left\{ d_1(f_0\mathbb{1}_{[0,1]},f) + c\sqrt{\|f_0 * q_0\|_\infty \frac{\left(\kappa_1 d(f) + c_\beta \kappa_2 (d(f))^{1+2\beta}\right)\log(nd(f))}{n}} + \frac{1}{n} \right\},$$

où c est une constante, et où c_β ne dépend que de β.

On observe que la borne de risque est bien écrite pour une perte $\mathbb{L}^1$ entre la fonction f_0 et l'estimateur (et non entre $f_0 * q_0$ et $\hat{f} * q_0$). En réalité, f_0 est remplacé par $f_0\mathbb{1}_{[0,1]}$ car l'objectif ici est d'estimer f_0 sur $[0,1]$ (rappelons que $\hat{f}$ est à support dans $[0,1]$ car les fonctions du modèle le sont). Si jamais f_0 était aussi à support compact dans $[0,1]$, $f_0 = f_0\mathbb{1}_{[0,1]}$.

Cette inégalité est vraie sans aucun a priori sur la densité f_0. Il convient maintenant de considérer des modèles $\mathcal{F}$ et de calculer ou de majorer l'infimum pour obtenir des bornes de risque plus précises lorsque f_0 vérifie telle ou telle contrainte. Voici 3 exemples.

Fonctions polynomiales par morceaux. Considérons le modèle $\mathcal{F}$ composé des fonctions positives, polynomiales par morceaux sur au plus k intervalles de $[0,1]$ et de degré au plus r. Cet ensemble vérifie l'Hypothèse 2 avec $d(f)$ proportionnel à $k(r+1)$, quelque soit $f \in \mathcal{F}$. Le Théorème 5 assure donc si $f_0\mathbb{1}_{[0,1]} \in \mathcal{F}$,

$$\mathbb{E}\big[d_1(f_0\mathbb{1}_{[0,1]},\hat{f})\big] \leq c\|f_0 * q_0\|_\infty^{1/2} \frac{(k(r+1))^{\beta+1/2}\sqrt{\log(nk(r+1))}}{\sqrt{n}},$$

où c ne dépend que de β.

Cette vitesse est donc essentiellement paramétrique. A noter que les intervalles n'ont pas besoin d'être connus par le statisticien, et que certains d'entre eux peuvent être très petits.

Fonctions unimodales. L'approche peut aussi être utilisée pour estimer une densité unimodale sur $[0,1]$. On choisit un modèle $\mathcal{F}$ adéquat et on calcule l'infimum dans le Théorème 5. L'estimateur $\hat{f}$ ne requiert pas la connaissance du mode et son risque $\mathbb{E}[d_1(f_0\mathbb{1}_{[0,1]},\hat{f})]$ tend vers 0 au moins à la vitesse $(\log n/n)^{1/(2\beta+3)}$ si f_0 est de plus bornée (la norme supérieure de f_0 n'a pas besoin d'être connue).

Ce facteur logarithmique est indésirable puisqu'on peut avoir la même borne de risque à l'aide d'un estimateur constant par morceaux sur une partition bien choisie si le mode de f_0 est connu (voir la Section 2.5 de [MS23]). L'exposant $1/(2\beta+3)$ est néanmoins, en général, le bon (voir la Proposition 5 de [MS23] pour une borne inférieure minimax).

Remarque : on peut montrer que l'estimateur $\hat{f}$ ci dessus atteindra au moins la vitesse $\sqrt{\log n/n}$ si f_0 est non seulement unimodale mais aussi constante par morceaux (sur un nombre fini de morceaux). Ce phénomène d'accélération des vitesses de convergence fait écho à celui qui se produit

pour l'estimateur de Grenander dans le cas direct (ou pour les moindres carrés en régression isotonique). Pour quelques références, voir [Zha02, Cha14, BT15, CGS15, GS15, Bel18, CL19].

Fonctions concaves. Il est possible de renforcer la contrainte de forme précédente pour obtenir de meilleurs résultats en choisissant un autre modèle. A titre d'exemple, si on remplace f_0 unimodale par f_0 concave sur $[0,1]$, le Corollaire 2 de [MS23] montre que l'estimateur $\hat{f}$ peut converger à la vitesse $(\log n/n)^{2/(2\beta+5)}$. Cette vitesse est donc plus rapide que celle que l'on avait dans la section précédente sous une hypothèse d'unimodalité. On montre que cette vitesse est, en général, bien la bonne, aux facteurs logs près (voir la Proposition 7 de [MS23] pour une borne inférieure minimax).

Chapitre 2

Sélection d'estimateurs

J'ai proposé dans [Sar17, Sar21a, Sar21b, Sar23] d'estimer une fonction en faisant de la sélection d'estimateurs. Il y avait deux grands arguments qui justifiaient à mes yeux cette approche. Le premier était de réduire la complexité numérique de certaines procédures. Le deuxième était de démontrer de nouveaux résultats théoriques. Les méthodes décrites ici ressemblent aux méthodes de sélection de Lepski ou à celle de la ρ-estimation. Elles ont néanmoins été modifiées pour des raisons de complexité computationnelle.

2.1. Programmation dynamique

2.1.1. Collections de partitions. Dans ce chapitre, on va avoir besoin de collections de partitions particulières. Les voici.

Collection 1. Soit $\mathcal{X} \subset \mathbb{R}$ un ensemble fini de la forme $\mathcal{X} = \{x_1, \dots, x_n\}$ où $x_1 < \cdots < x_n$. On définit $\mathcal{M}_{tot}(\mathcal{X})$ comme étant l'ensemble regroupant toutes les partitions de $[x_1, x_n]$ en intervalles de la forme

$$m = \{[x_1, x_{i_1}], (x_{i_1}, x_{i_2}], \dots, (x_{i_k}, x_n]\}, \tag{2.1}$$

où $k \geq 0$ et où $1 < i_1 < i_2 < \cdots < i_k < n$. On utilise la convention $m = \{[x_1, x_n]\}$ lorsque $k = 0$.

Collection 2. Au lieu de fixer les points x_i, on peut les laisser librement varier dans $\mathbb{R}$. Cela amène à la collection

$$\mathcal{M}_{tot} = \bigcup_{\mathcal{X} \subset \mathbb{R}} \mathcal{M}_{tot}(\mathcal{X}).$$

Cette dernière est donc simplement composée de familles disjointes d'intervalles de $\mathbb{R}$.

Collection 3. Lorsque l'on souhaite estimer une fonction régulière sur un compact, il n'est pas nécessaire de considérer des collections aussi riches que précédemment. On peut considérer des collections un peu moins riches mais ayant des propriétés d'approximation satisfaisantes comme celles définies via l'algorithme de [DY90].

Cet algorithme est décrit à de nombreux endroits dans la littérature. Pour fixer les notations, je le rappelle ci dessous en suivant la présentation de [Sar23].

Soit $\mathscr{I}$ la collection d'intervalles I de $[0,1]$ qui sont soit de la forme $[a,b)$ avec $a<b<1$, soit de la forme $[a,1]$ avec $a<1$. On peut diviser chaque intervalle $I \in \mathscr{I}$ en deux intervalles disjoints $I_1, I_2 \in \mathscr{I}$ de même taille et contiguës. On définit pour toute partition m de $[0,1]$ en intervalles I de $\mathscr{I}$, la collection

$$\mathcal{M}_m = \bigcup_{m' \subset m} (m \setminus m') \cup \left\{ I_1, I_2,\, I \in m' \right\}.$$

Cet ensemble regroupe ainsi toutes les partitions de $[0,1]$ qui peuvent être déduites de m en appliquant la division ci dessus à certains de ses intervalles.

On définit ensuite $\mathcal{M}_{DY}(\ell)$ par récurrence. Lorsque $\ell = 0$, $\mathcal{M}_{DY}(0) = \{\{[0,1]\}\}$, contient la partition triviale de $[0,1]$ réduit à un élément. Pour $\ell \geq 1$, on pose

$$\mathcal{M}_{DY}(\ell) = \mathcal{M}_{DY}(\ell-1) \cup \bigcup_{m \in \mathcal{M}_{DY}(\ell-1)} \mathcal{M}_m.$$

Ainsi, ℓ indique la finesse maximale des partitions m de $\mathcal{M}_{DY}(\ell)$ (les intervalles sont de longueurs au moins $2^{-\ell}$). Si l'on ne veut mettre aucune condition sur cette finesse, on peut considérer $\mathcal{M}_{DY} = \bigcup_{\ell \geq 0} \mathcal{M}_{DY}(\ell)$.

Notations. Il sera parfois utile de s'intéresser à des collections m dont le cardinal est fixé ou majoré. C'est la raison pour laquelle on posera pour toute collection $\mathcal{M}$ de partitions, et $k \geq 0$,

$$\begin{aligned} \mathcal{M}_{k-} &= \{m \in \mathcal{M},\, |m| \leq k\} \\ \mathcal{M}_k &= \{m \in \mathcal{M},\, |m| = k\}. \end{aligned}$$

L'indice indique ainsi une condition sur le cardinal des partitions.

2.1.2. Algorithmie. A moins que $\mathcal{X}$ ou ℓ soient vraiment très petits, il n'est pas possible en pratique d'optimiser un critère $\mathrm{crit}(\cdot)$ sur l'une des collections de partitions précédentes en calculant tous les $\mathrm{crit}(m)$ possibles. Il y a beaucoup trop de partitions à considérer.

Heureusement, les partitions de $\mathcal{M}_{\mathrm{DY}}(\ell)$ et $\mathcal{M}_{tot}(\mathcal{X})$ ont une structure particulière. Il est ainsi généralement possible de s'en sortir si le critère a certaines propriétés d'additivité. Plus précisément, s'il écrit de la forme

$$\mathrm{crit}(m) = \sum_{I \in m} F(I) \tag{2.2}$$

où $F(\cdot)$ est une fonction. Il faut pour cela utiliser un algorithme dynamique adapté au problème. Pour des exemples de tels algorithmes dans la littérature statistique, voir [Kan92, Don97, BSR04, CR04, AL11, Aka12]. L'optimisation du critère devient alors généralement faisable.

2.2. Un ρ-estimateur modifié polynomial par morceaux

2.2.1. Objectif. L'un des défauts majeurs de la ρ-estimation réside dans sa complexité numérique. Lorsque le modèle possède des propriétés de convexité, la ρ-estimation se ramène au maximum de vraisemblance et son calcul effectif est facilité. Pour d'autres modèles, en revanche, le problème semble numériquement insoluble. Une question naturelle est donc de savoir s'il est possible de construire, en un temps raisonnable, un estimateur possiblement différent mais avec des propriétés statistiques similaires.

2.2.2. Simulations numériques dans la littérature. Le problème de la complexité numérique n'est pas propre à la ρ-estimation mais s'inscrit dans le contexte plus général de l'estimation en utilisant des tests. Si l'on jette un coup d'œil à la littérature, on s'aperçoit qu'il existe désormais au moins cinq travaux faisant des simulations numériques avec des tests égaux ou ayant des propriétés similaires à $T(f_1, f_2)$. Par ordre chronologique :

1. Mon article [Sar14]. Il permet de faire de la sélection par histogramme dans le cas des chaînes de Markov et pour des partitions de $\mathcal{M}_{DY}(\ell)$ (en dimension $2d$, où l'on remplace les intervalles par des cubes). J'avais remarqué dans cet article les très bonnes performances numériques de la procédure par rapport aux moindres carrés (ce qui n'était pas garanti à priori malgré les résultats théoriques). Vu la proximité entre la méthode et la ρ-estimation, on peut logiquement penser que cela reste le cas pour celle ci. A l'époque, je n'avais pas pensé à comparer avec le maximum de vraisemblance, la connexion entre les deux ayant été remarquée plus tard. Les idées développées dans l'article pour réduire la complexité numérique ne sont pas propres aux chaînes de Markov mais peuvent naturellement s'étendre à d'autres cadres statistiques.
2. Mon article [Sar16]. J'avais proposé une nouvelle facon d'utiliser le test pour faire de l'estimation paramétrique. L'approche est justifiée par des résultats théoriques et est très rapide en pratique lorsque la « dimension » du modèle est très petite. J'avais en particulier étudié numériquement (et théoriquement) la connexion entre mon estimateur et le max de vraisemblance. Il lui était très proche lorsque le modèle était vrai et que l'estimateur du maximum de vraisemblance fonctionnait bien. On pouvait aussi l'utiliser dans des cas où l'estimateur du maximum de vraisemblance n'existait pas ou lorsque l'on voulait davantage de robustesse.
3. La thèse de Nelo Molter. Il s'était lui aussi intéressé à la question de la réduction de la complexité numérique des procédures de sélection d'estimateurs basées sur des tests. Son approche est basée sur du Hold-Out ou du V-fold. Techniquement, cela permet de voir les estimateurs comme des éléments essentiellement déterministes et d'avoir ainsi une procédure qui fonctionne pour tout type d'estimateurs (positifs). La procédure qu'il propose vise à avoir une complexité numérique plus petite que le nombre d'estimateurs candidats au carré. Je renvoie aux Chapitres 5 et 6 de sa thèse [Mag15] pour une description de ses idées, de ses résultats et de ses simulations numériques.
4. L'article [Sar21a]. La motivation était la suivante : je savais qu'utiliser un test tel que $T(f_1, f_2)$ pouvait conduire à de très bons résultats numériques. Cela avait été vu dans [Sar16] lorsque les modèles, avaient, en un certain sens, peu de degrés de libertés (pour un test très proche). Je voulais savoir si cela restait vrai pour des modèles en ayant beaucoup plus. Dans ces cas là, les propriétés de robustesses supérieures que l'on a par rapport au max de vraisemblance sont moins

importantes car la fonction à estimer est mécaniquement plus proche du modèle. La question est donc de quantifier le gain éventuel.

5. L'article [BC24b]. Dans cet article les auteurs s'intéressent à l'estimation d'une fonction de régression dans des familles exponentielles (paramétriques) via ρ-estimation. Dans les simulations numériques, ils génèrent une suite de fonctions $(f_n)_{n\geq 0}$ du modèle $\mathcal{F}$ par récurrence en posant $f_{n+1} = \arg\max_{g\in\mathcal{F}} T(f_n, g)$. Leur estimateur est alors une valeur de f_n pour n assez grand. Leurs résultats numériques sont dans le même esprit que les précédents. Je n'ai néanmoins pas trouvé de résultat théorique garantissant que cet algorithme conduit nécessairement à un ρ-estimateur.

2.2.3. Motivations et cadre statistique. Les résultats que je décris dans cette Section 2.2 ont été démontrées dans [Sar21a]. Par souci de simplicité, je me place dans le cadre statistique de l'estimation de la densité, mais les résultats sont en fait plus généraux (ils admettent par exemple une version adaptée au problème de l'estimation du hazard rate en données censurées).

Le modèle de dimension plutôt grande qui m'intéresse ici est un modèle composé de fonctions polynomiales par morceaux. De manière un peu plus précise, on considère une collection (finie, non-vide) m d'intervalles de $\mathbb{R}$ et $r \geq 0$. On définit

$$\mathcal{P}_r(m) = \left\{ \sum_{I\in m} f_I \mathbb{1}_I, \text{ telle que chaque } f_I \text{ est une fonction polynomiale de degré au plus } r \right\}.$$

Soit $\mathcal{P}_{r,+}(m)$ le sous ensemble de $\mathcal{P}_r(m)$ composé des fonctions $f \in \mathcal{P}_r(m)$ qui sont positives. Je souhaite savoir si on peut construire un estimateur sur $\cup_{m\in\mathcal{M}_{\text{tot}}} \mathcal{P}_{r,+}(m)$ ou sur $\cup_{m\in\mathcal{M}_{\text{tot},k}} \mathcal{P}_{r,+}(m)$ avec de bonnes propriétés théoriques, que l'on peut vérifier numériquement.

2.2.4. Max de vraisemblance. Pour avancer sur le sujet, notons tout d'abord qu'il est relativement facile de construire un ρ-estimateur polynomial par morceaux lorsque ces derniers sont donnés par le statisticien.

On peut en effet définir un estimateur $\hat{f}_m$ à valeurs dans $\mathcal{P}_{r,+}(m)$ en maximisant la vraisemblance $\mathcal{L}(\cdot)$ sur l'ensemble convexe $\mathcal{P}_{r,+}(m)$. On déduit de la connexion max de vraisemblance – ρ-estimateur décrite dans la Section 1.1.6 que l'estimateur $\hat{f}_m$ est un ρ-estimateur. On peut donc contrôler son risque en appliquant une version du Théorème 2 pour le modèle de densité. Cela conduit à

$$h^2(f_0, \hat{f}_m) \leq C \left\{ h^2(f_0, \mathcal{P}_{r,+}(m)) + \frac{|m|(r+1)}{n} \log_+^2 \left(\frac{n}{|m|(r+1)} \right) + \frac{\xi}{n} \log_+(n/\xi) \right\}. \tag{2.3}$$

Cette inégalité est valide pour tout $\xi > 0$ sur un événement de probabilité $1 - e^{-\xi}$ ne dépendant pas de m.

L'intérêt de pouvoir appliquer la théorie de la ρ-estimation est que le terme de biais dans cette borne est pour la distance de Hellinger. Il n'est pas toujours possible d'avoir un tel résultat. Tous les estimateurs du maximum de vraisemblance ne sont pas robustes par rapport à une erreur de modèle mesurée à l'aide de h. Par ailleurs, le résultat assure un contrôle du risque de tous les estimateurs $\hat{f}_m$ et pas seulement un. Cela est particulièrement important pour pouvoir choisir ensuite la partition m.

2.2.5. Collection de partitions. Si l'on souhaite laisser les données choisir la partition, en fixant pour simplifier pour le moment son cardinal, on pourrait appliquer la ρ-estimation au modèle aléatoire $\mathcal{F} = \{\hat{f}_m,\, m \in \mathcal{M}_{\mathrm{tot},k}\}$. Cette idée fonctionne théoriquement, car le Théorème 2 autorise les modèles aléatoires. Cependant, elle se heurte à un problème computationnel en raison du cardinal infini de $\mathcal{M}_{\mathrm{tot},k}$.

Je propose donc de remplacer $\mathcal{M}_{\mathrm{tot},k}$ par une collection finie mais suffisamment riche pour que l'estimateur qui en résulte ait des propriétés statistiques similaires à celui que l'on aurait eu si on avait utilisé la collection $\mathcal{M}_{\mathrm{tot},k}$. Le choix de cette collection dépend du cadre statistique étudié. Pour le modèle de densité, on peut remplacer $\mathcal{M}_{\mathrm{tot}}$ par $\widehat{\mathcal{M}}_{\mathrm{tot}} = \mathcal{M}_{\mathrm{tot}}(\mathcal{X})$ où $\mathcal{X} = \{X_1, \ldots, X_n\}$ (voir la Section 2.1.1 pour sa définition). On vise alors à sélectionner un estimateur parmi $\{\hat{f}_m,\, m \in \widehat{\mathcal{M}}_{\mathrm{tot},k}\}$.

2.2.6. Heuristique. Utiliser la procédure de la ρ-estimation pour $\mathcal{F} = \{\hat{f}_m,\, m \in \widehat{\mathcal{M}}_{\mathrm{tot},k}\}$ semble délicat en pratique car le cardinal de $\widehat{\mathcal{M}}_{\mathrm{tot},k}$ reste grand. Le critère ne semble par ailleurs pas avoir les propriétés permettant de faire de la programmation dynamique comme décrit dans la Section 2.1.2. Une solution est donc de le transformer.

J'explique ici les idées sous-jacentes conduisant à cette transformation et pourquoi cette transformation fonctionne. L'heuristique est inévitablement un peu lourde. Elle n'apparait pas dans l'article publié. L'intérêt de l'écrire dans ce mémoire est qu'on pourra faire le lien avec les autres transformations que j'ai faites dans les articles [Sar21b, Sar23].

Considérons deux collections m, m' et un intervalle I de m. Comme expliqué dans la Section 1.1.2, le test $T(\hat{f}_m \mathbb{1}_I, \hat{f}_{m'} \mathbb{1}_I)$ défini par (1.6) peut être vu comme $T_E(\hat{f}_m \mathbb{1}_I, \hat{f}_{m'} \mathbb{1}_I)$ plus une erreur stochastique. Il était écrit que le premier terme $T_E(\hat{f}_m \mathbb{1}_I, \hat{f}_{m'} \mathbb{1}_I)$ était, en quelque sorte, une approximation de $h^2(f_0, \hat{f}_m \mathbb{1}_I) - h^2(f_0, \hat{f}_{m'} \mathbb{1}_I)$. En fait, on peut montrer que $T_E(\hat{f}_m \mathbb{1}_I, \hat{f}_{m'} \mathbb{1}_I) \approx h^2(f_0 \mathbb{1}_I, \hat{f}_m \mathbb{1}_I) - h^2(f_0 \mathbb{1}_I, \hat{f}_{m'} \mathbb{1}_I)$. Plus précisément, l'inégalité (1.5) est vraie avec f_0 remplacé par $f_0 \mathbb{1}_I$, f_1 par $\hat{f}_m \mathbb{1}_I$ et f_2 par $\hat{f}_{m'} \mathbb{1}_I$.

Considérons une collection m, et pour tout $I \in m$, une collection m'_I. On peut montrer que l'erreur stochastique $\sum_{I \in m} \mathcal{E}(\hat{f}_m \mathbb{1}_I, \hat{f}_{m'_I} \mathbb{1}_I) = \sum_{I \in m} (T(\hat{f}_m \mathbb{1}_I, \hat{f}_{m'_I} \mathbb{1}_I) - T_E(\hat{f}_m \mathbb{1}_I, \hat{f}_{m'_I} \mathbb{1}_I))$ (rappel : $\mathcal{E}(\cdot, \cdot)$ est définie par (1.8)) est, avec grande probabilité, au plus de l'ordre de

$$\sum_{I \in m} \Big\{ \varepsilon\big(h^2(f_0 \mathbb{1}_I, \hat{f}_m \mathbb{1}_I) + h^2(f_0 \mathbb{1}_I, \hat{f}_{m'_I} \mathbb{1}_I)\big) + \mathcal{E}\big(|m'_I \vee I|\big) \Big\}$$

où

$$\mathcal{E}(x) = \kappa x \frac{(r+1) \log_+^2 (n/(r+1))}{n},$$

où

$$|m'_I \ \vee I| = \left\{ I' \cap I,\, (I, I') \in m \times m'_I \right\},$$

où $\varepsilon > 0$ est petit, et où κ est une constante à préciser. Ce résultat est vrai uniformément pour toutes collections m et m'_I d'intervalles disjoints.

Posons maintenant

$$F_k(I) = \sup_{m' \in \widehat{\mathcal{M}}_{\mathrm{tot},k}} \Big\{ T\big(\hat{f}_m \mathbb{1}_I, \hat{f}_{m'} \mathbb{1}_I\big) - \mathcal{E}(|m' \vee I|) \Big\}. \tag{2.4}$$

Noter que $\hat{f}_m \mathbb{1}_I$ ne dépend pas de m et donc $F_k(I)$ est bien défini. Ce qui précède suggère que $F_k(I) \lessapprox h^2(f_0\mathbb{1}_I, \hat{f}_m\mathbb{1}_I)$. En particulier, si l'on pose $\mathcal{A} = [X_{(1)}, X_{(n)}]$ (où la notation parenthésée fait référence aux statistiques d'ordre),

$$\mathrm{crit}_k(m) = \sum_{I \in m} F_k(I), \tag{2.5}$$

on devrait avoir $\mathrm{crit}_k(m) \lessapprox h^2(f_0\mathbb{1}_{\mathcal{A}}, \hat{f}_m)$. Par ailleurs, pour tout $m, m' \in \widehat{\mathcal{M}}_{\mathrm{tot},k}$,

$$\begin{aligned} h^2(f_0\mathbb{1}_I, \hat{f}_m\mathbb{1}_I) &\lessapprox h^2(f_0\mathbb{1}_I, \hat{f}_{m'}\mathbb{1}_I) + T\big(\hat{f}_m\mathbb{1}_I, \hat{f}_{m'}\mathbb{1}_I\big) - \mathcal{E}(|m' \vee I|) + 2\mathcal{E}(|m' \vee I|) \\ &\lessapprox h^2(f_0\mathbb{1}_I, \hat{f}_{m'}\mathbb{1}_I) + 2\mathcal{E}(|m' \vee I|) + F_k(I). \end{aligned}$$

Si on somme sur tous les $I \in m$,

$$h^2(f_0\mathbb{1}_{\mathcal{A}}, \hat{f}_m) \lessapprox h^2(f_0\mathbb{1}_{\mathcal{A}}, \hat{f}_{m'}) + 2\mathcal{E}(2k) + \mathrm{crit}_k(m).$$

Ainsi, une facon d'essayer de minimiser le risque de l'estimateur est de définir un minimiseur $\widehat{m} \in \widehat{\mathcal{M}}_{\mathrm{tot},k}$ du critère (2.5). En exploitant l'inégalité $\mathrm{crit}_k(m) \lessapprox h^2(f_0\mathbb{1}_{\mathcal{A}}, \hat{f}_m)$, on obtient,

$$h^2(f_0\mathbb{1}_{\mathcal{A}}, \hat{f}_{\widehat{m}}) \lessapprox \inf_{m \in \widehat{\mathcal{M}}_{\mathrm{tot},k}} \left\{ h^2(f_0\mathbb{1}_{\mathcal{A}}, \hat{f}_m) + \mathcal{E}(2k) \right\}.$$

Comme les partitions que l'on considère sont des partitions de $\mathcal{A}$, on a toujours $h^2(f_0, f_0\mathbb{1}_{\mathcal{A}}) \lessapprox h^2(f_0, \hat{f}_m)$ et l'inégalité précédente se réécrit sans l'indicatrice $\mathbb{1}_{\mathcal{A}}$:

$$h^2(f_0, \hat{f}_{\widehat{m}}) \lessapprox \inf_{m \in \widehat{\mathcal{M}}_{\mathrm{tot},k}} \left\{ h^2(f_0, \hat{f}_m) + \mathcal{E}(2k) \right\}.$$

Notons que (2.5) est bien de la forme (2.2). Si on rentre un peu plus dans le détail, on s'aperçoit qu'il faut en réalité résoudre un double problème d'optimisation pour trouver $\widehat{m}$. Il faut certes minimiser le critère, mais le calcul du supremum dans (2.4) n'est pas à oublier. Heureusement, la formule dans le supremum peut aussi s'écrire de la forme (2.2). On peut donc utiliser un algorithme adéquat pour faire le calcul en pratique, du moins lorsque k et n se sont pas trop grands.

Remarque : le fait que le test $T(\hat{f}_m\mathbb{1}_I, \hat{f}_{m'}\mathbb{1}_I)$ puisse être utilisé pour approcher $f_0\mathbb{1}_I$ et non f_0 est crucial ici. Si l'on utilisait la définition proposée dans [BB18], $T_E(\hat{f}_m\mathbb{1}_I, \hat{f}_{m'}\mathbb{1}_I)$ aurait été perçu comme $h^2(f_0, \hat{f}_m\mathbb{1}_I) - h^2(f_0, \hat{f}_{m'}\mathbb{1}_I)$. Les arguments précédents ne fonctionneraient alors plus car on ne pourrait plus sommer sur I.

2.2.7. Résultats théoriques

Inégalité oracle. Considérons une variable aléatoire $\hat{k}$ à valeurs dans $\{1, \ldots, n-1\}$. Soit $\widehat{m}$ un minimiseur de (2.5) appliqué à $k = \hat{k}$. On peut alors montrer que la procédure précédente sélectionne le meilleur estimateur de la famille $\{\hat{f}_m,\, m \in \widehat{\mathcal{M}}_{\mathrm{tot},\hat{k}}\}$, à une constante multiplicative près et à un terme additionnel près si κ est suffisamment grand. Plus précisément :

Théorème 6 ([Sar21a]). *Il existe κ_0 tel que si $\kappa \geq \kappa_0$, l'estimateur $\hat{f}_{\widehat{m}}$ vérifie pour tout $\xi > 0$, et probabilité au moins $1 - e^{-\xi}$,*

$$h^2(f_0, \hat{f}_{\widehat{m}}) \leq C \left[\inf_{m \in \widehat{\mathcal{M}}_{tot,\hat{k}}} h^2(f_0, \hat{f}_m) + \kappa \frac{(r+1)\hat{k} \log_+^2(n/(r+1))}{n} + \frac{\xi}{n} \log_+(n/\xi) \right]. \tag{2.6}$$

En particulier,

$$\mathbb{E}\left[h^2(f_0, \hat{f}_{\widehat{m}}) \right] \leq C' \mathbb{E} \left[\inf_{m \in \widehat{\mathcal{M}}_{tot,\hat{k}}} h^2(f_0, \hat{f}_m) + \kappa \frac{(r+1)\hat{k} \log_+^2 (n/(r+1))}{n} \right]. \tag{2.7}$$

Les paramètres κ_0, C et C' sont des constantes.

Le résultat précédent est utile pour déterminer la meilleure partition de $\widehat{\mathcal{M}}_{\text{tot}}$ à cardinal fixé. On peut modifier la procédure en pénalisant le critère pour laisser les données choisir ce cardinal. On obtient alors des inégalités similaires à (2.6) et (2.7) mais où l'infimum porte en plus sur tous les k inférieurs à un seuil souhaité. Les détails de la procédure sont dans l'article. Le résultat est le suivant.

Théorème 7 ([Sar21a]). *Soit $\hat{k}$ une variable aléatoire à valeurs dans $\{1, \ldots, n-1\}$. On peut construire un estimateur $\hat{f}_{\widehat{m}}$ où $\widehat{m} \in \widehat{\mathcal{M}}_{tot,\hat{k}-}$ de sorte que l'on ait pour tout $\xi > 0$, et probabilité au moins $1 - e^{-\xi}$,*

$$h^2(f_0, \hat{f}_{\widehat{m}}) \leq C \left[\inf_{1 \leq k \leq \hat{k}} \left\{ \inf_{m \in \widehat{\mathcal{M}}_{tot,k}} h^2(f_0, \hat{f}_m) + \frac{(r+1)k \log_+^2(n/(r+1))}{n} \right\} + \frac{\xi}{n} \log_+(n/\xi) \right]. \tag{2.8}$$

En particulier,

$$\mathbb{E}\left[h^2(f_0, \hat{f}_{\widehat{m}}) \right] \leq C' \mathbb{E} \left[\inf_{1 \leq k \leq \hat{k}} \left\{ \inf_{m \in \widehat{\mathcal{M}}_{tot,k}} h^2(f_0, \hat{f}_m) + \frac{(r+1)k \log_+^2(n/(r+1))}{n} \right\} \right]. \tag{2.9}$$

Les termes C et C' sont des constantes.

Réécriture de la borne de risque. Les deux théorèmes précédents garantissent que l'estimateur sélectionné est, essentiellement, le meilleur de la famille considérée (à une constante et à un terme de variance près).

Il convient néanmoins de pousser l'analyse un peu plus loin en étudiant les distances aux estimateurs $\hat{f}_m$ dans (2.7) et (2.9). Pour cela, remarquons que l'inégalité (2.3) peut être utilisée pour transformer $\inf_{m \in \widehat{\mathcal{M}}_{\text{tot},k}} h^2(f_0, \hat{f}_m)$ en $\inf_{m \in \widehat{\mathcal{M}}_{\text{tot},k}} h^2(f_0, \mathcal{P}_{r,+}(m))$. Ce dernier infimum porte sur des partitions aléatoires particulières, et on aimerait savoir s'il ne pourrait pas porter à la place sur toute la collection infinie $\mathcal{M}_{\text{tot},k}$.

Je présente ici un résultat de l'article [Sar21a] appliqué lorsque $\hat{k} = n - 1$ et lorsqu'on laisse les données choisir le cardinal de la partition. L'estimateur $\hat{f}_{\hat{m}}$ du Théorème 7 vérifie alors

$$\mathbb{E}\left[h^2(f_0, \hat{f}_{\hat{m}}) \right] \leq C'' \mathbb{E} \left[\inf_{k \geq 1} \left\{ \inf_{m \in \mathcal{M}_{\text{tot},k}} h^2(f_0, \mathcal{P}_{r,+}(m)) + \frac{k(r+1) \log_+^2(n/(r+1))}{n} \right\} \right],$$

où C'' est une constante.

Cette borne de risque est tout à fait similaire à celle que l'on aurait eu avec un ρ-estimateur (pénalisé). En particulier, la stratégie qui consiste à travailler avec les partitions de $\widehat{\mathcal{M}}_{\text{tot}}$ pour obtenir des résultats sur la collection infinie $\mathcal{M}_{\text{tot}}$ fonctionne.

2.2.8. Une illustration numérique. Je propose d'illustrer la méthode numériquement dans le cas où $r = 0$, $n = 100$, les données sont Gaussiennes $\mathcal{N}(0, 1)$ et le cardinal de la partition est fixé. Le paramètre κ ici est calibré en ré-appliquant la ρ-estimation. Les détails sont dans [Sar21a] (ainsi que des simulations numériques plus complètes).

J'ai représenté ci dessous le risque de Hellinger (carré) de l'estimateur (en bleu) et celui du maximum de vraisemblance (en rouge). Le risque est en ordonnée, et en abscisse est indiquée la valeur de k. Le risque et la probabilité sont calculés par méthode de Monte-Carlo en simulant 1000 fois les données.

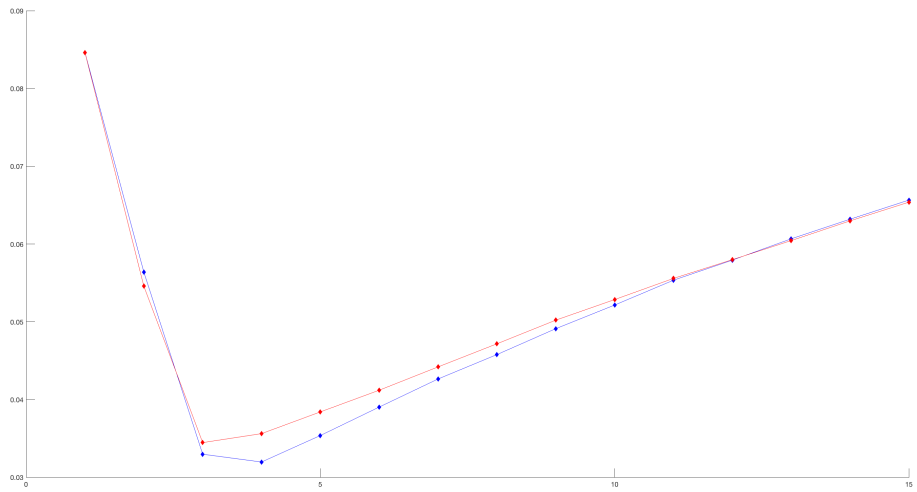

FIGURE 2.1 – Comparaison du risque entre le maximum de vraisemblance et le ρ-estimateur modifié

On déduit de cet exemple que les risques des deux estimateurs ne sont pas fondamentalement différents. Si l'on regarde plus dans le détail, on s'aperçoit que le ρ-estimateur modifié a tendance à faire un peu mieux que l'estimateur du maximum de vraisemblance, ce qui est tout de même intéressant d'un point de vue théorique.

2.3. Estimation d'une densité non bornée

Un autre sujet qui m'a intéressé ces dernières années était l'étude des vitesses minimax de convergence d'une fonction régulière. Ici, je commence par présenter les résultats principaux de [Sar21b]

qui portent sur l'estimation d'une densité f_0 régulière sur $[0,1]$ à partir de l'observation de n variables i.i.d $X_1, \ldots, X_n$. Des résultats pour l'estimation sur un ensemble de longueur infini tel que $\mathbb{R}$ seront décrits dans le chapitre suivant.

2.3.1. Espaces de Besov. La notion phare pour mesurer la régularité d'une fonction en statistiques est probablement les espaces de Besov. Je rappelle leurs définitions ci dessous. Les fonctions considérées à partir de maintenant et jusqu'à la fin de ce chapitre seront définies sur $[0,1]$.

Soient $\alpha > 0$, $p \in]0, +\infty]$ et un entier arbitraire $r > \alpha$. On définit pour $t, h > 0$, et pour toute fonction f sur $[0,1]$,

$$\Delta_h^r f(t) = \sum_{k=0}^{r} \binom{r}{k} (-1)^{r-k} f(t+kh).$$

On associe à f son module de continuité $\omega_p(f,x)$ défini pour tout $x > 0$ par

$$\omega_p(f,x) = \sup_{0<h\leq x} \left\| (\Delta_h^r f) \mathbb{1}_{[0,1-rh]} \right\|_p .$$

Dans cette écriture, $\|\cdot\|_p$ représente la norme de l'espace $\mathbb{L}^p$ sur $[0,1]$, noté $\mathbb{L}^p([0,1])$.

On définit ensuite l'espace de Besov $\mathcal{B}^\alpha_{p,\infty}$ comme étant l'ensemble composé des fonctions $f \in \mathbb{L}^p([0,1])$ dont la (quasi) norme

$$\|f\|_{\mathcal{B}^\alpha_{p,\infty}} = \|f\|_p + \sup_{x>0} x^{-\alpha} \omega_p(f,x), \tag{2.10}$$

est finie.

Techniquement, la norme ci dessus devrait dépendre du choix du paramètre r. Changer cette valeur conduit cependant à une norme équivalente (voir le Théorème 10.1 de [DL93]). C'est la raison pour laquelle j'omets cette précision dans la suite.

Supposer que f_0 est régulière en estimation statistique revient généralement à mettre une condition sur sa norme $\|f_0\|_{\mathcal{B}^\alpha_{p,\infty}}$ de Besov. On peut formuler cette affirmation autrement en supposant que f_0 appartient, pour un certain $R > 0$, à la boule de Besov $\mathfrak{B}^\alpha_{p,\infty}(R)$ définie par

$$\mathfrak{B}^\alpha_{p,\infty}(R) = \left\{ f \in \mathcal{B}^\alpha_{p,\infty}(R),\ \|f\|_{\mathcal{B}^\alpha_{p,\infty}} \leq R \right\}. \tag{2.11}$$

2.3.2. Interprétation des paramètres. L'un des attraits de la modélisation précédente est qu'elle peut être utilisée pour estimer des fonctions dont la régularité varie, en un certain sens, spatialement.

L'indice α dans $\mathcal{B}^\alpha_{p,\infty}$ peut être vu comme étant la régularité « globale » maximale des fonctions f de cet ensemble. Plus α est grand, plus les fonctions de $\mathcal{B}^\alpha_{p,\infty}$ pourront être régulières. Le deuxième, p, quant à lui, exprime comment cette régularité est mesurée. Un de ses rôles est de contrôler, en quelque sorte, le degré d'homogénéité de cette régularité.

— Dans le cas extrême où $p = \infty$, les variations de f sont mesurées uniformément. L'espace $\mathcal{B}^\alpha_{\infty,\infty}$ correspond alors à l'ensemble des fonctions α-Hölderiennes, du moins lorsque α n'est pas un entier (pour le cas α entier voir [HKPT12] pour plus de détails).

— Lorsque p est plus petit, $p < 1/\alpha$, les fonctions f de $\mathcal{B}^{\alpha}_{p,\infty}$ peuvent ne pas être continues ni même bornées. Une fonction $f \in \mathcal{B}^{\alpha}_{p,\infty}$ peut en fait admettre une singularité d'ordre q où q est d'autant plus grand (jusqu'à 1 pour une densité) que α est petit. Cette phrase signifie qu'il peut exister des $x_0 \in I$ tels que $f(x)$ se comporte comme $|x - x_0|^{-q}$ au voisinage ce point. A noter que dans bien des cas (mais pas tous), la vitesse optimale d'estimation ne fait intervenir que α et non p. Cette dernière est généralement d'autant meilleure que α est grand. On voit donc ici l'intérêt dans mes résultats statistiques à venir d'autoriser p à être très petit : cela permet d'obtenir des vitesses élevées de convergence même pour des fonctions ayant un comportement un peu pathologique.
— On peut en fait montrer que la condition $f \in \mathcal{B}^{\alpha}_{p,\infty}$ est d'autant plus faible que p est petit. Ce résultat exploite néanmoins le fait que l'on travaille sur un compact (il est faux quand la régularité est mesurée sur $\mathbb{R}$).

Naturellement, il n'est pas obligatoire de s'appuyer sur les espaces de Besov pour modéliser des variations dans la régularité de f. Des solutions alternatives existent. On peut par exemple citer le papier récent [DS24] dans lequel la fonction à estimer est Hölder par morceaux. Une telle fonction est globalement α régulière sauf en quelques points. L'avantage de procéder ainsi est que la condition de régularité semble plus tangible. Néanmoins, ces fonctions Hölder par morceaux sont dans les espaces de Besov. Plus précisément, f_0 est dans $\mathcal{B}^{\alpha}_{p,\infty}$ si p est assez petit. Pour un résultat plus général autorisant des singularités aux points de jonctions, voir mon résultat pédagogique écrit dans [Sar24b] (Proposition 2).

2.3.3. Estimation linéaire vs non linéaire. L'interprétation du paramètre p comme mesure du degré d'homogénéité de la régularité peut également se voir dans les résultats minimax.

On rappelle qu'un estimateur linéaire $\hat{f}$ de f_0 est un estimateur de la forme

$$\hat{f}(x) = \sum_{i=1}^{n} T_i(X_i, x)$$

où T_i est une certaine fonction, non aléatoire. Des exemples typiques d'estimateurs linéaires sont les estimateurs par histogramme (si la partition ne dépend pas des données), les estimateurs à noyaux (si la fenêtre est indépendante des données), ou les estimateurs à ondelettes (si les coefficients choisis le sont indépendamment des données).

Il s'avère que la vitesse maximale pour la perte $\mathbb{L}^q$ que peut atteindre un tel estimateur lorsque $f_0 \in \mathcal{B}^{\alpha}_{p,\infty}(R)$ est

$$\begin{cases} n^{-(\alpha-1/p+1/q)/(1+2(\alpha-1/p+1/q))} & \text{si } p < q \\ n^{-\alpha/(2\alpha+1)} & \text{si } p \geq q. \end{cases}$$

Ce résultat a été écrit pour $q, p \geq 1$ (et $\alpha \geq 1/p$ si $p < q$) dans [DJKP96] (en fait c'est très légèrement inexact car leur régularité est mesurée sur $\mathbb{R}$ et les fonctions sont supposées à support compact). Si la vitesse lorsque p est assez grand ($p \geq q$) correspond bien à la vitesse optimale d'estimation, ce n'est plus vrai quand p est plus petit ($p < q$). Tout estimateur linéaire est donc sous optimal dans ce cas.

Pour être optimal, il faut, en un certain sens, que l'estimateur s'adapte aux possibles variations locales de la fonction cible. Si l'on souhaite estimer f_0 à l'aide d'un estimateur par histogramme,

il faut construire de manière adéquate la partition m sur lequel il est basé. Cette partition doit dépendre des données, et être adaptée à la régularité changeante de la densité. Si l'on préfère un estimateur à noyau, il faut choisir une fenêtre adéquate dépendante des données et variant spatialement. Intuitivement, elle doit être plus fine aux endroits où la fonction varie fortement, plus grande ailleurs. Enfin, si l'on préfère un estimateur par ondelettes, il faut de manière similaire faire attention au choix des coefficients.

Ce qui précède illustre l'importance des hypothèses sur les paramètres α et p dans les résultats minimax et dans les résultats des procédures d'estimation. Il peut être très facile d'être minimax sur certaines boules de Besov. Pour d'autres, en revanche, c'est nettement plus difficile.

2.3.4. Motivations. Supposons maintenant que l'on souhaite estimer f_0 en utilisant des estimateurs par projection et en choisissant la norme 2 comme fonction de perte. Un coup d'oeil à la littérature montre que les bornes de risque $\mathbb{L}^2$ de ces estimateurs font parfois intervenir la norme supérieure de f_0, et parfois non, selon que le modèle vérifie une condition reliant les normes $\mathbb{L}^2$ et $\mathbb{L}^\infty$ du modèle (voir l'équation (7.16) de [Mas07]).

Dans le cas très particulier où l'estimateur par projection est un estimateur polynomial par morceaux $\hat{f}_m$ sur une partition m, cette condition revient essentiellement à supposer la régularité de la partition. Cette phrase signifie que m doit être constituée uniquement d'intervalles de même longueur. Ainsi, si $\hat{f}_m$ est polynomial de degré au plus r, les bornes attendues sont essentiellement

$$\mathbb{E}\left[d_2^2(f_0, \hat{f}_m)\right] \lessapprox \begin{cases} d_2^2(f_0, \mathcal{P}_r(m)) + \dfrac{(r+1)^2|m|}{n} & \text{si } m \text{ est régulière} \\ d_2^2(f_0, \mathcal{P}_r(m)) + \|f_0\|_\infty \dfrac{(r+1)^2|m|}{n} & \text{sinon.} \end{cases} \tag{2.12}$$

Supposons maintenant que l'on souhaite estimer une densité f_0 de $\mathfrak{B}^\alpha_{p,\infty}(R)$. Pour cela, on va considérer une collection de tels estimateurs $\left\{\hat{f}_m,\, m \in \mathcal{M}\right\}$ et utiliser une procédure pour essayer de sélectionner le meilleur.

Si l'on utilise uniquement la première formule, on aura au final un estimateur qui pourra approcher des fonctions qui ont une régularité suffisamment homogène, c'est à dire qui ne varient pas trop localement. Plus mathématiquement, on aura la bonne borne de risque sur $\mathfrak{B}^\alpha_{p,\infty}(R)$ lorsque $p \geq 2$. Le cas $p < 2$ semble néanmoins hors d'atteinte. Si l'on utilise la seconde formule, l'estimateur pourra s'adater aux variations locales de la densité. En conséquence, on pourra traiter le cas $p < 2$. Mais cela a un coût : il faut supposer $\|f_0\|_\infty < \infty$. Ce qui m'a motivé à écrire le papier était donc de savoir ce qui se passait lorsque $p < 2$ et $\|f_0\|_\infty = \infty$.

Dans la littérature, il n'y avait pas, à ma connaissance, de résultats minimax explicités sur $\mathfrak{B}^\alpha_{p,\infty}(R)$ lorsque $p < 2$ sans condition sur la norme sup, à l'exception du papier [Bir14]. L'approche de [Bir14] est basée sur la théorie de la T-estimation. Il obtient une inégalité de sélection de modèle générale, valide sans condition sur la norme supérieure. En la spécifiant, il obtient une borne supérieure minimax sur $\mathfrak{B}^\alpha_{p,\infty}(R)$. En utilisant des outils classiques sur les bornes minimax, il prouve également une borne minimax inférieure. Or, ces deux bornes ne coincident pas. Il était donc instructif pour moi de savoir si la théorie de la T-estimation avait un problème ici, ou si, au contraire, la borne inférieure était trop imprécise.

2.3.5. Résultats minimax. Bien que la motivation initiale dans [Sar21b] était de travailler pour $\mathbb{L}^2$, les résultats sont en fait valides pour toute perte $\mathbb{L}^q$. J'ignore ici le cas $q = 1$ qui est un peu différent des autres bien que traité dans l'article. Je le détaillerai davantage dans le chapitre suivant.

Je m'intéresse dans cette section à l'estimation de densités dont la régularité est inhomogène. C'est la raison pour laquelle je suppose que $f_0 \in \mathfrak{B}^\alpha_{p,\infty}(R)$ avec $p < q$. Par ailleurs, comme je ne souhaite pas de conditions sur la norme supérieure de f_0, je suppose $\alpha \leq 1/p$. On sait en effet que les fonctions de $\mathfrak{B}^\alpha_{p,\infty}(R)$ sont uniformément majorées sinon. Les formules donnant les exposants dans les vitesses minimax sont alors bien connus (voir la Figure 2.2 ci dessous).

Soit pour $p \in]0, q[$,

$$\overline{\alpha} = 1/(2p) - 1/q + \sqrt{1/p - 1/q + (1/(2p) - 1/q)^2}. \tag{2.13}$$

Soit pour $\alpha \in]1/p - 1/q, 1/p]$,

$$\gamma = \begin{cases} (\alpha - 1/p + 1/q)/(1 + \alpha - 1/p) & \text{si } \alpha \in]1/p - 1/q, \overline{\alpha}], \\ \alpha/(1 + 2\alpha) & \text{si } \alpha \in]\overline{\alpha}, 1/p]. \end{cases}$$

Le théorème ci dessous donne une borne minimax supérieure et inférieure sur $\mathfrak{B}^\alpha_{p,\infty}(R)$.

Théorème 8 ([Sar21b]). *Soient $q \in]1, +\infty[$, $p \in]0, q[$, $\alpha \in]1/p - 1/q, 1/p]$. Il existe n_0 et R_0 tels que pour tout $n \geq n_0$, $R \geq R_0$,*

$$c_1 n^{-\gamma} \leq \inf_{\hat{f}} \sup_{f_0 \in \mathfrak{B}^\alpha_{p,\infty}(R)} \mathbb{E}^{1/q}\left[d_q^q(f_0, \hat{f})\right] \leq c_2 (\log n)^\tau n^{-\gamma},$$

où τ ne dépend que de p, q, α. De plus, $c_1 > 0$ et c_2 ne dépendent que de R, p, q, α.

Quelques commentaires :

— Pour obtenir la borne supérieure, j'ai proposé dans [Sar21b] une procédure qui consiste à faire de la sélection d'estimateurs parmi une famille $\{\hat{f}_m,\ m \in \mathcal{M}\}$ d'estimateurs par projection. Chaque $\hat{f}_m$ est un estimateur polynomial sur la partition m. L'ensemble $\mathcal{M}$ est composé des partitions dyadiques de Devore et Yu : $\mathcal{M} = \mathcal{M}_{DY}(\ell)$. La procédure est une procédure de type Lepski, mais modifié pour des raisons numériques en accord avec la Section 2.1. On obtient ainsi une complexité numérique tout à fait modéré. J'expliquerai dans un autre modèle, voir la Section 2.4.5, les idées sous-jacentes pour réduire la complexité numérique de telles procédures.

— La borne supérieure peut être atteinte par un estimateur adaptatif : l'estimateur que l'on propose dans le papier atteint bien la vitesse indiquée sans la connaissance à priori de p, α, R (il faut juste imposer que le degré du polynôme soit assez grand par rapport à α).

— La preuve de ce résultat se fait en deux étapes. Dans une première, on montre une inégalité oracle non asymptotique. Il convient ensuite de montrer que l'on peut approcher des fonctions de type Besov par des fonctions polynomiales par morceaux basés sur des partitions m de $\mathcal{M}_{DY}(\ell)$. De tels résultats sont trouvables dans le papier très classique [DY90]. Une généralisation est néanmoins nécessaire car le terme de variance dans l'inégalité oracle peut ne pas dépendre uniquement du cardinal m de la partition mais peut aussi dépendre de la finesse des intervalles qui la constitue (voir la Proposition 5 de [Sar21b] pour le résultat).

— Il est intéressant de noter que la vitesse optimale de convergence d'une densité n'est pas toujours $n^{-\alpha/(1+2\alpha)}$, même sous perte $\mathbb{L}^2$. Il y a une autre formule qui prend le relais lorsque α est trop petit. Ce ralentissement de la vitesse d'estimation s'explique par la présence de singularités à certains endroits. Ce « fléau des singularités » ne se produit pas pour la perte $\mathbb{L}^1$ (voir le chapitre suivant).
— Une des conséquences de ce théorème est que la T-estimation développée pour la norme $\mathbb{L}^2$, telle qu'écrite par [Bir14], ne conduit pas aux bonnes vitesses de convergence lorsque f_0 n'est pas bornée. Sa borne minimax inférieure pour la norme 2 donne cependant le bon exposant. C'est cette question qui m'avait motivé à étudier le sujet.
— Bien que le papier [Sar21b] semble être le premier endroit où ces formules sont explicitées, il est très probable qu'on puisse les atteindre avec d'autres procédures existantes de la littérature (estimateurs à noyaux dont la fenêtre varie spatialement [GL14], méthodes d'ondelettes...). Voir aussi le Chapitre 3 pour ce dernier point.
— L'exposant dans la vitesse d'estimation tend vers 0 lorsque $q > 1$ et $\alpha \to 1/p - 1/q$. On peut aussi montrer (voir la Proposition 2 de [Sar21b] par exemple) qu'il n'est pas possible, du point de vue minimax, d'estimer une densité de $\mathfrak{B}^{\alpha}_{p,\infty}(R)$ lorsque $\alpha = 1/p - 1/q$.

Je présente ci dessous un graphique pour résumer ces vitesses lorsque $q \in]1, 2]$ (gauche) et $q \in]2, +\infty[$ (droite). J'ai également indiqué les exposants (classiques cette fois) correspondant au cas $\alpha > 1/p$.

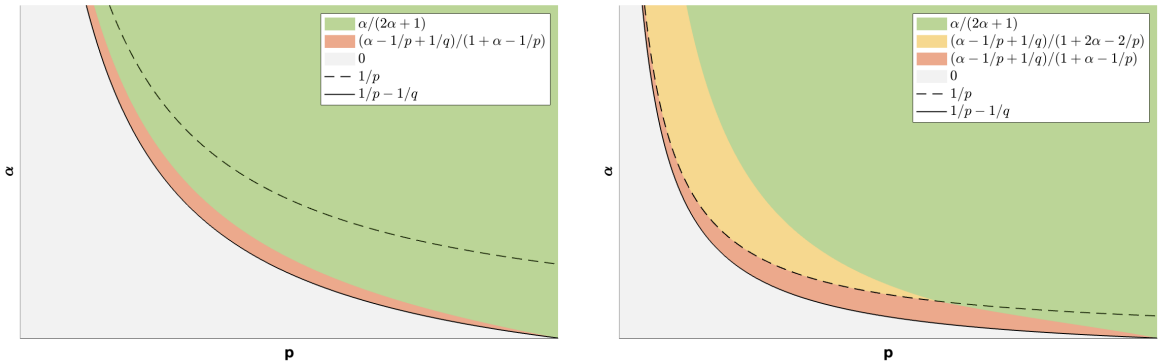

FIGURE 2.2 – Vitesses minimax (aux logs près) sur $\mathfrak{B}^{\alpha}_{p,\infty}(R)$ et domaine d'estimation compact

2.4. Modèle de confidentialité locale

2.4.1. Cadre statistique. Je m'intéresse maintenant à la situation où les données ont été privatisées, c'est à dire qu'elles ont été transformées pour garantir une certaine confidentialité aux individus. Une question naturelle est alors de mesurer l'impact de cette transformation sur les résultats d'estimation statistique.

Pour cela, il convient de modéliser rigoureusement la notion de confidentialité. On suppose ainsi que la variable X d'intérêt n'est pas accessible. A la place, on observe une variable aléatoire Y à valeurs dans un espace mesurable $(\mathcal{Y}, \mathcal{E})$. Il est alors supposé la propriété suivante pour la probabilité

conditionnelle $Q(\cdot \mid X)$ de Y sachant X : il existe $\beta \in [0, +\infty]$ tel que pour tout $x, x' \in [0, 1]$,

$$\sup_{A \in \mathcal{E}} \frac{Q(A \mid X = x')}{Q(A \mid X = x)} \leq e^{\beta}. \tag{2.14}$$

Le paramètre β règle le niveau de confidentialité du mécanisme. Si $\beta = 0$, Y devient indépendante de X et la confidentialité est totale. D'un autre coté, si $\beta = \infty$, plus aucune confidentialité n'est garantie car $Y = X$ convient.

Supposer (2.14) revient à faire ce qu'on appelle de la confidentialité différentielle locale. D'autres modélisations sont possibles, une bonne introduction à ce sujet étant [BD14]. Ce sujet semble s'être beaucoup développé ces dernières années et de nombreuses problématiques statistiques ont été considérées. En quelques mots, on peut citer l'estimation de fonctionnelles, de la moyenne, de la densité, de la densité spectrale, de la fonction de régression, les tests d'ajustements...La liste des papiers est désormais longue, un aperçu étant [DJW18, BDKS20, BRS20, Kro20, RS20, Kro21, BGW21, DBB21, BI21, BGW21, LWLL22, GK22, SJ22].

2.4.2. Motivations. Dans l'article [Sar23], je me suis intéressé au problème de l'estimation de la densité. Le cadre statistique se formule précisément comme suit. Soit X une variable d'intérêt à valeurs dans $[0, 1]$ de densité f_0 par rapport à la mesure de Lebesgue. Soit Y une version privatisée de X de sorte que (2.14) soit vraie. L'objectif est d'estimer f_0 à partir de l'observation de n copies indépendantes $Y_1, \ldots, Y_n$ de Y.

Dans la littérature, l'estimation non adaptative de f_0 basée sur des estimateurs linéaires est étudiée dans [DJW18]. L'estimation adaptative est quant à elle traitée dans [BDKS20] et [Kro21, SJ22]. Le premier papier s'intéresse à l'estimation de f_0 sous norme $\mathbb{L}^q$ et les deux autres à l'estimation ponctuelle.

Les auteurs de [BDKS20] s'appuient sur des méthodes d'ondelettes pour estimer f_0. Ils peuvent ainsi estimer des densités dont la régularité varie spatialement. Ils obtiennent des bornes de risque supérieures qui coincident avec les bornes inférieures, à des facteurs logarithmiques près. Ils quantifient ainsi l'impact du mécanisme de confidentialité sur les vitesses de convergence, qui est naturellement négatif. Noter, pour faire écho à la section précédente, qu'ils imposent $p \geq 1$ et $\alpha > 1/p$. Une telle condition implique en particulier f_0 bornée. Il reste ainsi des questions qui semblent encore ouvertes aujourd'hui (cas f_0 non bornée, à support non compact, problème des facteurs logarithmiques...).

Cependant, ce qui m'intéressait n'était pas de travailler sur l'estimation sous $\mathbb{L}^q$ mais plutôt de se poser la question de savoir s'il était possible d'obtenir des résultats pour h^2. La distance de Hellinger semble en effet assez naturelle pour juger de la qualité d'un estimateur d'une distribution. Elle permet aussi de faire des choses que peuvent difficilement faire les pertes $\mathbb{L}^q$ lorsque $q > 1$ (comme estimer une densité $f_0 \notin \mathbb{L}^q$). Le modèle de confidentialité locale est en quelque sorte un problème inverse et je ne connaissais aucun résultat pour la perte de Hellinger dans un tel contexte. Le but était donc de profiter du modèle de confidentialité locale pour explorer ce sujet.

En estimation non paramétrique sous condition de régularité, que l'on soit en problème inverse ou non, la stratégie est généralement de choisir un estimateur parmi une collection d'estimateurs linéaires. Ces estimateurs sont en effet des estimateurs simples, faciles à manipuler, et dont on peut contrôler le risque $\mathbb{L}^q$. Malheureusement, en général, contrôler leurs risques h^2 est plus compliqué.

Ils n'ont, par exemple, en général, pas de raison d'être positifs. C'est pourquoi j'avais considéré à la place, dans la Section 2.2, une famille d'estimateurs polynomiaux par morceaux basés sur la méthode du maximum de vraisemblance.

Dans l'article [Sar23], j'ai tout de même souhaité proposer une procédure d'estimation basée sur des estimateurs linéaires. Cependant, ce choix a un coût : les seuls estimateurs linéaires dont le risque h^2 a, à ma connaissance, été contrôlé dans la littérature en estimation directe sont les estimateurs par histogramme, et les estimateurs à noyau (dont le noyau est positif). Je renvoie par exemple à [BB09, Mag15]. Que l'on choisisse l'un ou l'autre des estimateurs, on aura une approche qui produira des estimateurs un peu irréguliers, et qui seront donc à éviter si la fonction f_0 est trop régulière (c'est à dire α trop grand). Malgré cela, on pourra déjà voir l'impact de la confidentialité sur les vitesses d'estimation, et les résultats sous h^2 à atteindre dans un problème inverse.

Dans l'article [Sar23], j'avais proposé d'utiliser des estimateurs par histogramme. Je vais donc présenter une procédure pour sélectionner la partition à partir des données.

2.4.3. Mécanisme de confidentialité. Il convient tout d'abord de présenter la technique d'anonymisation des données. Cette dernière est connue par le statisticien. Celle décrite ci dessous s'inscrit dans la lignée des travaux précédents. Plus précisément, soit pour $j \in \{0, \dots, n\}$, la partition régulière $\overline{m}_j$ de $[0,1]$ de taille 2^j :

$$\overline{m}_j = \left\{ \left[k2^{-j}, (k+1)2^{-j}\right[, \, k \in \{0, \dots, 2^j - 2\} \right\} \bigcup \left\{ \left[(2^j-1)2^{-j}, 1\right] \right\}.$$

On définit pour chaque intervalle $I \in \overline{m}_j$, une nouvelle variable aléatoire $W(I)$ de densité

$$q(x) = \frac{1}{2} e^{-|x|}.$$

Soient $\beta \in]0, \infty]$, $\delta = 1/\log(\log n)$, et pour tout $j \in \{0, \dots, n\}$, $I \in \overline{m}_j$,

$$Y(I) = \mathbb{1}_I(X) + \frac{2(1+1/\delta)(1+j)^{1+\delta}}{\beta} W(I). \tag{2.15}$$

Par convention, la fraction ci dessus vaut 0 si $\beta = \infty$.

Une version confidentielle Y de X peut alors être définie par $Y = (Y(I))_{I \in \cup_{j \in \{0,\dots,n\}} \overline{m}_j}$. On peut en effet montrer que la distribution conditionnelle $Q(\cdot \mid X)$ de Y sachant X vérifie (2.14) (Proposition 1 de [Sar23]).

2.4.4. Histogrammes. J'introduis désormais des estimateurs préliminaires linéaires. Ils seront constants par morceaux sur une partition m de $\mathcal{M}_{DY}(\ell)$ où je rappelle que cette dernière collection est définie dans la Section 2.1.1.

Soient $\ell \in \{1, \dots, n\}$, une partition $m \in \mathcal{M}_{DY}(\ell)$ et $I \in m$. L'ensemble I appartient bien à $\cup_{j \in \{0,\dots,n\}} \overline{m}_j$ et on peut donc estimer la probabilité $\mathbb{P}(X \in I)$ sans biais grâce à la formule

$$P_n(I) = \frac{1}{n} \sum_{i=1}^{n} Y_i(I).$$

Cela conduit à l'estimateur

$$\tilde{f}_m = \sum_{I \in m} \frac{P_n(I)}{|I|} \mathbb{1}_I$$

de f_0. Contrairement au problème de l'estimation directe, l'estimateur ci dessus peut ne pas être positif. Dans ce cas, $h^2(f_0, \tilde{f}_m)$ n'a pas de sens. Cette difficulté est facile à corriger ici car f_0 est une densité donc positive. On peut ainsi remplacer dans la suite $\tilde{f}_m$ par sa partie positive $\hat{f}_m = (\tilde{f}_m)_+$.

2.4.5. Heuristique. Le risque de l'estimateur $\hat{f}_m$ dépend du choix de la partition. Je propose ci dessous de définir cette partition en utilisant une procédure de type Lepski mais en expliquant comment on peut la modifier pour réduire sa complexité computationnelle.

Une idée pour sélectionner un estimateur parmi $\{\hat{f}_m,\, m \in \mathcal{M}_{DY}(\ell)\}$ serait de minimiser un critère de la forme

$$\mathrm{crit}(m) = \sup_{m' \in \mathcal{M}_{DY}(\ell)} \left\{ h^2(\hat{f}_m, \hat{f}_{m \vee m'}) - c_1 \mathrm{pen}(m \vee m') \right\} + c_2 \mathrm{pen}(m),$$

où $m \vee m' = \{I \cap I',\, (I, I') \in m \times m'\}$, où $c_1, c_2 > 0$ sont à choisir, et où $\mathrm{pen}(\cdot)$ est une pénalité adéquate.

Un tel critère semble néanmoins difficile à optimiser numériquement. Comme expliqué dans la Section 2.1, une solution serait de le munir de propriétés d'additivité. Notons que l'estimateur $\hat{f}_m$ lui en possède : il s'écrit en effet de la forme

$$\hat{f}_m = \sum_{I \in m} \hat{f}_I \mathbb{1}_I,$$

où $\hat{f}_I = (P_n(I)/|I|)_+$. Supposons qu'il en soit de même pour la pénalité :

$$\mathrm{pen}(m \vee m') = \sum_{\substack{I \in m \\ I' \in m'}} \mathrm{pen}(I \cap I')$$
$$\mathrm{pen}(m) = \sum_{I \in m} \mathrm{pen}(I),$$

où $\mathrm{pen}(\cdot) \geq 0$. On a alors,

$$\begin{aligned}\mathrm{crit}(m) &= \sup_{m' \in \mathcal{M}_{DY}(\ell)} \left\{ \sum_{\substack{I \in m \\ I' \in m'}} h^2(\hat{f}_I \mathbb{1}_{I \cap I'}, \hat{f}_{I \cap I'} \mathbb{1}_{I \cap I'}) - c_1 \mathrm{pen}(I \cap I') \right\} + c_2 \mathrm{pen}(m) \\ &\leq \sum_{I \in m} \sup_{m' \in \mathcal{M}_{DY}(\ell)} \left\{ \sum_{I' \in m'} h^2(\hat{f}_I \mathbb{1}_{I \cap I'}, \hat{f}_{I \cap I'} \mathbb{1}_{I \cap I'}) - c_1 \mathrm{pen}(I \cap I') \right\} + c_2 \mathrm{pen}(m).\end{aligned}$$

Notons $\overline{\mathrm{crit}}(m)$ le terme de droite de cette inégalité. Minimiser ce nouveau critère est possible en utilisant un algorithme de programmation dynamique car il est de la forme (2.2).

Si jamais les pénalités sont suffisamment grosses pour assurer que

$$h^2(f_0 \mathbb{1}_{I \cap I'}, \hat{f}_{I \cap I'} \mathbb{1}_{I \cap I'}) \lessapprox h^2(f_0 \mathbb{1}_{I \cap I'}, \mathcal{F}_{I \cap I'}) + \mathrm{pen}(I \cap I')$$

où $\mathcal{F}_{I\cap I'}$ est l'ensemble constitué des fonctions constantes et à support dans $I\cap I'$, on a en utilisant l'inégalité triangulaire si c_1 est assez grand,

$$\begin{aligned}\overline{\mathrm{crit}}(m) &\lessapprox \sum_{I\in m}\sup_{m'\in\mathcal{M}_{DY}(\ell)}\left\{\sum_{I'\in m'} h^2(f_0\mathbb{1}_{I\cap I'},\hat{f}_I\mathbb{1}_{I\cap I'})\right\}+c_2\mathrm{pen}(m)\\ &\lessapprox h^2(f_0,\hat{f}_m)+c_2\mathrm{pen}(m).\end{aligned}$$

Noter qu'on a également pour tout m et m',

$$\begin{aligned}h^2(f_0,\hat{f}_m) &\lessapprox h^2(f_0,\hat{f}_{m\vee m'})+h^2(\hat{f}_m,\hat{f}_{m\vee m'})\\ &\lessapprox h^2(f_0,\mathcal{F}_{m\vee m'})+\mathrm{pen}(m\vee m')+h^2(\hat{f}_m,\hat{f}_{m\vee m'})\end{aligned}$$

où $\mathcal{F}_{m\vee m'}$ représente l'ensemble des fonctions constantes par morceaux sur $m\vee m'$. Par ailleurs, $m\vee m'\subset m\cup m'$ en raison de la forme particulière des partitions et donc $\mathrm{pen}(m\vee m')\leq \mathrm{pen}(m)+\mathrm{pen}(m')$. On en déduit,

$$\begin{aligned}h^2(f_0,\hat{f}_m) &\lessapprox h^2(f_0,\hat{f}_{m'})+(c_1+1)\left[\mathrm{pen}(m)+\mathrm{pen}(m')\right]+\left\{h^2(\hat{f}_m,\hat{f}_{m\vee m'})-c_1\mathrm{pen}(m\vee m')\right\}\\ &\lessapprox h^2(f_0,\hat{f}_{m'})+(c_1+1)\mathrm{pen}(m')+\mathrm{crit}(m),\end{aligned}$$

si c_2 est bien choisi. Cette dernière inégalité est vraie pour tout m'. Ainsi, minimiser $\mathrm{crit}(m)$ ou $\overline{\mathrm{crit}}(m)$ revient bien, intuitivement, à minimiser $h^2(f_0,\hat{f}_m)+\mathrm{pen}(m)$ (à des facteurs multiplicatifs près).

Le lecteur aura peut être pu remarquer que cette heuristique pour une méthode de type Lepski n'est pas fondamentalement différente de celle que j'avais déjà écrite dans la Section 2.2.6 pour réduire la complexité de la ρ-estimation pour une autre famille de partitions. Les idées sous-jacentes sont donc relativement générales. Elles ne sont par ailleurs pas spécifiques au choix de la perte de Hellinger, ni au modèle de confidentialité.

2.4.6. Inégalité oracle. On peut rendre rigoureuse l'heuristique précédente. Cela conduit à un estimateur $\hat{f}$ entièrement adaptatif et à l'inégalité oracle non-asymptotique suivante :

Théorème 9 ([Sar23]). *Soit $\ell\in\{1,\dots,n\}$. Il existe un estimateur $\hat{f}$ tel que*

$$\mathbb{E}\left[h^2(f_0,\hat{f})\right]\leq C\inf_{m\in\mathcal{M}_{DY}(\ell)}\left\{h^2(f_0,\mathcal{F}_m)+\upsilon_m\right\}. \tag{2.16}$$

Dans ce résultat, C est une constante universelle et $\mathcal{F}_m$ représente l'ensemble des fonctions positives constantes par morceaux sur m. De plus,

$$\upsilon_m=\sum_{\substack{I\in m\\ \rho_I>\log n/n}}\frac{\rho_I^2}{\max\left\{\mathbb{P}\left(X\in I\right),\rho_I\right\}}+\sum_{\substack{I\in m\\ \rho_I\leq\log n/n}}\rho_I+\frac{|m|}{n},$$

où

$$\rho_I=\frac{2(1+1/\delta)(1+\log_2(1/|I|))^{1+\delta}}{\beta}\sqrt{\frac{\log(n/|I|)}{n}}.$$

L'infimum dans (2.16) porte sur toutes les partitions m de $\mathcal{M}_{DY}(\ell)$. Il s'avère que l'on peut le faire porter sur toutes les partitions m de $\mathcal{M}_{DY}$ (sans condition de finesse des intervalles donc) si l'on prend $\ell = n$.

Bien que ce n'était pas l'objectif, on peut considérer le cas de l'estimation directe en prenant $\beta = \infty$. Le terme υ_m devient alors $\upsilon_m = |m|/n$. Dans ce cas là, on retrouve un résultat similaire à celui qui peut être démontré via les méthodes de sélection d'histogramme via T-estimation de [BB09, Bar11]. Contrairement à la mienne, ces deux dernières solutions sont essentiellement théoriques en raison de leurs complexités numériques. Noter qu'il est aussi possible de sélectionner une partition en estimation directe en s'appuyant sur la vraisemblance et cela est faisable numériquement. Cependant, les bornes sous h^2 que je connais sont moins précises que (2.16). Les termes de biais font en effet souvent intervenir la divergence de Kullback-Leibler (voir [Cas99, BBM99, Mas07]).

En estimation indirecte, υ_m est plus compliqué et peut être bien plus grand que $|m|/n$. C'est en quelque sorte le coût de la confidentialité dans le résultat statistique.

Ainsi, ce théorème a un double enjeu : nouveaux résultats théoriques dans le modèle de confidentialité locale (donc évaluation du risque minimax sous h^2 dans le cadre d'un problème inverse), et réduction de complexité numérique dans le modèle direct.

2.4.7. Risque minimax. On peut maintenant utiliser (2.16) pour contrôler le risque de l'estimateur $\hat{f}$ sous des hypothèses de régularité sur f_0. Ce problème n'est plus un problème de statistique, mais un problème de la théorie de l'approximation, le rôle de l'inégalité oracle étant de faire un pont entre ces deux mondes.

Contrairement au cas direct, cependant, le terme υ_m ne dépend pas que de la taille de la partition mais aussi des intervalles qui la composent. Ce terme suggère qu'il est plus difficile d'estimer f_0 aux voisinages où elle est petite. Cela explique pourquoi je vais aussi considérer une condition de minoration uniforme sur f_0.

Soient pour tout $\varepsilon \geq 0$, $M \in]0, +\infty]$, $p > 0$, $R > 0$, $\alpha > 0$,

$$\mathfrak{B}^{\alpha}_{p,\infty}(R, M, \varepsilon) = \left\{ f \in \mathfrak{B}^{\alpha}_{p,\infty}(R),\ \inf_{x\in[0,1]} f(x) \geq \varepsilon,\ \sup_{x\in[0,1]} f(x) \leq M \right\}$$

$$\mathcal{S}\mathfrak{B}^{\alpha}_{p,\infty}(R, M, \varepsilon) = \left\{ f \in \mathcal{D}([0,1]),\ \sqrt{f} \in \mathfrak{B}^{\alpha}_{p,\infty}(R),\ \inf_{x\in[0,1]} f(x) \geq \varepsilon,\ \sup_{x\in[0,1]} f(x) \leq M \right\},$$

où $\mathcal{D}([0,1])$ désigne l'ensemble des densités sur $[0,1]$. La différence entre les deux classes réside dans le fait que l'hypothèse de régularité est mise sur f pour la première et sur $\sqrt{f}$ dans la seconde. Noter que les valeurs $\varepsilon = 0$ et $M = \infty$ sont autorisées. Lorsque $\varepsilon > 0$, la densité est uniformément minorée. De manière analogue, elle est uniformément majorée si $M < \infty$.

On définit pour toute collection $\mathcal{F}$, le risque minimax

$$\mathcal{R}(\mathcal{F}) = \inf_{\tilde{f}, Q} \sup_{f_0 \in \mathcal{F}} \mathbb{E}\left[h^2(f_0, \tilde{f}) \right] \tag{2.17}$$

où l'infimum est pris sur tous les mécanismes Q de niveau β, c'est à dire vérifiant (2.14), et sur tous les estimateurs $\tilde{f}$ basés sur les données confidentielles.

Dans la suite, je suppose $\beta \neq \infty$ pour qu'il y ait de la confidentialité. Les résultats suivants s'appliquent éventuellement pour R et M (finis) assez grands (pour la preuve des bornes inf).

1. Cas $\varepsilon = 0$.
   (a) Le risque minimax $\mathcal{R}(\mathfrak{B}^\alpha_{p,\infty}(R,\infty,0))$ tend vers 0 à la vitesse $n^{-\alpha/(2\alpha+2)}$ aux logs près, pour tout $p > 0$, $\alpha \in](1/p-1)_+, 1[$.
   (b) Le risque minimax $\mathcal{R}(\mathcal{S}\mathfrak{B}^\alpha_{p,\infty}(R,\infty,0))$ tend vers 0 à la vitesse $n^{-\alpha/(2\alpha+1)}$ aux logs près, pour tout $p > 0$, $\alpha \in](1/p-1/2)_+, 1[$.
   (c) Les deux points (a) et (b) restent vrais si l'on rajoute une condition de majoration uniforme sur f_0, c'est à dire si l'on remplace ∞ par un M fini.
2. Cas $\varepsilon > 0$.
   (a) Le risque minimax $\mathcal{R}(\mathfrak{B}^\alpha_{p,\infty}(R,\infty,\varepsilon))$ tend vers 0 à la vitesse $n^{-\gamma}$ aux logs près, pour tout $p > 0$, $\alpha \in](1/p-1)_+, 1[$ où

$$\gamma = \begin{cases} \alpha/(\alpha+1) & \text{si } \alpha > 2/p-1, \\ \alpha p/2 & \text{si } \alpha \leq 2/p-1. \end{cases} \tag{2.18}$$

   (b) Le risque minimax $\mathcal{R}(\mathcal{S}\mathfrak{B}^\alpha_{p,\infty}(R,\infty,\varepsilon))$ tend vers 0 à la vitesse $n^{-\gamma}$ aux logs près, pour tout $p > 0$, $\alpha \in](1/p-1/2)_+, 1[$.
   (c) Les deux points (a) et (b) restent vrais si l'on rajoute une condition de majoration uniforme sur f_0, c'est à dire si l'on remplace ∞ par un M fini.

On peut comparer ces (nouvelles) vitesses au cas direct. On sait par exemple (voir [Bir06]) que la vitesse minimax d'estimation d'une densité f_0 est $n^{-2\alpha/(2\alpha+1)}$ lorsque $\sqrt{f_0} \in \mathfrak{B}^\alpha_{p,\infty}(R)$ avec $p > 0$, $\alpha > (1/p-1/2)_+$. On en déduit que le mécanisme de confidentialité détériore les vitesses optimales de convergence. C'était également vrai pour les autres pertes $\mathbb{L}^q$.

On voit à travers ce résultat qu'une hypothèse de majoration sur f_0 n'a pas de conséquence sur les vitesses d'estimation sous la perte de Hellinger (α peut être strictement plus petit que $1/p$, la condition f_0 ou $\sqrt{f_0}$ dans la boule de Besov n'implique donc pas forcément que f_0 est bornée). En revanche, une condition de minoration a un impact, et ce phénomène n'apparaissait pas en estimation directe.

Cas $\mathbb{L}^2$. Bien que l'approche soit dédiée à la perte de Hellinger, on peut en déduire des (nouveaux) résultats pour la perte $\mathbb{L}^2$. Les deux distances se comportent en effet de manière similaire lorsque les densités sont minorées par ε et majorées par M. Plus précisément,

$$8\varepsilon h^2(f_1,f_2) \leq d_2^2(f_1,f_2) \leq 8Mh^2(f_1,f_2). \tag{2.19}$$

Ainsi, les vitesse minimax d'estimation sur $\mathfrak{B}^\alpha_{p,\infty}(R,M,\varepsilon)$ lorsque $\varepsilon > 0$ et $M < \infty$ sont les mêmes pour h^2 et pour d_2^2. Démontrer des résultats $\mathbb{L}^2$ à partir de Hellinger lorsque $\varepsilon = 0$ est possible en utilisant une astuce adéquate.

Les valeurs des paramètres non étudiés dans la littérature sont $p < 2$ avec $\alpha < 1/p$. Je distingue deux cas ci dessous selon que f_0 soit bornée ou non.

1. Si f_0 bornée et si $\beta \in]0,1]$, $\alpha \in]0,1[$ est tel que $\alpha \in]1/p-1, 1/p]$. Dans ce cas, je peux montrer que le risque minimax pour d_2^2 est $n^{-\gamma}$, aux logs près (où γ est donné par (2.18)). Cette vitesse, ainsi que le phénomène de coude qui se produit est nouveau. J'ai aussi montré une borne inf qui assure que cette vitesse est bien optimale (aux logs près).
2. Si f_0 n'est pas supposée bornée, déduire des résultats pour $\mathbb{L}^2$ à partir de h^2 semble plus délicat. Néanmoins, j'ai montré une borne inférieure pour explorer le sujet. Plus précisément, le risque minimax ne peut tendre vers 0 plus rapidement que $n^{-\nu}$ où

$$\nu = \begin{cases} \alpha/(\alpha+1) & \text{si } \alpha \in]2/p-1, 1/p], \\ (\alpha - 1/p + 1/2)/(\alpha - 1/p + 1) & \text{si } \alpha \in]1/p - 1/2, 2/p - 1], \end{cases}$$

et cela quels que soient $p > 0$, $\beta \in]0,1]$, $\varepsilon \in [0,1[$, $\alpha \in]0,1[$ tel que $\alpha \in]1/p - 1/2, 1/p]$ et R assez grand. Je conjecture que cette vitesse est la bonne, aux facteurs logs éventuels près.

Ces deux points montrent qu'il y a bien une influence de la condition « f_0 bornée » sur les vitesses d'estimation pour la norme 2.

La limitation $\alpha \leq 1$ ci dessus est inhérente à l'approche utilisée. Pour la contourner, d'autres solutions peuvent être envisagées. On peut par exemple modifier la procédure en remplaçant h^2 par d_2^2 et en adaptant la pénalité. Grâce à ce changement de distance, on peut aussi utiliser des estimateurs par projection plus généraux et donc plus réguliers. De manière alternative, on peut aussi utiliser une approche par ondelettes, et s'intéresser au seuillage des coefficients comme dans [BDKS20]. Plus d'informations sur les méthodes d'ondelletes dans le Chapitre 3.

Chapitre 3

Estimation optimale

Ce chapitre s'intéresse au problème de l'estimation non-paramétrique, optimale et adaptative de la densité f_0 d'une variable aléatoire réelle X à partir de données i.i.d $X_1, \ldots, X_n$.

Les trois premières sections résument les articles [Sar25a] et [Sar24b]. J'y explique comment déterminer de manière optimale les coefficients d'ondelettes dans les méthodes associées. J'étudie en particulier les vitesses minimax de convergence lorsque f_0 est régulière ou lorsqu'elle est régulière avec une forme spécifique. La dernière section est dédiée à [Sar24a] et montre que les résultats minimax sont très différents pour h^2. Des perspectives concluent le chapitre.

3.1. Introduction

3.1.1. Estimation optimale. L'expression « estimation optimale » dans ce chapitre signifie que l'estimateur doit atteindre la vitesse minimax de convergence sous les hypothèses considérées et cela sans perte de facteurs logarithmiques. Il s'agit d'un problème facile à résoudre lorsque les estimateurs linéaires conviennent. Malheureusement, comme indiqué dans la Section 2.3.2 cela n'est pas toujours le cas. Ces estimateurs peuvent ne plus être optimaux lorsque p est trop petit même si $f_0 \in \mathfrak{B}^{\alpha}_{p,\infty}(R)$ en estimation sur un domaine compact. Lorsque l'estimation est faite sur un domaine infini, ils peuvent être sous optimaux si p est trop grand (voir [JLL04]). Il est alors nécessaire de s'appuyer sur des méthodes non linéaires.

Si on exclut les cas où l'estimation linéaire est possible, le problème de l'estimation optimale sous des conditions Besov, sous une distance $\mathbb{L}^q$ ou sous Hellinger, et sur un ensemble compact a été résolu au moins dans les situations suivantes.

- La perte est $\mathbb{L}^1$, $p > 0$ et $\alpha > 1/p - 1$. Le seul papier à ma connaissance qui le fait est [Bir06]. Les inconvénients de cette approche sont d'ordre computationnel (implémentation de la procédure très difficile).
- La perte est h^2. Une procédure basée sur des tests robustes, comme la T ou ρ-estimation peut être utilisée (voir [Bir06]).
- La perte est $\mathbb{L}^2$, $p > 0$ et f_0 est bornée. Une procédure des moindres carrés adéquate fonctionne.
- La perte est $\mathbb{L}^q$, $q \geq 1$, $p > 0$ et f_0 est bornée. Une procédure basée sur un seuillage adéquat des coefficients d'ondelettes peut fonctionner [DJ96].

Le problème de l'estimation optimale ne doit pas être confondu avec le problème, plus facile, de l'estimation presque optimale, c'est à dire celui où l'on accepte de perdre des facteurs logarithmiques dans les vitesses de convergence. Les résultats pour un domaine d'estimation compact et toute perte $\mathbb{L}^q$ sont décrits dans la Section 2.3.5. Les résultats les plus généraux dans le cas non compact que je connais sont écrits dans [GL14].

L'objectif dans ce chapitre est de s'intéresser à l'estimation optimale d'une densité sur $\mathbb{R}$, qu'elle soit bornée ou non, pour les pertes $\mathbb{L}^1$ et h^2. S'il s'avérera que l'on peut s'appuyer sur des techniques de tests robustes pour h^2, le cas $\mathbb{L}^1$ est plus délicat, et a nécessité le développement de nouvelles idées sur les ondelletes. Un mot est également dit sur la perte $\mathbb{L}^2$.

3.1.2. Mélange de contraintes. L'approche minimax est toujours un peu pessimiste. Il peut être ainsi plus réaliste d'étudier des hypothèses qui portent à la fois sur la régularité et la forme de la densité.

A titre d'exemple, la plupart des densités usuelles sont non seulement régulières mais ont aussi des formes particulières. Elles sont par exemple souvent unimodales, ou au moins multimodales. Dans les deux cas, les queues des distributions sont monotones. En fait, on verra que ce qui importe vraiment pour les vitesses minimax sur $\mathbb{R}$, c'est une condition de forme sur les queues de la distribution (et non sur toute la distribution). Ce point est intéressant car les queues de la plupart des densités ont des propriétés de formes plus fortes que la simple monotonie. Elles sont par exemple très souvent au moins convexes (et en fait s-monotones pour tout s, voir plus bas).

Estimer une fonction sous le mélange de ces deux conditions n'est pas nouveau, et différentes solutions ont été proposées dans la littérature. On peut par exemple régulariser un estimateur construit préalablement sous l'hypothèse que f_0 vérifie une contrainte de forme (penser à Grenander par exemple). Une autre idée est de faire le cheminement inverse et d'imposer une certaine forme à des estimateurs construits uniquement sur des hypothèses de régularité (estimateurs à noyaux par exemple). Il est aussi possible de minimiser un critère tel que la log vraisemblance, les moindres carrés, ..., éventuellement en le régularisant, sur une classe de fonctions vérifiant une contrainte de forme. Ces méthodes sont décrites dans [BF96, HH02, VDVVDL03, HK05, Bir09, Mey12, LM17, LM19, Che20] pour le modèle de densité. La référence [DL18] offre une review du sujet.

Ces papiers se limitent à des régularités « homogènes » et à une contrainte de forme qui porte sur l'entière distribution. Par ailleurs, les vitesses d'estimation qui apparaissent correspondent aux vitesses usuelles, c'est à dire celles que l'on aurait sous l'une des deux contraintes seules. Ce point est un peu problématique dans le sens où l'on ne voit pas dans ces vitesses le bénéfice de considérer les deux hypothèses en simultanée.

Dans ce chapitre, on souhaite ainsi mieux comprendre l'interaction entre ces deux types d'hypothèses dans les vitesses optimales de convergence. Nous verrons qu'il est bien possible, pour certaines fonctions de perte ($\mathbb{L}^1$ et h^2), et dans certains cas, d'avoir une vitesse d'estimation plus rapide que celles que l'on aurait eu sous les deux contraintes prises séparément. On donnera ainsi une description des vitesses minimax sous ces deux contraintes, et donc en particulier des vitesses de référence qui pourront être utilisées dans le futur pour évaluer l'optimalité de procédures d'estimation précédentes ou à venir. Certains estimateurs connus pour être optimaux pour estimer une fonction régulière peuvent ne pas l'être lorsqu'une contrainte de forme naturelle est rajoutée.

3.2. Ensembles de fonctions

Je résume dans cette section les différentes conditions que je souhaite mettre sur la densité à estimer. La condition la plus simple est « f_0 est régulière sur $\mathbb{R}$ ». Bien que celle ci se modélise avec les espaces de Besov déjà définis, il convient d'ajouter des précisions dans les 3 sections à venir. J'explique dans la Section 3.2.4 les contraintes de forme que je souhaite mélanger à la condition de régularité. La dernière partie 3.2.5 introduit une condition de domination sur les queues de la distribution qui s'avère être importante pour les résultats minimax.

3.2.1. Régularité mesurée via ondelettes. J'ai besoin ici de rappeler la caractérisation des espaces de Besov en termes de coefficients d'ondelettes.

Soit $\tau \geq 1$ et ϕ, $\overline{\phi}$, ψ, $\overline{\psi}$, 4 ondelettes de [CDF92] dont les propriétés importantes sont les suivantes.

— L'ondelette père correspond à la densité de la loi uniforme sur $[0,1]$: $\phi = \mathbb{1}_{[0,1]}$.
— L'ondelette mère ψ est constante par morceaux
— Les versions duales $\overline{\phi}$ et $\overline{\psi}$ de ϕ et ψ sont à support compact et τ-Hölderiennes.
— L'ondelette mère ψ a ses $\tau - 1$ premiers moments nuls : elle vérifie $\int_{\mathbb{R}} x^k \psi(x)\,\mathrm{d}x = 0$ pour tout $k \in \{0, \ldots, \tau - 1\}$.

Dans une telle base, une densité f admet la décomposition suivante : quel que soit $J_0 \in \mathbb{Z}$,

$$f = \sum_{k\in\mathbb{Z}} \alpha_{J_0,k}(f)\overline{\phi}_{J_0,k} + \sum_{j=J_0}^{\infty}\sum_{k\in\mathbb{Z}} \beta_{j,k}(f)\overline{\psi}_{j,k}, \tag{3.1}$$

où pour tout $j \geq J_0$ et $k \in \mathbb{Z}$,

$$\alpha_{J_0,k}(f) = \int f(x)\phi_{J_0,k}(x)\,\mathrm{d}x, \quad \beta_{j,k}(f) = \int f(x)\psi_{j,k}(x)\,\mathrm{d}x,$$

et où pour tout $x \in \mathbb{R}$,

$$\begin{aligned} \phi_{J_0,k}(x) &= 2^{J_0/2}\phi(2^{J_0}x - k), \quad \psi_{j,k}(x) = 2^{j/2}\psi(2^j x - k), \\ \overline{\phi}_{J_0,k}(x) &= 2^{J_0/2}\overline{\phi}(2^{J_0}x - k), \quad \overline{\psi}_{j,k}(x) = 2^{j/2}\overline{\psi}(2^j x - k). \end{aligned}$$

Il est prouvé dans [DJ97] que la (quasi-) norme de l'espace de Besov $\mathcal{B}^{\alpha}_{p,\infty}$ peut être définie via la formule

$$\|f\|_{\mathcal{B}^{\alpha}_{p,\infty}} = \|\alpha_{0,\cdot}(f)\|_p + \sup_{j\geq 0}\left\{2^{j(\alpha+1/2-1/p)}\|\beta_{j,\cdot}(f)\|_p\right\}, \tag{3.2}$$

et cela quels que soient $p \in]0, +\infty]$, $\alpha \in](1/p - 1)_+, \tau[$. On définit alors la boule de Besov $\mathfrak{B}^{\alpha}_{p,\infty}(R)$ par

$$\mathfrak{B}^{\alpha}_{p,\infty}(R) = \left\{f \in \mathbb{L}^{\max\{p,1\}}(\mathbb{R}), \|f\|_{\mathcal{B}^{\alpha}_{p,\infty}} \leq R\right\}.$$

Remarque : la définition ci dessus diffère de celle donnée par (2.11). Dans le chapitre précédent, la régularité des fonctions était évaluée sur $[0,1]$. Elle est évaluée sur $\mathbb{R}$ ici.

3.2.2. Classes de Besov fortes. La formule (3.2) est composée de deux termes. Le deuxième terme mesure bien une certaine notion de régularité comme prévu. Ce n'est pas le cas du premier.

Mettre une condition sur la (quasi) ℓ^p norme des coefficients $(\alpha_{0,k}(f))_k$ contraint en effet les queues de f à être suffisamment petites. Cela se voit en particulier si f se comporte comme $f(x) \approx |x|^{-1/\theta}$ où $\theta \in]0,1[$ lorsque $|x|$ est grand. On a alors $\alpha_{0,k}(f) \approx |k|^{-1/\theta}$ quand $|k|$ est grand. En particulier, f ne peut être dans $\mathfrak{B}^{\alpha}_{p,\infty}(R)$ lorsque $p < \theta$, peu importe sa régularité.

Pour que la notion précédente corresponde davantage à une hypothèse de régularité, une solution est d'ignorer la (quasi-) ℓ^p norme des $\alpha_{0,k}(f)$ dans (3.2). Cela m'a amené à introduire la notion de classe (forte) de Besov :

$$\mathcal{B}^{\alpha}_{p,\infty}(R) = \left\{ f \in \mathbb{L}^1(\mathbb{R}),\ \forall j \geq 0,\ \|\beta_{j,\cdot}(f)\|_p \leq R 2^{-j(\alpha+1/2-1/p)} \right\}. \tag{3.3}$$

J'ai fait ce raffinement dans mes papiers pour mieux comprendre le rôle des hypothèses de régularité dans les vitesses de convergence. Il s'avérera que les vitesses minimax sur $\mathcal{B}^{\alpha}_{p,\infty}(R)$ et sur $\mathfrak{B}^{\alpha}_{p,\infty}(R)$ ne sont pas toujours les mêmes.

L'intérêt de ces classes réside principalement dans le cas où $p < 1$. En effet, on a toujours $\|\alpha_{0,\cdot}(f)\|_p \leq \|\alpha_{0,\cdot}(f)\|_1 \leq \|f\|_1$ si $p \geq 1$. Une densité de $\mathcal{B}^{\alpha}_{p,\infty}(R)$ est alors aussi dans $\mathfrak{B}^{\alpha}_{p,\infty}(1+R)$. Ce cas $p < 1$ est important comme mentionné dans la Section 2.3.5 puisqu'il permet d'atteindre des vitesses de convergence élevées pour des densités admettant des singularités (voir aussi l'exemple dans la seconde partie de la Section 3.4.2 à venir).

3.2.3. Classes de Besov faibles. On peut affaiblir la contrainte dans la définition (3.3) en remplaçant la (quasi)-norme ℓ^p par sa version faible. Cette dernière est définie pour $p \in]0,+\infty[$ et $x = (x_k)_{k\in\mathbb{Z}}$ par

$$\|x\|_{p,\infty} = \sup_{t>0}\ t \left(\sum_{k\in\mathbb{Z}} \mathbb{1}_{|x_k|\geq t} \right)^{1/p}.$$

Lorsque $p = \infty$, on pose simplement $\|x\|_{p,\infty} = \|x\|_\infty$. On définit alors la classe de Besov faible par

$$\mathcal{W}\mathcal{B}^{\alpha}_{p,\infty}(R) = \left\{ f \in \mathbb{L}^1(\mathbb{R}),\ \forall j \geq 0,\ \|\beta_{j,\cdot}(f)\|_{p,\infty} \leq R 2^{-j(\alpha+1/2-1/p)} \right\}.$$

Elle contient la classe de Besov forte $\mathcal{B}^{\alpha}_{p,\infty}(R)$.

3.2.4. Contraintes de forme. Je rappelle qu'une fonction est dite 1-monotone si elle est décroissante sur $]0,+\infty[$. Pour tout $s \geq 2$, une fonction f est dite s-monotone si elle est $s-2$ fois dérivable et que $(-1)^\ell f^{(\ell)}(\cdot)$ est positive, décroissante et convexe sur $]0,+\infty[$, et cela pour tout $\ell \in \{0,\dots,s-2\}$.

On pose pour $b \geq a$,

$$\mathcal{M}^s(a,b) = \{ f \in \mathcal{D}(\mathbb{R}), f(a-\cdot) \text{ and } f(b+\cdot) \text{ sont } s\text{-monotones sur }]0,+\infty[\},$$

où $\mathcal{D}(\mathbb{R})$ représente l'ensemble des densités sur $\mathbb{R}$.

Cette condition ne porte que sur la restriction de f à $\mathbb{R} \setminus [a, b]$. Elle s'avère être vérifiée pour la plupart des distributions usuelles pour s très grand si a et b sont adéquatement choisis. C'est par exemple le cas si f s'écrit

$$f(x) = \frac{P(x)}{Q(x)} e^{R(x)} \tag{3.4}$$

où P, Q, R sont des polynômes (R est éventuellement nul). La densité vérifie alors la propriété suivante : pour tout $s \geq 1$, il existe a et b tels que $f \in \mathcal{M}^s(a, b)$.

3.2.5. Condition de domination. L'estimation d'une densité régulière sur $\mathbb{R}$ et sous perte $\mathbb{L}^1$ n'est pas possible en général sans rajouter une condition supplémentaire qui vise à contrôler la taille de ses queues. Celle dont j'aurai besoin s'écrit naturellement à l'aide des intégrales

$$F_{j,k}(f) = \int_{2^{-j}(k-1/2)}^{2^{-j}(k+1/2)} f(x)\,\mathrm{d}x.$$

De manière plus précise, on définit pour $b \geq a$, $\theta \in [0, 1]$, $M > 0$, l'ensemble $\mathcal{WT}_\theta(a, b, M)$ composé des fonctions positives et intégrables f vérifiant l'inégalité

$$|\{k \in \mathbb{Z}_j(a, b), F_{j,k}(f) \geq t\}| \leq M t^{-\theta} 2^{j(1-\theta)} \tag{3.5}$$

pour tout $j \geq 0$ et tout $t > 0$. Ici,

$$\mathbb{Z}_j(a, b) = \mathbb{Z} \cap \big(]-\infty, -1/2 + 2^j a] \cup [1/2 + 2^j b, +\infty[\big)$$

représente un ensemble d'entiers garantissant que l'intégrale ci dessus n'utilise que les propriétés de f en dehors de $[a, b]$.

On peut aussi remplacer l'ensemble $\mathbb{Z}_j(a, b)$ dans (3.5) par $\mathbb{Z}$. Je note l'ensemble qui en résulte par $\mathcal{WT}_\theta(M)$. Cela semble a priori être plus restrictif. La Proposition 4 de [Sar24b] montre cependant qu'une densité f de $\mathcal{WT}_\theta(a, b, M)$ est aussi dans $\mathcal{WT}_\theta((b - a + 2)^{1-\theta} + M)$. Ainsi, les deux ensembles modélisent bien la même chose. L'intérêt de $\mathcal{WT}_\theta(a, b, M)$ est surtout qu'il n'utilise pas les propriétés des fonctions sur $[a, b]$.

J'ai dit dans [Sar25a] que la condition de domination faible était vérifiée lorsque $f \in \mathcal{WT}_\theta(M)$. Le terme « faible » a été introduit pour la distinguer d'une autre condition, que j'ai appelé condition de domination forte et qui s'écrit $f \in \mathcal{T}_\theta(M)$. Ce dernier ensemble est défini comme regroupant toutes les fonctions positives et intégrables f vérifiant

$$\sup_{j \geq 0} \left\{ 2^{-j(1-\theta)} \|F_{j,\cdot}(f)\|_\theta^\theta \right\} \leq M.$$

Noter que $\mathcal{T}_\theta(M) \subset \mathcal{WT}_\theta(M)$.

Exemples. Ces différentes conditions peuvent paraître un peu abstraites. C'est pourquoi je les ai reliés dans [Sar24a, Sar25a, Sar24b] à des conditions plus tangibles. En particulier :

— Toute densité à support compact dans $[-L, L]$ appartient à $\mathcal{WT}_0(a, b, M)$ quels que soient a et b si $\theta = 0$ et $M = 2L + 2$. Cette borne sur M peut être assez pessimiste par contre : la densité f définie pour $c > 0$ et $x \in \mathbb{R}$ par

$$f(x) = \frac{1}{2}\mathbb{1}_{[-c-1,-c]}(x) + \frac{1}{2}\mathbb{1}_{[c,c+1]}(x)$$

appartient à $\mathcal{WT}_0(a, b, 6)$ (peu importe a et b) tandis que $L = c + 1$ peut être rendu arbitrairement large.

— La condition de domination $f \in \mathcal{WT}_\theta(a, b, M)$ revient essentiellement à dire que f est majorée par une fonction de l'ordre de $|x|^{-1/\theta}$ lorsque x est grand. En effet, on a pour toute densité f et $\theta \in]0, 1[$.
  — Si $f(x) \leq M^{1/\theta}(x - b)^{-1/\theta}$ pour $x > b$ et si $f(x) \leq M^{1/\theta}(a - x)^{-1/\theta}$ pour $x < a$, alors $f \in \mathcal{WT}_\theta(a, b, 2M + 2)$.
  — Si $f \in \mathcal{WT}_\theta(a, b, M) \cap \mathcal{M}^1(a, b)$, alors $f(x) \leq (2M)^{1/\theta}(x - b)^{-1/\theta}$ pour $x > b$ et $f(x) \leq (2M)^{1/\theta}(a - x)^{-1/\theta}$ pour $x < a$.

  Attention, l'hypothèse $f \in \mathcal{M}^1(a, b)$ est vraiment importante pour le point 2, on peut trouver un contre exemple sinon.

— La condition de domination forte apparait naturellement lorsque l'on travaille avec les espaces de Besov. Les deux points suivants sont valides pour tout $p \in]0, 1[$, $R > 0$ et $\alpha \in]1/p - 1, \tau[$.
  — Si $f \in \mathfrak{B}^\alpha_{p,\infty}(R)$, alors $f \in \mathcal{T}_p(c_1 R^p)$ où c_1 ne dépend que de la base d'ondelettes, de α et de p.
  — Si $f \in \mathcal{B}^\alpha_{p,\infty}(R) \cap \mathcal{T}_p(R^p)$, alors $f \in \mathfrak{B}^\alpha_{p,\infty}(c_2 R)$ où c_2 ne dépend que de la base d'ondelettes, de α et de p.

  Pour parler un peu grossièrement, on peut donc dire qu'une boule de Besov lorsque $p < 1$ est une classe de Besov auquel on lui a adjoint une condition de domination forte.

3.3. Estimer avec des ondelettes

3.3.1. Une heuristique. Je présente ici les idées sous-jacentes à une nouvelle méthode d'estimation.

Soient $J_0 \leq J_1$ et une collection $\mathbf{K} = (K_j)_{j \in \{J_0, \ldots, J_1\}}$ de sous ensembles de $\mathbb{Z}$. Soit l'estimateur linéaire défini par

$$\hat{f}_{\mathbf{K}} = \sum_{k \in \mathbb{Z}} \widehat{\alpha}_{J_0,k} \overline{\phi}_{J_0,k} + \sum_{j=J_0}^{J_1} \sum_{k \in K_j} \widehat{\beta}_{j,k} \overline{\psi}_{j,k},$$

où $\widehat{\alpha}_{j,k}$ et $\widehat{\beta}_{j,k}$ représentent les versions empiriques des coefficients d'ondelettes :

$$\widehat{\alpha}_{j,k} = \frac{1}{n} \sum_{i=1}^{n} \phi_{j,k}(X_i)$$

$$\widehat{\beta}_{j,k} = \frac{1}{n} \sum_{i=1}^{n} \psi_{j,k}(X_i).$$

Le risque de cet estimateur dépend du choix des coefficients que l'on garde.

Pour avoir une idée de celui ci, on peut appliquer brutalement l'inégalité triangulaire pour avoir

$$\left\|\hat{f}_{\mathbf{K}} - f_0\right\|_1 \leq c\left[\sum_{j=J_0}^{J_1}\left\{2^{-j/2}\sum_{k\in\mathbb{Z}}|\beta_{j,k}| + \mathcal{B}_j(K_j) + \mathcal{E}_j(K_j)\right\} + R(J_0,J_1)\right],$$

où c ne dépend que de la base d'ondelettes, où

$$\begin{aligned}\mathcal{B}_j(K_j) &= -2^{-j/2}\sum_{k\in K_j}|\beta_{j,k}|\\ \mathcal{E}_j(K_j) &= 2^{-j/2}\sum_{k\in K_j}|\widehat{\beta}_{j,k} - \beta_{j,k}|,\end{aligned} \tag{3.6}$$

et où

$$R(J_0,J_1) = \sum_{j=J_1+1}^{\infty} 2^{-j/2}\sum_{k\in\mathbb{Z}}|\beta_{j,k}| + 2^{-J_0/2}\sum_{k\in\mathbb{Z}}|\widehat{\alpha}_{J_0,k} - \alpha_{J_0,k}|.$$

La plupart des termes dans cette inégalité sont inconnus. Néanmoins, on peut estimer $\mathcal{B}_j(K_j)$ par

$$\widehat{\mathcal{B}}_j(K_j) = -2^{-j/2}\sum_{k\in K_j}|\widehat{\beta}_{j,k}|.$$

Le terme $\mathcal{E}_j(K_j)$ semble plus délicat à estimer. Il s'avère néanmoins qu'il est possible de le contrôler avec grande probabilité. Notons $\widehat{\mathcal{E}}_j(K_j)$ un tel majorant. On obtient alors (utiliser l'inégalité triangulaire pour remplacer $\mathcal{B}_j(K_j)$ par $\widehat{\mathcal{B}}_j(K_j)$),

$$\left\|\hat{f}_{\mathbf{K}} - f_0\right\|_1 \leq c\left[\sum_{j=J_0}^{J_1}\left\{2^{-j/2}\sum_{k\in\mathbb{Z}}|\beta_{j,k}| + \widehat{\mathcal{B}}_j(K_j) + 2\widehat{\mathcal{E}}_j(K_j)\right\} + R(J_0,J_1)\right]. \tag{3.7}$$

Ce résultat suggère, pour minimiser le risque de l'estimateur, de choisir l'ensemble K_j pour lequel la quantité

$$\widehat{\mathcal{B}}_j(K_j) + 2\widehat{\mathcal{E}}_j(K_j) \tag{3.8}$$

est minimale. La méthode que j'utilise dans la suite, et qui est écrite de manière formelle dans la Section 3.3.4, est basée sur ce principe.

A noter que le risque de l'estimateur dépend aussi de J_0 et J_1. Plus J_1 est grand, plus le terme $R(J_0,J_1)$ est petit. Cela suggère d'appliquer l'heuristique pour choisir les K_j à un nombre maximal de niveaux j. Quant au choix de J_0, les choses sont un peu plus délicates et dépendent des hypothèses considérées. Ce point est détaillé plus bas.

3.3.2. Comparaison avec la littérature. L'heuristique précédente revient en fait à faire essentiellement un compromis entre la norme $\mathbb{L}^1$ des coefficients que l'on estime, et un majorant de l'erreur d'estimation de l'ensemble de ces coefficients.

Dans le cas où l'on pense que l'erreur globale d'estimation est la somme des erreurs individuelles, on peut choisir $\widehat{\mathcal{E}}_j(K_j)$ de la forme

$$\widehat{\mathcal{E}}_j(K_j) = 2^{-j/2} \sum_{k \in K_j} \widehat{e}_j(k), \tag{3.9}$$

où $\widehat{e}_j(k)$ doit majorer $|\widehat{\beta}_{j,k} - \beta_{j,k}|$. La procédure revient alors à sélectionner les coefficients dépassant un certain seuil :

$$\widehat{K}_j = \left\{ k \in \mathbb{Z},\ |\widehat{\beta}_{j,k}| \ \geq 2\widehat{e}_j(k) \right\}$$

minimise (3.8). On peut jouer avec ces $\widehat{e}_j(k)$ pour retrouver des procédures existantes de la littérature.

— Si l'on choisit $\widehat{e}_j(k)$ de l'ordre de $\sqrt{\|f\|_\infty j/n}$, on retombe sur la procédure de [DJKP96].
— Si l'on choisit $\widehat{e}_j(k)$ de l'ordre de $\sqrt{\|f\|_\infty (j-\overline{j})_+/n}$ pour un certain $\overline{j}$, on retombe sur la procédure de [DJ96].
— Si l'on choisit $\widehat{e}_j(k)$ de l'ordre de

$$\widehat{e}_j(k) = c_1 2^{j/2} \left[\sqrt{\frac{\log n}{n} \widehat{\sigma}^2_{j,k}} + \frac{\log n}{n} \right], \tag{3.10}$$

où $\widehat{\sigma}^2_{j,k}$ est un estimateur adéquat, on retombe sur [JLL04] et [RBRTM11].

On voit donc que c'est la manière dont on contrôle l'erreur d'estimation qui conduit à la forme de la procédure.

Des vitesses de convergence sous l'hypothèse de régularité $f_0 \in \mathfrak{B}^\alpha_{p,\infty}(R)$ ont été établies dans [DJKP96, DJ96] pour les deux premiers seuils. Elles sont optimales à des logs près pour le premier papier, et sans le log pour le second. Malheureusement, elles sont montrées sous des hypothèses supplémentaires restrictives : f_0 est bornée (de norme sup connue), et f_0 à support compact. On peut trouver dans les papiers susmentionnés utilisant le seuil (3.10) des résultats sans condition de support. Des conditions sur α, p restent néanmoins de mises et l'hypothèse f_0 bornée est nécessaire pour les résultats. Mais le problème principal est que le seuil fait intervenir le terme $\log n/n$. Il semble donc très difficile d'éviter des facteurs logs dans les vitesses de convergence, même lorsque ceux ci ne devraient pas y être.

3.3.3. Contrôle précis de l'erreur. Le point clef de l'heuristique (3.8) est qu'elle peut être utilisée avec tout majorant $\widehat{\mathcal{E}}_j(K_j)$ de l'erreur $\mathcal{E}_j(K_j)$, pas uniquement ceux additifs de la forme (3.9). On a ainsi plus de flexibilité pour contrôler finement l'erreur d'estimation. Je propose d'expliciter une borne ici. Elle est un peu lourde et requiert d'introduire certaines notations.

On définit pour tout $j, k \in \mathbb{Z}$,

$$\widehat{\sigma}^2_{j,k} = \frac{1}{n} \sum_{i=1}^n \psi^2(2^j X_i - k).$$

On pose

$$\widehat{\mathbb{Z}}_j = \left\{k \in \mathbb{Z},\ \widehat{\sigma}^2_{j,k} > 0\right\}. \tag{3.11}$$

On considère ensuite un nombre réel $\varsigma > 0$ qui sera précisé plus tard. On définit le plus grand entier $\overline{r}_{n,j} \geq 0$ vérifiant $2^{-\overline{r}_{n,j}} \geq \min\{1, \varsigma \log((|j|+1)n)/n\}$ et on pose pour tout $r \geq 0$,

$$\begin{aligned}
\widehat{\mathbb{Z}}_{j,r,-} &= \left\{k \in \mathbb{Z},\ \widehat{\sigma}^2_{j,k} > \|\psi\|^2_\infty 2^{-r}\right\} \\
\widehat{\mathbb{Z}}_{j,r} &= \left\{k \in \mathbb{Z},\ \|\psi\|^2_\infty 2^{-r} < \widehat{\sigma}^2_{j,k} \leq \|\psi\|^2_\infty 2^{-r+1}\right\} \\
\widehat{\mathbb{Z}}'_{j,r} &= \left\{k \in \mathbb{Z},\ \|\psi\|^2_\infty 2^{-r-2} < \widehat{\sigma}^2_{j,k} \leq \|\psi\|^2_\infty 2^{-r+3}\right\} \\
\widehat{\lambda}_{j,r} &= \begin{cases} \min\left\{|\widehat{\mathbb{Z}}'_{j,r}|, 2^r\right\} & \text{si } r \leq \overline{r}_{n,j} \\ \min\left\{|\widehat{\mathbb{Z}}_j| + \log((1+|j|)n), 2^r\right\} & \text{si } r > \overline{r}_{n,j}. \end{cases}
\end{aligned} \tag{3.12}$$

On définit les fonctions $\widehat{\mathcal{E}}_{j,r,+}(\cdot)$ et $\widehat{\mathcal{E}}_{j,r}(\cdot)$ pour $x \geq 0$ par

$$\begin{aligned}
\widehat{\mathcal{E}}_{j,r,-}(x) &= \sqrt{\frac{x}{n}} + \sqrt{\frac{\log((|j|+1)(1+r)) + \log n}{n}} \\
\widehat{\mathcal{E}}_{j,r}(x) &= x\sqrt{\frac{2^{-r}\log_+\left(|\widehat{\lambda}_{j,r}|/x\right)}{n}} + x\frac{\log_+\left(|\widehat{\lambda}_{j,r}|/x\right)}{n} \\
&\quad + \sqrt{x\frac{2^{-r}\log((|j|+1)(1+r)n)}{n}} + \frac{\log((|j|+1)(1+r)n)}{n}.
\end{aligned}$$

Ci dessus, la convention $0 \times \log_+(\cdot/0) = 0$ est utilisée si nécessaire.

Alors, pour tout $K_j \subset \widehat{\mathbb{Z}}_j$, on peut utiliser

$$\widehat{\mathcal{E}}_j(K_j) = \kappa \inf_{r_j \geq 0} \left\{\widehat{\mathcal{E}}_{j,r_j,-}(|K_j \cap \widehat{\mathbb{Z}}_{j,r_j,-}|) + \sum_{r=r_j+1}^{\infty} \widehat{\mathcal{E}}_{j,r}(|K_j \cap \widehat{\mathbb{Z}}_{j,r}|)\right\} \tag{3.13}$$

dans la procédure sous réserves que κ soit suffisamment grand. On a en effet :

Proposition 10 ([Sar25b, Sar24b]). *Il existe κ_0, ς_0 ne dépendant que des ondelettes, et un événement de probabilité $1 - n^{-4}$ sur lequel on a : pour tout $j \in \mathbb{Z}$, tout $K_j \subset \widehat{\mathbb{Z}}_j$, et tout $\kappa \geq \kappa_0$, $\varsigma \geq \varsigma_0$*

$$\mathcal{E}_j(K_j) \leq \widehat{\mathcal{E}}_j(K_j). \tag{3.14}$$

Quelques remarques :

— L'exposant 4 dans la probabilité de l'événement est arbitraire. On aurait pu le remplacer par n'importe quel autre nombre. Le point important est que l'événement soit vrai avec grande probabilité uniformément pour tout K_j.

— La preuve de ce théorème étant importante, je décris les idées sur lesquelles elle est basée dans la Section 3.6.1.

— Cette borne a été initialement prouvée dans [Sar25b]. La version présentée ici est plutôt celle de [Sar24b] qui diffère légèrement de l'originale car celle ci n'était écrite que pour des j positifs.
— La formule donnant $\widehat{\mathcal{E}}_j(K_j)$ n'étant pas additive, la procédure ne revient pas à seuiller individuellement les coefficients comme dans les procédures de la section précédente.

3.3.4. Procédure. Pour résumer, la procédure est la suivante. Soient $\widehat{J}_0$ et $\widehat{J}_1$ deux entiers. J'ai mis un chapeau sur ces entiers car ils peuvent être aléatoires. Pour tout $j \in \{\widehat{J}_0, \dots, \widehat{J}_1\}$ et $K_j \subset \widehat{\mathbb{Z}}_j$, on pose

$$\mathrm{crit}_j(K_j) = -2^{-j/2} \sum_{k \in K_j} |\widehat{\beta}_{j,k}| + 2\widehat{\mathcal{E}}_j(K_j), \tag{3.15}$$

où $\widehat{\mathcal{E}}_j(K_j)$ est donné par (3.13).

On définit alors $\widehat{K}_j$ comme n'importe quel sous ensemble de $\widehat{\mathbb{Z}}_j$ vérifiant

$$\mathrm{crit}_j(\widehat{K}_j) = \min_{K_j \subset \widehat{\mathbb{Z}}_j} \mathrm{crit}_j(K_j). \tag{3.16}$$

L'estimateur est

$$\hat{f} = \sum_{k \in \mathbb{Z}} \widehat{\alpha}_{\widehat{J}_0,k} \overline{\phi}_{\widehat{J}_0,k} + \sum_{j=\widehat{J}_0}^{\widehat{J}_1} \sum_{k \in \widehat{K}_j} \widehat{\beta}_{j,k} \overline{\psi}_{j,k}. \tag{3.17}$$

Avant de regarder les propriétés théoriques de cet estimateur, mentionnons que le problème d'optimisation ci dessus peut être résolu en un temps linéaire en le nombre d'observations, à des logs près. C'est un point intéressant car certaines idées conduisant à de l'estimation optimale (T-estimation dans [Bir06] ou noyaux dans [Lep15]) peuvent être difficiles à implémenter en pratique.

3.3.5. Résolutions initiales et finales. Il faut définir $\widehat{J}_0$ et $\widehat{J}_1$ pour que la procédure fonctionne.

Soit $L_{\mathrm{wav}} \in \mathbb{N}^\star$ un entier tel que l'intervalle $[-L_{\mathrm{wav}}, L_{\mathrm{wav}}]$ contienne les supports des 4 ondelettes $\phi, \overline{\phi}, \psi, \overline{\psi}$. On trie l'échantillon $X_{(1)} < \cdots < X_{(n)}$ par ordre croissant. Je propose de définir $\widehat{J}_1 \geq 0$ par la formule

$$\widehat{J}_1 = \min \left\{ j \geq 0, \min_{1 \leq i \leq n-1} \left(X_{(i+1)} - X_{(i)} \right) \geq L_{\mathrm{wav}} 2^{1-j} \right\}. \tag{3.18}$$

Le choix de $\widehat{J}_0$ est plus délicat. Le plus évident est $\widehat{J}_0 = 0$. On mime alors la plupart des procédures théoriques, comme certaines écrites dans les papiers de la Section 3.3.2. Ce choix est tout indiqué pour estimer une densité sous une contrainte de régularité. Je le déconseille cependant si la fonction possède d'autres types de propriétés. On peut en effet montrer qu'un estimateur de la forme

$$\tilde{f} = \sum_{k \in \widehat{K}_{0,\alpha}} \widehat{\alpha}_{0,k} \overline{\phi}_{0,k} + \sum_{j=0}^{\infty} \sum_{k \in \widehat{K}_{j,\beta}} \widehat{\beta}_{j,k} \overline{\psi}_{j,k}$$

ne peut estimer f_0 plus rapidement que $n^{-(1-\theta)}$ si $f_0(x) \approx |x|^{-1/\theta}$ quand $|x|$ est grand (pour la perte $\mathbb{L}^1$). Ici les ensembles en indices peuvent être aléatoires et donc être donnés par n'importe quelle procédure statistique. Ce résultat apparait dans la Proposition 1 de [Sar24b].

Il s'avère que les vitesses minimax d'estimation sous contraintes de régularité sont toujours au moins aussi rapides que $n^{-(1-\theta)}$. Cependant, ce n'est plus nécessairement le cas pour d'autres contraintes (penser à la situation où θ est proche de 1). Plus d'informations dans la Section 3.4.2 à venir. Ceci explique pourquoi je considère aussi la valeur

$$\widehat{J}_0 = \max\left\{j \leq 0,\ |\widehat{\mathbb{Z}}_j(\alpha)| \leq \varrho \log((1+|j|)n)\right\}, \tag{3.19}$$

où $\varrho > 0$ est à préciser et où

$$\widehat{\mathbb{Z}}_j(\alpha) = \{k \in \mathbb{Z},\ \widehat{\alpha}_{j,k} \neq 0\}.$$

3.4. Résultats pour la perte $\mathbb{L}^1$

On peut désormais écrire les bornes de risque que j'ai prouvées dans [Sar25a, Sar24b] pour l'estimateur (3.17).

3.4.1. Estimation sous condition de régularité pure. Je considère tout d'abord le cas où f_0 est régulière avec des queues dominées. Dans cette section, $\widehat{J}_0 = 0$.

Soient $R > 0$, $M \geq 1$, $p \in]0, +\infty]$, $\alpha \in](1/p-1)_+, \tau[$, $\theta \in [0, 1[$, et la classe

$$\mathcal{F}^{\alpha,0}_{p,\theta}(R, M) = \begin{cases} \mathcal{WB}^{\alpha}_{p,\infty}(R) \cap \mathcal{WT}_{\theta}(M) & \text{si } p \neq 1 \\ \mathcal{B}^{\alpha}_{p,\infty}(R) \cap \mathcal{WT}_{\theta}(M) & \text{si } p = 1. \end{cases}$$

On pose

$$\begin{aligned}
\theta_0 &= \alpha/(2\alpha + 1 - 1/p) \\
\gamma &= \begin{cases} \alpha/(2\alpha+1) & \text{si } \theta \leq \theta_0 \\ \alpha(1-\theta)/(\alpha+1-\theta/p) & \text{si } \theta > \theta_0 \end{cases} \\
\nu_n &= \begin{cases} \log n & \text{si } \theta = \theta_0 \text{ et } p \neq 1 \\ (\log n)^{2\gamma} & \text{si } \theta = \theta_0 \text{ et } p = 1 \\ 1 & \text{sinon} \end{cases} \\
\beta_1 &= \begin{cases} 1/(2\alpha+1) & \text{si } \theta \leq \theta_0 \\ (1-\theta)/(1+\alpha-\theta/p) & \text{si } \theta > \theta_0 \end{cases} \\
\beta_2 &= \begin{cases} (\alpha+1-1/p)/((1-\theta)(2\alpha+1)) & \text{si } \theta \leq \theta_0 \\ (\alpha+1-1/p)/(\alpha+1-\theta/p) & \text{si } \theta > \theta_0. \end{cases}
\end{aligned}$$

Le théorème ci dessous donne un majorant du risque maximal de l'estimateur lorsque $f_0 \in \mathcal{F}^{\alpha,0}_{p,\theta}(R, M)$.

Théorème 11 ([Sar25a]). *Soient $p \in]0,\infty]$, $\alpha \in](1/p-1)_+, \tau[$, $\theta \in [0,1[$, $R>0$, $M \geq 1$. Il existe ς_0, κ_0, et n_0 tels que pour tout $n \geq n_0$, $\kappa \geq \kappa_0$, $\varsigma \geq \varsigma_0$, l'estimateur $\hat{f}$ définie par (3.17) avec $\widehat{J}_0 = 0$ vérifie*

$$\sup_{f \in \mathcal{F}^{\alpha,0}_{p,\theta}(R,M)} \mathbb{E}\left[d_1(f_0, \hat{f})\right] \leq c\left[R^{\beta_1} M^{\beta_2} \nu_n n^{-\gamma} + M n^{-(1-\theta)}\right]. \tag{3.20}$$

De plus, ς_0, κ_0 ne dépendent que de la base d'ondelettes. Le facteur c ne dépend que de $p, \alpha, \theta, \kappa, \varsigma$ et des ondelettes, et n_0 ne dépend que de $p, \alpha, \theta, \kappa, \varsigma, R, M$ et des ondelettes.

Il y aurait beaucoup de choses à dire sur ce résultat.

1. La procédure est bien entièrement adaptative.
2. Le point clef est qu'aucun facteur logarithmique n'apparait dans la borne de risque sauf dans un cas de frontière $\theta = \theta_0$. C'est ce qui rend ce résultat délicat à prouver et c'est pour moi la nouveauté principale. Comme indiqué précédemment, cette précision est permise grâce au contrôle très fin du processus empirique sous-jacent, c'est à dire la Proposition 10, et le fait que la procédure puisse exploiter ce contrôle très fin. Par exemple, je ne suis pas capable de ne pas perdre à certains endroits de facteurs logs, si l'on remplaçait $\widehat{\lambda}_{j,r}$ dans (3.12) par la version légèrement plus grossière

$$\widehat{\lambda}_{j,r} = \begin{cases} \min\left\{|\widehat{\mathbb{Z}}'_{j,r}|, 2^r\right\} & \text{si } r \leq \overline{r}_{n,j} \\ \min\left\{n, 2^r\right\} & \text{si } r > \overline{r}_{n,j}. \end{cases}$$

   Autrement dit, si l'on remplaçait le nombre aléatoire $|\widehat{\mathbb{Z}}_j|$ d'indices k pour lequel $\widehat{\sigma}^2_{j,k} \neq 0$ par un terme de l'ordre de n.
3. Les calculs de ce théorème suggèrent que, si l'on faisait du seuillage hard avec un seuil adéquat de la forme (3.10), on devrait retrouver ce résultat, mais à des facteurs logs près. Cela ne semble pas apparaitre dans la littérature par contre. Ainsi, le fait de développer une nouvelle procédure est principalement justifiée par la suppression des logs.
4. On peut se comparer très succinctement aux résultats minimax existants de la littérature.
   — Cas 1 : f_0 à support compact, qui correspond à $\theta = 0$. Le cas $p \geq 1$ n'est pas très intéressant car n'importe quel estimateur linéaire adéquat devrait atteindre la vitesse $n^{-\alpha/(2\alpha+1)}$. Le cas $p < 1$ est nettement plus délicat et le seul papier où j'ai trouvé un résultat sans hypothèse supplémentaire et sans perte de vitesse est celui de [Bir06] avec l'approche de la T-estimation. Il obtient la même vitesse que la mienne. L'intérêt de la procédure développée ici est qu'elle est computationnellement faisable. Mais au delà de ces aspects numériques, il peut être utile de mentionner que sa vitesse est obtenue à partir d'une inégalité de sélection de modèles générale, et je ne sais pas en déduire les bons résultats dans le cas non compact.

   Une version de celle ci écrite pour des espaces vectoriels serait la suivante : soit $(V_m)_{m \in \mathcal{M}}$ une collection au plus dénombrable de sous espaces vectoriels V_m de $\mathbb{L}^1(\mathbb{R})$. Soit π une mesure de probabilité sur $\mathcal{M}$. Alors, il existe un estimateur $\hat{f}_T$ tel que

$$\mathbb{E}\left[d_1(f_0, \hat{f}_T)\right] \leq c \inf_{m \in \mathcal{M}} \left\{ d_1\big(f_0, V_m\big) + \sqrt{\frac{\dim V_m + \log(1/\pi(m))}{n}} \right\}, \tag{3.21}$$

où c est une constante (voir son Théorème 8). Le terme de variance est du bon ordre de grandeur pour traiter le cas où le domaine d'estimation est compact mais il semble ne pas l'être lorsqu'il est infini. Cela m'empêche de retrouver les exposants que j'ai ci dessus. Cela suggère aussi très fortement que les résultats de la T-estimation pour $\mathbb{L}^1$ peuvent manquer de précision.

Pour information, le Théorème 11 découle aussi d'une inégalité oracle non asymptotique. Elle est plus compliquée que celle ci dessus, et je préfère ne pas l'écrire car elle est lourde. Je renvoie le lecteur à la (longue) preuve de ce théorème pour plus de détails.

— Cas 2 : f_0 à support infini. A ma connaissance seul le cas $p \geq 1$ a été étudié dans la littérature et cela, dans deux papiers : [CL20] et [GL14]. Dans le premier, les ondelettes sont aussi utilisées et le risque étudié sous la condition de domination forte. Les auteurs n'obtiennent en revanche jamais les bonnes vitesses (ils perdent un log dans le cas compact, exposants incorrects sinon). Le second papier est basé sur des noyaux et une règle de sélection locale pour déterminer la fenêtre. La différence majeure dans les résultats entre leur approche et la mienne réside dans le fait qu'ils perdent systématiquement des facteurs logarithmiques.

5. Tous les cas possibles pour α, p, θ sont considérés. Un oeil aiguisé pourrait remarquer la condition sur le α mais cette dernière est en réalité minimale.
   — Le théorème reste techniquement valable si $\alpha \geq \tau$ mais l'absence de caractérisation des espaces de Besov par ondelettes rend ce cas peu intéressant. Je rappelle aussi que τ peut être arbitrairement grand.
   — Le théorème n'est plus valable si $\alpha \leq 1/p - 1$, ce qui n'est possible que si $p < 1$. J'ai démontré une borne inférieure dans [Sar25a] qui montre que le risque minimax ne tend pas vers 0 dans ce cas (même si $\theta = 0$ et que la fonction est supposée à support compact dans $[0, 1]$). Ce résultat fait écho à ce qui se passe dans le cas $\mathbb{L}^q$ (voir la Section 2.3.5) : le risque minimax ne tend pas non plus vers 0 lorsque $\alpha = 1/p - 1/q$ et $q > 1$. Cependant, la construction des familles dans les preuves sous-jacentes des cas $q = 1$ et $q > 1$ est très différente. Notons aussi que l'exposant sur le n tend continûment vers 0 lorsque $\alpha \to 1/p - 1/q$ et $q > 1$ mais pas si $q = 1$. Le résultat est donc sans surprise lorsque $q > 1$ mais était plus difficilement prévisible lorsque $q = 1$.

   Si le lecteur jette un coup d'œil à l'article, il pourra noter que le résultat a été initialement annoncé sous la condition supplémentaire $\theta \in [0, p]$ dans [Sar25a]. Cette dernière s'avère néanmoins superflue si l'on écrit la borne de risque comme ci dessus, j'explique ce point dans [Sar24b]. De même, l'estimateur n'est pas exactement le même que celui de [Sar25a] car je n'ai pas appliqué de procédure ici pour sélectionner les coefficients $\widehat{\alpha}_{0,k}$. Le théorème reste néanmoins valide, la manière de sélectionner ces coefficients étant plutôt secondaire ici.

6. Sur la condition de domination.
   — On sait qu'il n'est pas possible d'estimer une densité $f_0 \in \mathfrak{B}^{\alpha}_{p,\infty}(R)$ sans aucune condition supplémentaire lorsque $p \geq 1$. Il existe en effet une borne minimax inférieure qui montre que cela n'est pas possible, du moins si R est assez grand ([GL14, IK81, JLL04]). C'est la raison pour laquelle, il a été introduit dans [GL14] une condition de domination sous laquelle la vitesse du cas compact peut être retrouvée dans le cas infini, et à vitesse plus lente $n^{-\alpha(1-\theta)/(\alpha+1-\theta/p)}$ aux logs près. La condition de domination ici est plus faible que la leur, et le point clef est l'absence de ces facteurs logs...

— Contrairement à [GL14], je m'intéresse aussi au cas $p < 1$, et on n'observe alors pas les mêmes phénomènes. En effet, la condition de domination que je considère est automatiquement vérifiée avec $\theta = p$ lorsque $f_0 \in \mathfrak{B}^{\alpha}_{p,\infty}(R)$ avec $p < 1$. On peut donc estimer ces fonctions sur $\mathbb{R}$, sans hypothèse supplémentaire, ce qui n'était pas possible précédemment. Cela semble nouveau, et la vitesse $\nu_n n^{-\gamma}$ également.

7. On peut remarquer que j'ai explicité la dépendance en R et M dans (3.20). On ne le fait pas toujours car cela rend plus fastidieux les calculs sous-jacents, mais cela peut être important, notamment lorsqu'ils n'apparaissent pas dans la littérature. Il peut parfois avoir des choses un peu plus étonnantes, certaines inégalités « apparaissant à différents endroits de la littérature » peuvent ne pas conduire aux bons résultats même dans des cas à priori simples, comme je le mentionne dans la Section 3.7 à venir pour la perte $\mathbb{L}^2$.

Proposition 12 ([Sar25a]). *Soient $p \in]0, \infty]$, $\alpha \in](1/p - 1)_+, \tau[$, $\theta \in]0, 1[$. Il existe R_0, M_0 tels que : pour tout $R \geq R_0$, $M \geq M_0$ et tout n assez grand,*

$$\inf_{\tilde{f}} \sup_{f_0 \in \mathcal{F}} \mathbb{E}\left[d_1(f_0, \tilde{f})\right] \geq c\left[R^{\beta_1} M^{\beta_2} \nu_n n^{-\gamma} + M n^{-(1-\theta)}\right],$$

où $\mathcal{F}$ est un sous ensemble de $\mathcal{B}^{\alpha}_{p,\infty}(R) \cap \mathcal{WT}_{\theta}(M)$, où $c > 0$ ne dépend que de $\alpha, p, \theta, \psi, \overline{\psi}, \overline{\phi}$, et où R_0, M_0 ne dépendent que de $\alpha, p, \theta, \psi, \overline{\psi}, \overline{\phi}$.

Ainsi, la vitesse du Théorème 11 est optimale, et la dépendance en R et M est la bonne (en fait, ce résultat a été montré dans [Sar25a] pour $\theta \leq p$ mais reste valable lorsque $\theta \in]0, 1[$ s'il est écrit sous cette forme, voir [Sar24b]). On peut aussi remarquer qu'il est nécessaire de perdre des facteurs logs au seul endroit où ils apparaissent, c'est à dire dans le cas limite $\theta = \theta_0$.

3.4.2. Mélange de contraintes. Dans la section précédente, l'hypothèse sur f_0 était « f_0 régulière et queues dominées ». Cependant, comme expliqué dans les Sections 3.1.2 et 3.2.4, la plupart des distributions usuelles vérifient des contraintes de formes supplémentaires (ou au moins leurs queues).

C'est la raison pour laquelle je vais considérer une contrainte de forme supplémentaire ici. Afin d'obtenir les bons résultats, et de ne pas être limité par l'exposant $n^{-(1-\theta)}$, je suppose que $\widehat{J}_0$ est donné par (3.19). On peut séparer l'analyse en deux parties selon que le niveau de la contrainte de forme s est supérieur ou inférieur au niveau de régularité globale α de f_0. On va voir ci dessous que les résultats sont sensiblement différents du Théorème 11.

Première partie. On suppose tout d'abord que s est strictement inférieur à α. On considère $p \in]0, +\infty]$, $s \geq 1$, $\alpha \in]\max\{1/p - 1, s\}, \tau[$, $\theta \in]0, 1[$, $R > 0$, $M_1, M_2 \geq 1$, $b \geq a$ et

$$\mathcal{F}^{\alpha,s}_{p,\theta}(a, b, R, M_1, M_2) = \begin{cases} \mathcal{WB}^{\alpha}_{p,\infty}(R) \cap \mathcal{WT}_{\theta}(M_1) \cap \mathcal{WT}_{\theta}(a, b, M_2) \cap \mathcal{M}^s(a, b) & \text{si } p \neq 1 \\ \mathcal{B}^{\alpha}_{p,\infty}(R) \cap \mathcal{WT}_{\theta}(M_1) \cap \mathcal{WT}_{\theta}(a, b, M_2) \cap \mathcal{M}^s(a, b) & \text{si } p = 1. \end{cases}$$

On pose

$$\gamma_s = \begin{cases} \dfrac{\alpha}{2\alpha+1} & \text{si } \theta \le \theta_0 \\ \dfrac{\alpha - s\theta/p - \alpha\theta + s\theta + \alpha s\theta}{1-\theta/p+\alpha+s-2s\theta/p+s\theta+2\alpha s\theta} & \text{si } \theta > \theta_0 \end{cases}$$

$$\beta_{1,s} = \begin{cases} \dfrac{1}{2\alpha+1} & \text{si } \theta \le \theta_0 \\ \dfrac{(s+1)(1-\theta)}{1-\theta/p+\alpha+s-2s\theta/p+s\theta+2\alpha s\theta} & \text{si } \theta > \theta_0 \end{cases}$$

$$\beta_{2,s} = \begin{cases} \dfrac{\alpha+1-1/p}{(1-\theta)(2\alpha+1)} & \text{si } \theta \le \theta_0 \\ \dfrac{(s+1)(1+\alpha-1/p)}{1-\theta/p+\alpha+s-2s\theta/p+s\theta+2\alpha s\theta} & \text{si } \theta > \theta_0 \end{cases}$$

$$M = \begin{cases} M_1 & \text{si } \theta \le \theta_0 \\ M_2 & \text{si } \theta > \theta_0. \end{cases}$$

On montre :

Théorème 13 ([Sar24b])**.** *Soient $s \ge 1$, $p \in]0,+\infty]$, $\alpha \in]\max\{1/p-1,s\},\tau[$, $\theta \in]0,1[$, $R>0$, $M_1, M_2 \ge 1$ et $b \ge a$. Il existe $\varsigma_0, \varrho_0, \kappa_0$, et n_0 tels que pour tout $n \ge n_0$, $\kappa \ge \kappa_0$, $\varrho \ge \varrho_0$, $\varsigma \ge \varsigma_0$, l'estimateur $\hat{f}$ défini par (3.17) avec $\widehat{J}_0$ donné par (3.19) vérifie*

$$\sup_{f_0 \in \mathcal{F}^{\alpha,s}_{p,\theta}(a,b,R,M_1,M_2)} \mathbb{E}\left[d_1(f_0,\hat{f})\right] \le c\left[R^{\beta_{1,s}} M^{\beta_{2,s}} \nu_n n^{-\gamma_s} + M_2^{(s+1)/(2s\theta+1)} n^{-(s\theta+1-\theta)/(2s\theta+1)}\right]. \quad (3.22)$$

De plus, $\varsigma_0, \varrho_0, \kappa_0$ ne dépendent que des ondelettes. Le facteur c ne dépend que de $p, s, \alpha, \theta, \kappa, \varrho, \varsigma$ et de la base d'ondelettes, et n_0 ne dépend que de $p, \alpha, \theta, s, \kappa, \varrho, \varsigma, R, M_1, M_2, b-a$ et de la base d'ondelettes.

La vitesse obtenue lorsque $\theta < \theta_0$ correspond au cas compact. Le régime qui apparait lorsque $\theta > \theta_0$ est très inhabituel et est à ma connaissance nouveau. L'exposant est un peu compliqué et la preuve fastidieuse. Un point important est qu'il n'y a jamais de facteurs logarithmiques dans la borne de risque même lorsque la régularité de la fonction varie spatialement (sauf à la frontière $\theta = \theta_0$). L'optimalité de (3.22) se discute à la lumière de la proposition suivante.

Proposition 14 ([Sar24b])**.** *Soient $s \ge 1$, $p \in]0,+\infty]$, $\alpha > \max\{1/p-1,s\}$, $\theta \in]0,1[$, τ assez grand, $R>0$, $M_1, M_2 \ge 1$ et $b > a$. Alors, il existe R_0, M_0 et n_0 tels que : pour tout $R \ge R_0$, $M_1 \ge M_0$, $M_2 \ge M_0$, et $n \ge n_0$,*

$$\inf_{\tilde{f}} \sup_{f_0 \in \mathcal{F}^{\alpha,s}_{p,\theta}(a,b,R,M,M)} \mathbb{E}\left[d_1(f_0,\tilde{f})\right] \ge c R^{\beta_{1,s}} M^{\beta_{2,s}} n^{-\gamma_s}. \quad (3.23)$$

De plus, c est strictement positive et ne dépend que de p, s, α, θ et de la base d'ondelettes.

Cette proposition garantit l'optimalité de l'estimateur dans tous les cas sauf deux particuliers.

— Le premier est lorsque $\theta = \theta_0$. Les deux bornes peuvent alors diverger d'un facteur logarithmique. Je conjecture au vu de la Proposition 12 que ce facteur log est indispensable.

— La seconde est quand $(s\theta + 1 - \theta)/(2s\theta + 1) < \gamma_s$. Ce cas est difficile à gérer dans la borne inférieure pour construire la famille sous-jacente (difficile de vérifier les deux contraintes simultanément). Cependant, on peut montrer que pour tout $\varepsilon > 0$, et tout M_1, M_2, τ, n assez grands,

$$\inf_{\tilde{f}} \sup_{f_0 \in \mathcal{F}^{\alpha,s}_{p,\theta}(a,b,R,M,M)} \mathbb{E}\left[d_1(f_0, \tilde{f})\right] \geq C_\varepsilon n^{-(s\theta+1-\theta)/(2s\theta+1)-\varepsilon},$$

où $C_\varepsilon > 0$ ne dépend que de $\varepsilon, p, s, \alpha, \theta, M_1, M_2, R$ et des ondelettes. La marge d'amélioration de (3.22) semble donc minime.

On peut maintenant faire ce que l'on souhaitait : évaluer l'impact d'une contrainte de forme dans les vitesses minimax de convergence. Pour cela, j'ai reproduit la Figure 3.4.2 de l'article [Sar24b] ci dessous. Le graphe de gauche donne les vitesses du Théorème 13. Celui de droite les vitesses du Théorème 11, c'est à dire sans la contrainte de forme. Le paramètre en abscisse est p et celui en ordonnée θ.

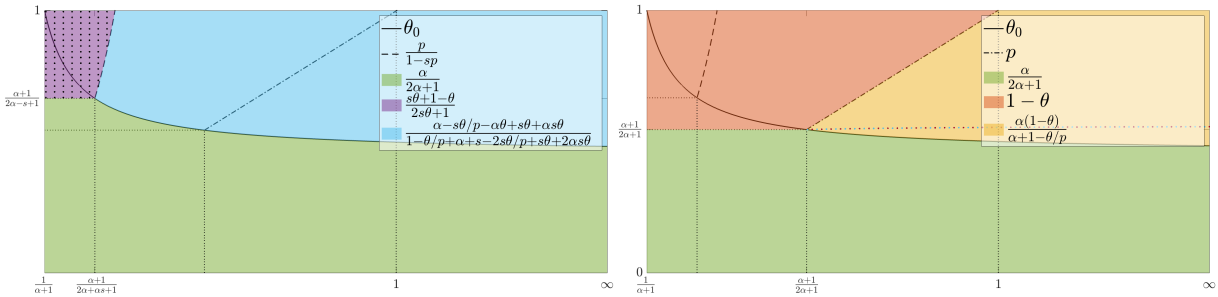

FIGURE 3.1 – Exposants sur le n. Gauche : mélange de contraintes. Droite : contrainte de régularité pure.

Les éléments importants sont les suivants.

1. La vitesse standard d'estimation $n^{-\alpha/(2\alpha+1)}$ s'applique sur un plus grand domaine lorsque l'on rajoute une condition de forme sur les queues (même avec $s = 1$, c'est à dire si on suppose les queues monotones).
2. L'exposant dans le graphe de gauche est toujours compris dans l'intervalle $]s/(2s+1), \alpha/(2\alpha+1)]$. Combiner les deux hypothèses, forme et régularité, conduit donc toujours à une vitesse plus rapide que celle que l'on attendrait sous une contrainte de forme pure. Elle conduit aussi à une vitesse plus rapide que celle que l'on aurait sous une contrainte de régularité pure quand l'exposant n'est pas $\alpha/(2\alpha + 1)$. A l'exception de mes travaux, je n'ai pas trouvé d'article décrivant un tel phénomène.
3. Cette amélioration de la vitesse de convergence se produit pour tout $a < b$. Cela signifie que l'endroit à partir duquel on met la contrainte de forme n'a pas impact dans les vitesses de convergence (sauf s'il dépend de n). Par ailleurs, ces deux paramètres n'interviennent pas dans (3.22). En un certain sens, la contrainte de forme permet de réduire les erreurs d'estimations dans les

queues de f_0, et cela, même si son niveau s est strictement inférieur à la régularité α de la fonction à estimer.

4. Les vitesses ci dessus ne peuvent pas être atteintes en général par un estimateur adaptatif qui serait uniquement basé sur des contraintes de régularité. On peut par exemple calculer le risque de l'estimateur si $\widehat{J}_0 = 0$, ce qui est le choix naturel des contraintes de type Besov. On obtiendrait alors

$$\sup_{f_0 \in \mathcal{F}^{\alpha,s}_{p,\theta}(a,b,R,M_1,M_2)} \mathbb{E}\left[d_1(f_0, \hat{f})\right] \leq c\left[R^{\beta_{1,s}} M^{\beta_{2,s}} \nu_n n^{-\gamma_s} + M_2 n^{-(1-\theta)}\right]. \tag{3.24}$$

L'exposant γ_s apparait bien mais la vitesse est entachée d'un second terme qui peut être prédominant (voir le graphe ci dessus). On voit ainsi ici l'importance théorique du choix de ce premier niveau $\widehat{J}_0$ dans les méthodes d'ondelettes.

Seconde partie. Le cas $s < \alpha$ est un cas assez riche. Le cas $s \geq \alpha$ l'est nettement moins. On peut en effet montrer (Théorème 8 de [Sar24b]) que l'estimateur atteint alors la vitesse standard de convergence $n^{-\alpha/(2\alpha+1)}$.

Il peut tout de même être utile d'écrire le résultat ici. On prend $M_1 = M_2$ et on les note M. On pose

$$\begin{aligned}\mathcal{F}^{\alpha,s}_{p,\theta}(a,b,R,M) &= \mathcal{F}^{\alpha,s}_{p,\theta}(a,b,R,M,M) \\ &= \begin{cases} \mathcal{WB}^{\alpha}_{p,\infty}(R) \cap \mathcal{WT}_{\theta}(M) \cap \mathcal{M}^s(a,b) & \text{si } p \neq 1 \\ \mathcal{B}^{\alpha}_{p,\infty}(R) \cap \mathcal{WT}_{\theta}(M) \cap \mathcal{M}^s(a,b) & \text{si } p = 1. \end{cases}\end{aligned}$$

On prouve alors :

Théorème 15 ([Sar24b])**.** *Soient $p \in]0,+\infty]$, $\alpha \in](1/p-1)_+, \tau[$, $s \in [\alpha, \tau[$, $\theta \in]0,1[$, $R > 0, M \geq 1$, $b \geq a$. Supposons $b \neq a$ si $s > \alpha$. Alors, il existe $\varsigma_0, \varrho_0, \kappa_0$, et n_0 tels que pour tout $n \geq n_0$, $\kappa \geq \kappa_0$, $\varrho \geq \varrho_0$, $\varsigma \geq \varsigma_0$, l'estimateur $\hat{f}$ défini par (3.17) avec $\widehat{J}_0$ donné par (3.19) vérifie*

$$\sup_{f_0 \in \mathcal{F}^{\alpha,s}_{p,\theta}(a,b,R,M)} \mathbb{E}\left[d_1(f_0, \hat{f})\right] \leq C n^{-\alpha/(2\alpha+1)}, \tag{3.25}$$

où

$$C = \begin{cases} cR^{1/(2\alpha+1)}(b-a)^{(\alpha+1-1/p)/(2\alpha+1)} & \textit{si } s > \alpha \\ c\left[R^{1/(2\alpha+1)}(b-a)^{(\alpha+1-1/p)/(2\alpha+1)} + \log_+(R) + \log_+(M)\right] & \textit{si } s = \alpha, \end{cases}$$

et où c ne dépend que de $p, s, \alpha, \theta, \kappa, \varrho, \varsigma$ et la base d'ondelettes. De plus, $\varsigma_0, \varrho_0, \kappa_0$ ne dépendent que de la base d'ondelettes, et n_0 ne dépend que de $p, \alpha, \theta, s, \kappa, \varrho, \varsigma, R, M, b-a$ et des ondelettes.

Ainsi, la vitesse d'estimation est la vitesse standard mais ce qui est intéressant c'est qu'on n'est pas dans les conditions standards. Ici, θ peut être aussi proche de 1 que l'on veut. Cela signifie que les queues de la distribution peuvent tendre très lentement vers 0. Ce résultat ne peut être vrai sous une condition de régularité pure (Proposition 12). A noter aussi les conditions sur α, p qui sont, encore une fois, essentiellement minimales.

Ce qui est intéressant aussi, c'est que ce résultat montre que l'on peut atteindre des vitesses très rapides même pour des densités « difficiles à estimer » avec une approche non-paramétrique. Dans le papier, je donne l'exemple de la densité f_0 définie pour $x \in \mathbb{R}$ par

$$f_0(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ \pi_1 x^{-1/q} & \text{si } x \in]0,1] \\ \pi_2 & \text{si } x \in]1,2] \\ \pi_3 x^{-1/\theta} & \text{si } x > 2. \end{cases} \tag{3.26}$$

On suppose ici $q > 1$, $\theta \in]0,1[$, et $\pi_1, \pi_2, \pi_3 > 0$. Cette densité admet une singularité en 0 qui peut être très forte si q est proche de 1. Quant à ses queues, elles peuvent tendre arbitrairement lentement vers 0 en jouant avec θ. Ces deux propriétés rendent l'estimation de f_0 délicate. Par exemple, une procédure basée sur la perte $\mathbb{L}^2$ pourra difficilement l'estimer si q est trop petit. Une procédure basée uniquement sur des contraintes de régularité ne pourra dépasser la vitesse $n^{-(1-\theta)}$ en norme $\mathbb{L}^1$.

On peut s'appuyer (par exemple) sur la Proposition 2 de [Sar24b] pour montrer que f_0 appartient à $\mathcal{WB}^{\alpha}_{p,\infty}(R)$ et cela, pour tout $p \in]q/(1+q\tau), q[$, $\alpha = 1/p - 1/q$. Le terme R dépend du choix de $p, q, \theta, \pi_1, \pi_2, \pi_3$ et des ondelettes. Par ailleurs, $f_0 \in \mathcal{M}^s(0,2)$ pour tout $s \geq 1$. On déduit donc du théorème précédent que $\hat{f}$ estime f_0 à la vitesse $n^{-\alpha/(2\alpha+1)}$. L'exposant peut être rendu très proche de $1/2$ si τ est assez grand puisqu'on peut alors prendre p petit et α grand (je rappelle que τ ne dépend que des ondelettes et conduit leurs régularités, ainsi que nombre de moments). Noter qu'autoriser $p < 1$, ce qui n'est pas toujours le cas dans la littérature, est important ici pour que la vitesse puisse être très rapide.

3.5. Résultats minimax pour h^2

La section précédente s'intéressait à l'estimation optimale d'une densité sous $\mathbb{L}^1$. Ici, je change de fonction de perte et considère plutôt la distance de Hellinger. Cette dernière est importante pour la ρ-estimation, mais aussi dans les travaux sur le maximum de vraisemblance. Je montre alors que les formules donnant les vitesses optimales sont très différentes du cas $\mathbb{L}^1$ lorsque f_0 est à support infini. Je considère à la fois des conditions de régularité pures et le mélange de contraintes.

3.5.1. Régularité pure. Je suis la tradition de considérer des hypothèses sur $\sqrt{f_0}$ au lieu de f_0. Je suis ainsi amené à considérer $p \in]0,+\infty]$, $\alpha \in](1/p - 1/2)_+, \tau[$, $\theta \in [0, p/2] \cap [0,1[$, $R > 0$, $M \geq 1$ et la classe

$$\mathcal{SF}^{\alpha}_{p,\theta}(R,M) = \begin{cases} \{f \in \mathcal{D}(\mathbb{R}),\ \sqrt{f} \in \mathcal{WB}^{\alpha}_{p,\infty}(R),\ f \in \mathcal{WT}_{\theta}(M)\} & \text{si } p \neq 2 \\ \{f \in \mathcal{D}(\mathbb{R}),\ \sqrt{f} \in \mathcal{B}^{\alpha}_{p,\infty}(R),\ f \in \mathcal{WT}_{\theta}(M)\} & \text{si } p = 2. \end{cases} \tag{3.27}$$

Je rappelle que $\mathcal{D}(\mathbb{R})$ désigne l'ensemble des densités sur $\mathbb{R}$. Une fonction $f \in \mathcal{SF}^{\alpha}_{p,\theta}(R,M)$ est donc une densité dont la racine carrée est régulière, et qui vérifie la condition de domination faible.

Je montre dans [Sar24a] qu'il est possible de construire un estimateur $\hat{f}$ ne dépendant que des données et de la base d'ondelettes précédente, et dont le risque peut être majoré comme suit.

Théorème 16 ([Sar24a]). *Pour tout $p \in]0,+\infty]$, $\alpha \in](1/p-1/2)_+, \tau[$, $\theta \in [0,p/2] \cap [0,1[$, $R>0$, $M \geq 1$,*

$$\sup_{f_0 \in \mathcal{SF}^{\alpha}_{p,\theta}(R,M)} \mathbb{E}\left[h^2(f_0,\hat{f})\right] \leq c\left[R^{2(1-\theta)/(2\alpha+1-2\theta/p)} M^{(1+2\alpha-2/p)/(1+2\alpha-2\theta/p)} n^{-2\alpha(1-\theta)/(2\alpha+1-2\theta/p)} + M n^{-(1-\theta)} + (\log n) n^{-1}\right], \tag{3.28}$$

où c ne dépend que de p, α, θ et de la base d'ondelettes.

Discutons ce résultat.

— On peut montrer une borne inférieure du risque minimax (Théorème 2.3 de [Sar24a]) et en déduire que la vitesse ci dessus est la bonne. De même, la dépendance en R et M correspond bien à celle que l'on a dans la borne inf. La vitesse affichée est donc bien la vitesse optimale d'estimation d'une fonction régulière à support infini pour la perte de Hellinger. Elle semble nouvelle lorsque $\theta \neq 0$.

— La construction de l'estimateur $\hat{f}$ est basée sur des tests robustes et je renvoie au papier [Sar24a] pour plus de détails (il était aussi possible de procéder par ρ-estimation). Elle ne dépend pas des paramètres de la classe. La vitesse (3.28) peut donc être atteinte de manière adaptative.

— Je mentionne néanmoins que cet estimateur vérifie une inégalité de sélection de modèles de la forme

$$\mathbb{E}\left[h^2(f_0,\hat{f})\right] \leq c \inf_{m \in \mathcal{M}} \left\{ d_2^2\big(\sqrt{f_0}, V_m\big) + \frac{\dim V_m + \log(1/\pi(m))}{n} \right\}, \tag{3.29}$$

où les V_m sont des espaces vectoriels, où $\mathcal{M}$ est un ensemble au plus dénombrable, et où π est une mesure de probabilité sur $\mathcal{M}$. Cette inégalité ressemble fortement à l'inégalité de sélection de modèle (3.21) obtenue dans le cas $\mathbb{L}^1$ via T-estimation. Cependant, l'inégalité (3.21) ne semblait pas suffisante pour estimer de manière optimale une densité régulière à support infini. Il s'avère qu'une inégalité de la forme (3.29) pour h^2 l'est. Les inégalités oracles « qu'il faut démontrer » ne sont donc pas complètement analogues pour les deux pertes.

— Le résultat ne couvre pas le cas $\alpha < 1/p - 1/2$, qui ne peut se produire que si $p < 2$. Cela est normal : je prouve dans [Sar24a] une borne minimax inférieure qui montre qu'on ne peut estimer une densité f_0 pour h^2 sous la seule hypothèse que $\sqrt{f_0} \in \mathfrak{B}^{\alpha}_{p,\infty}(R)$ et supp $f_0 \subset [0,1]$ lorsque $\alpha < 1/p - 1/2$ et $p < 2$. Comme dans le cas $\mathbb{L}^1$, mais contrairement aux cas $\mathbb{L}^q$, $q > 1$, l'exposant sur le n est une fonction discontinue au point limite.

— L'exposant sur le n se détériore même lorsque θ est très petit. Ce phénomène est remarquable car il est très différent de ce qui se passe pour la perte $\mathbb{L}^1$ où l'on retrouvait l'exposant correspondant à l'estimation d'une densité à support compact lorsque $\theta > 0$ est proche de 0 (et les autres pertes $\mathbb{L}^q$, du moins si on exclut le problème des facteurs logs, voir [GL14] pour plus de détails).

— On peut montrer, voir la Proposition 2.1 de [Sar24a], qu'une densité f dont la racine carrée est dans $\mathfrak{B}^{\alpha}_{p,\infty}(R)$ avec $p < 2$, vérifie la condition (forte) de domination avec $\theta = p/2$. On en déduit qu'il est possible d'estimer de telles densités sur $\mathbb{R}$ sans hypothèse supplémentaire.

3.5.2. Unimodalité. Comme dans le cas $\mathbb{L}^1$, on peut étudier le mélange de contraintes. Ici, je considère la double hypothèse f_0 est « régulière » et unimodale.

Soit l'ensemble

$$\mathscr{U} = \{f \in \mathcal{D}(\mathbb{R}), \text{ il existe } m \in \mathbb{R} \text{ tel que } f \text{ est croissante sur }]-\infty, m] \\ \text{et décroissante sur } [m, +\infty[\}$$

composé des densités unimodales. Soient $p \in]0, +\infty]$, $\alpha \in]\max(1/p - 1/2, 1), \tau[$, $\theta \in]0, p/2] \cap [0, 1[$, $R > 0$, $M \geq 1$ et l'ensemble

$$\mathcal{SF}^{\alpha,1}_{p,\theta}(R, M) = \mathscr{U} \cap \mathcal{SF}^{\alpha}_{p,\theta}(R, M),$$

où $\mathcal{SF}^{\alpha}_{p,\theta}(R, M)$ est défini par (3.27). Une densité de cet ensemble est donc une densité unimodale vérifiant la condition de domination et dont la racine carrée est régulière.

J'ai besoin des notations

$$\gamma = \frac{2(1 - 2\theta/p + 2\alpha\theta)}{1 + 2\alpha + 2\theta + 4\alpha\theta - 6\theta/p}$$
$$\beta_1 = \frac{2(1 - \theta)}{1 + 2\alpha + 2\theta + 4\alpha\theta - 6\theta/p}$$
$$\beta_2 = \frac{1 + 2\alpha - 2/p}{1 + 2\alpha + 2\theta + 4\alpha\theta - 6\theta/p}.$$

On peut comme dans la section précédente construire un estimateur $\hat{f}$ ne dépendant que des données et de la base d'ondelettes tel que :

Théorème 17 ([Sar24a]). *Pour tout $p \in]0, +\infty]$, $\alpha \in]\max(1/p - 1/2, 1), \tau[$, $\theta \in]0, p/2] \cap]0, 1[$, $R > 0$, $M \geq 1$, et n assez grand,*

$$\sup_{f_0 \in \mathcal{SF}^{\alpha,1}_{p,\theta}(R,M)} \mathbb{E}\left[h^2(f_0, \hat{f})\right] \leq cR^{\beta_1} M^{\beta_2} n^{-\gamma}, \tag{3.30}$$

où c ne dépend que de p, α, θ et de la base d'ondelettes.

Quelques commentaires.

— On peut montrer (Théorème 3.3 de [Sar24a]) que la vitesse ci dessus est bien la bonne (la dépendance en R et M correspond bien aussi à la borne inférieure).

— La condition $\alpha > 1$ est due au fait qu'une fonction unimodale f est régulière si elle vérifie une condition légère sur sa norme q. Plus précisément, on a $\sqrt{f} \in \mathcal{WB}^1_{p,\infty}(R)$ pour certains p, voir ma Proposition 3 dans [Sar24b] ou le Lemme 9.2 de [DL93]. Le but ici était d'imposer une condition de régularité de niveau supérieure à celle induite par la contrainte de forme.

— La vitesse (3.30) est toujours plus rapide que (3.28). C'est une autre différence avec le cas $\mathbb{L}^1$ où rajouter cette contrainte pouvait ne pas modifier la vitesse optimale de convergence si celle ci était déjà la vitesse du cas compact. Mélanger les deux hypothèses conduit donc toujours à une vitesse plus rapide que celle que l'on aurait sous une hypothèse de régularité pure, ou celle que l'on aurait sous une hypothèse d'unimodalité uniquement.

— Le papier [Sar24a] est à ma connaissance le premier où ce phénomène d'accélération des vitesses de convergence est mis en avant. Ce papier est antérieur aux résultats $\mathbb{L}^1$ décrits dans la section précédente. C'est la raison pour laquelle la contrainte de forme ici est plus sévère que ce que j'ai fait sous $\mathbb{L}^1$ et qu'il y a une condition sur θ. Il est possible d'envisager de généraliser ces résultats (s-monotonie, condition uniquement sur les queues...).
— J'interprète comme précédemment cette accélération des vitesses de convergence par le fait que la contrainte de forme permet de réduire les erreurs d'estimation dans les queues de f_0. Ce phénomène se traduit dans les vitesses car h^2 (comme d_1) accorde une certaine importance à ces erreurs. Je conjecture que la contrainte n'a plus d'impact sur les vitesses en estimation sous perte $\mathbb{L}^q$, si q est assez grand. Autrement dit, qu'on ne peut montrer le bénéfice de ces deux hypothèses dans les procédures uniquement pour certaines fonctions de perte. Quantifier cette valeur de q pourrait être intéressant.

3.6. Deux arguments clefs

3.6.1. Avant l'inégalité oracle : le contrôle du processus empirique. Les bornes de risque $\mathbb{L}^1$ reposent fortement sur la formule (3.13). La Proposition 10 est donc un résultat central de ce chapitre. Le but dans cette section est de décrire les grandes lignes de la preuve pour mettre en avant les idées sous-jacentes. Dans ce mémoire, j'ai insisté sur le coté statistique mathématique, et ici je souhaitais parler un peu de probabilités. En fait, toutes les inégalités oracles ou bornes de risque que j'ai énoncées s'appuient sur des contrôles de processus empiriques (incluant celles des chapitres précédents) qui peuvent parfois être délicats. Le raisonnement qui suit est (très) approximatif. La preuve exacte est à trouver dans [Sar25a].

Tout d'abord, chaque sous ensemble K_j de $\widehat{\mathbb{Z}}_j$ peut s'écrire

$$K_j = \left(K_j \cap \widehat{\mathbb{Z}}_{j,r_j,-}\right) \bigcup \bigcup_{r=r_j+1}^{\infty} \left(K_j \cap \widehat{\mathbb{Z}}_{j,r}\right)$$

et ceci, quelque soit r_j. Ainsi,

$$\mathcal{E}_j(K_j) = \inf_{r_j \geq 0} \left\{ \mathcal{E}_j(K_j \cap \widehat{\mathbb{Z}}_{j,r_j,-}) + \sum_{r=r_j+1}^{\infty} \mathcal{E}_j(K_j \cap \widehat{\mathbb{Z}}_{j,r}) \right\}.$$

Au lieu de contrôler $\mathcal{E}_j(K_j)$, on peut contrôler chacun des termes apparaissant dans cette égalité. C'est ce qui explique la forme de (3.13).

Je propose de discuter uniquement de la manière dont on peut majorer $\mathcal{E}_j(K_j \cap \widehat{\mathbb{Z}}_{j,r})$ lorsque $r \geq r_j + 1$. Majorer $\mathcal{E}_j(K_j \cap \widehat{\mathbb{Z}}_{j,r_j,-})$ se fait en utilisant les mêmes outils mais en les appliquant un peu différemment. Pour éviter de traiter différents cas, j'explique comment obtenir un résultat un peu plus faible que celui annoncé. Plus précisément, on montrera le résultat avec $\widehat{\lambda}_{j,r}$ dans (3.12) remplacé par

$$\widehat{\lambda}_{j,r} = \min\left\{ |\widehat{\mathbb{Z}}_j| + \log((1+|j|)n), 2^r \right\}.$$

Le résultat est en fait prouvé si l'on montre que

$$\mathcal{E}_j(K_j) \lessapprox \sqrt{\frac{|K_j|}{n}\widehat{\sigma}_j^2(K_j)\min\left\{\log_+\left(1/\widehat{\sigma}_j^2(K_j)\right), \log_+\left(\left(|\widehat{\mathbb{Z}}_j| + \log((1+|j|)n)\right)/|K_j|\right)\right\}}$$
$$+ \frac{|K_j|}{n}\min\left\{\log_+\left(1/\widehat{\sigma}_j^2(K_j)\right), \log_+\left(\left(|\widehat{\mathbb{Z}}_j| + \log((1+|j|)n)\right)/|K_j|\right)\right\} \tag{3.31}$$

est vrai pour tout $K_j \subset \mathbb{Z}$ sur un événement de grande probabilité. Le signe $\lessapprox$ ici signifie que le terme de gauche est, intuitivement, au moins de l'ordre du terme de droite. Plus précisément, $a \lessapprox b$ si on a $a \leq c(b+\varepsilon)$ où c est un facteur multiplicatif peu pertinent et où ε est interprété intuitivement comme un terme résiduel. En effet, si on l'applique la formule à $K_j \cap \widehat{\mathbb{Z}}_{j,r}$ au lieu de K_j, on a $\widehat{\sigma}_j^2(K_j \cap \widehat{\mathbb{Z}}_{j,r}) \approx 2^{-r}|K_j \cap \widehat{\mathbb{Z}}_{j,r}|$ et on retrouve bien à peu près (3.13).

Introduisons maintenant les notations $\sigma_{j,k}^2 = \mathbb{E}[\psi^2(2^jX - k)]$ et

$$\sigma_j^2(K_j) = \sum_{k\in K_j} \sigma_{j,k}^2.$$

Pour montrer (3.31) on montre d'abord les deux inégalités

$$\mathcal{E}_j(K_j) \lessapprox \sqrt{\frac{|K_j|}{n}\sigma_j^2(K_j)\log_+\left(1/\sigma_j^2(K_j)\right)} + \frac{|K_j|}{n}\log_+(1/\sigma_j^2(K_j)) \tag{3.32}$$

$$\mathcal{E}_j(K_j) \lessapprox \sqrt{\frac{|K_j|}{n}\sigma_j^2(K_j)\log_+\left(\left(|\widehat{\mathbb{Z}}_j| + \log((1+|j|)n)\right)/|K_j|\right)}$$
$$+ \frac{|K_j|}{n}\log_+\left(\left(|\widehat{\mathbb{Z}}_j| + \log((1+|j|)n)\right)/|K_j|\right). \tag{3.33}$$

Il faudra ensuite montrer que $\widehat{\sigma}_j^2(K_j) \approx \sigma_j^2(K_j)$ pour conclure. Cette approximation est admise ici.

La preuve de ces deux inégalités découle de la théorie des processus empiriques. Elle se décompose en plusieurs parties.

1. Tout d'abord, des calculs élémentaires montrent que l'erreur est un supremum de processus empirique. Pour tout $K_j \subset \mathbb{Z}$, $\mathcal{E}_j(K_j) \leq 2\mathcal{E}_j'(K_j)$ où

$$\mathcal{E}_j'(K_j) = \sup_{K_j' \subset K_j}\left|\frac{1}{n}\sum_{i=1}^n\left[\psi_{K_j'}(X_i) - \mathbb{E}\big(\psi_{K_j'}(X_i)\big)\right]\right|$$

   où

$$\psi_{K_j}(x) = \sum_{k\in K_j}\psi(2^jx - k).$$

   On va donc en réalité majorer $\mathcal{E}_j'(K_j)$ au lieu de $\mathcal{E}_j(K_j)$.

2. Considérons $\sigma^2 > 0$, un ensemble $\mathcal{C}_j \subset \mathbb{Z}$, $d \geq 1$ et

$$\mathcal{F}_j(d) = \left\{\psi_{K_j}(\cdot),\ K_j \subset \mathcal{C}_j,\ |K_j| \leq d,\ \sigma_j^2(K_j) \leq \sigma^2\right\}.$$

Cette classe s'avère être composée de fonctions uniformément bornées. Par ailleurs, on déduit des propriétés des ondelettes une majoration du moment d'ordre deux de $\psi_{K_j}(X)$:

$$\mathbb{E}\left[\psi_{K_j}^2(X)\right] \lessapprox \sigma_j^2(K_j).$$

On peut aussi observer que toute fonction de $\mathcal{F}_j(d)$ est majorée par

$$\bar{f}(x) = \sum_{k\in\mathcal{C}_j} \left|\psi(2^j x - k)\right|$$

et que $\mathbb{E}[\bar{f}^2(X)] \lessapprox \sigma_j^2(\mathcal{C}_j) \lessapprox 1$. Les propriétés des ondelettes assurent de plus que les sous graphes de $\mathcal{F}_j(d)$ sont Vapnik de dimension au plus proportionnel à d. On peut alors utiliser une inégalité maximale de Koltchinskii (Théorème 3.1 de [GK06]) pour obtenir la majoration

$$\mathbb{E}\left[\sup_{\substack{K_j\subset\mathcal{C}_j\\ |K_j|\ \leq d\\ \sigma_j^2(K_j)\ \leq\sigma^2}} \mathcal{E}_j'(K_j)\right] \lessapprox \sqrt{\frac{d}{n}\sigma^2\log_+(\sigma_j^2(\mathcal{C}_j)/\sigma^2)} + \frac{d}{n}\log_+(\sigma_j^2(\mathcal{C}_j)/\sigma^2).$$

3. L'inégalité de Talagrand peut être utilisée pour contrôler le supremum apparaissant dans le coté gauche de l'inégalité ci dessus autour de son espérance. L'inégalité (3.32) se déduit alors des points 1. et 2. ci dessus en choisissant $\mathcal{C}_j = \mathbb{Z}$, $\sigma_j^2(\mathbb{Z}) \approx 1$, et en faisant du chainage.
4. Pour prouver (3.33), on définit

$$\overline{\mathbb{Z}}_j = \left\{k \in \mathbb{Z},\ \sigma_{j,k}^2\ \geq 1/n\right\}.$$

   a) On fait comme pour prouver (3.32) mais on applique ce qui précède avec $\mathcal{C}_j = \overline{\mathbb{Z}}_j^c$ au lieu de $\mathcal{C}_j = \mathbb{Z}$. Noter que $\sigma_j^2(K_j) \leq |K_j|/n$ quand $K_j \subset \overline{\mathbb{Z}}_j^c$. On en déduit qu'il existe un événement de grande probabilité sur lequel on a pour tout $K_j \subset \overline{\mathbb{Z}}_j^c$,

$$\mathcal{E}_j'(K_j) \lessapprox \frac{|K_j|}{n}\log_+(n\sigma_j^2(\overline{\mathbb{Z}}_j^c)/|K_j|).$$

   b) Pour traiter le cas où $K_j \subset \overline{\mathbb{Z}}_j$, on applique simplement l'inégalité de Bernstein avec des bornes d'unions pour obtenir avec grande probabilité et uniformément pour tout $K_j \subset \overline{\mathbb{Z}}_j$,

$$\mathcal{E}_j'(K_j) \lessapprox \sqrt{\frac{|K_j|}{n}\sigma_j^2(K_j)\log_+(|\overline{\mathbb{Z}}_j|/|K_j|)} + \frac{|K_j|}{n}\log_+(|\overline{\mathbb{Z}}_j|/|K_j|).$$

   c) En mettant ensemble les points a) et b) ci dessus, et en écrivant tout $K_j \subset \mathbb{Z}$ comme $K_j = (K_j \cap \overline{\mathbb{Z}}_j) \cup (K_j \setminus \overline{\mathbb{Z}}_j)$, on en déduit très brutalement

$$\mathcal{E}_j'(K_j) \lessapprox \sqrt{\frac{|K_j|}{n}\sigma_j^2(K_j)\log_+(z_j/|K_j|)} + \frac{|K_j|}{n}\log_+(z_j/|K_j|) \tag{3.34}$$

   où

$$z_j = |\overline{\mathbb{Z}}_j| + n\sigma_j^2(\overline{\mathbb{Z}}_j^c).$$

   Il faut maintenant relier le terme inconnu z_j à $\widehat{\mathbb{Z}}_j$. Pour cela, on montre deux résultats.

i- Le premier est que $z_j \lessapprox \mathbb{E}[|\widehat{\mathbb{Z}}_j|]$.

ii- Le second est que $|\widehat{\mathbb{Z}}_j|$ se concentre autour de son espérance. De manière un peu plus précise, des inégalités Poissonniennes pour des fonctionnelles auto bornées montrent que pour tout $\xi > 0$ et probabilité $1 - e^{-\xi}$,

$$\mathbb{E}[|\widehat{\mathbb{Z}}_j|] \lessapprox |\widehat{\mathbb{Z}}_j| + \xi.$$

L'inégalité (3.33) se déduit alors de (3.34) combiné à ces deux points (et ξ de l'ordre de $\log((1+|j|)n)$ pour avoir un résultat vrai avec grande probabilité uniformément pour tout j).

3.6.2. Après l'inégalité oracle : l'approximation pour les contraintes de forme. J'ai montré à plusieurs reprises que renforcer une hypothèse de régularité par une contrainte de forme pouvait conduire à une amélioration des vitesses de convergence, et cela, même si le niveau de la contrainte de forme s était inférieur au niveau α de la condition de régularité. Ce qui explique mathématiquement ce phénomène, c'est que les résultats concernant l'approximation d'une fonction vérifiant une contrainte de forme ne sont pas les mêmes que ceux concernant l'approximation d'une fonction vérifiant une hypothèse de régularité (même si $\alpha = s$).

A titre d'exemple, considérons une densité unimodale bornée à support dans $[-L, L]$. Alors, elle appartient à $\mathfrak{B}^1_{1,\infty}(R)$ où R est de l'ordre de $1 + \|f\|_\infty$ (voir Lemme 9.2 de [DL93] ou Proposition 3 de [Sar24b]). Considérons $r \geq 1$. Toute fonction f de $\mathfrak{B}^1_{1,\infty}(R)$ peut s'approcher par une fonction $\bar{f}$ constante par morceaux basée sur une partition de $[-L, L]$ en r morceaux de sorte que $d_1(f, \bar{f}) \leq cLRr^{-1}$. D'un autre coté, si on utilise la forme particulière de f, on peut montrer (résultat d'approximation datant au moins de [Bir87]) qu'il existe une fonction $\bar{f}'$ constante par morceaux basée sur une partition de $[-L, L]$ en r morceaux telle que $d_1(f, \bar{f}') \leq c' \log(1 + \|f\|_\infty L)r^{-1}$. Les deux bornes sont en r^{-1}. Néanmoins, le facteur devant le r^{-1} n'est pas le même. Si l'on estime une fonction qui a un grand support ou une grande norme supérieure, la deuxième inégalité est nettement meilleure.

Dans ce chapitre, les espaces d'approximation sont des espaces générés par des ondelettes plutôt que des espaces composés de fonctions constantes par morceaux. On peut montrer :

Lemme 1 ([Sar24b]). *Supposons que f soit s-monotone sur $]0, +\infty[$ avec $\tau \geq s$. Alors, pour tout $j \in \mathbb{Z}$, $\ell \geq 1$ et tout $k_j \geq 3L_{wav} + (s-1)\ell$,*

$$\sum_{k \geq k_j} 2^{-j/2} |\beta_{j,k}(f)| \leq \ell^{1-s} f_{j,k_j-(s-1)\ell-2L_{wav}}$$

où c ne dépend que de s et de la base d'ondelettes et où

$$f_{j,k} = \int f(x) \mathbb{1}_{supp\ \psi_{j,k}}(x)\, \mathrm{d}x.$$

L'intérêt de ce résultat par rapport aux conditions de régularité est que celles ci n'imposent une contrainte sur les coefficients d'ondelettes que si $j \geq 0$ (voir (3.2)). Le lemme ci dessus fonctionne avec des indices j positifs ou négatifs. Il permet donc de contrôler le biais des estimateurs $\widehat{\beta}_{j,k}$ lorsque $j \leq 0$.

Par exemple, si $s = 1$, et que $f(x) \approx x^{-1/\theta}$ lorsque x est grand, on a pour k_j grand, $f_{j,k_j-(s-1)\ell-2L_{\mathrm{wav}}} \lessapprox 2^{j(1/\theta-1)}k_j^{-1/\theta}$. On obtient donc une borne d'autant meilleure que $j \leq 0$ est petit ou que k_j est grand. Un tel résultat ne semble pas accessible en utilisant uniquement (3.2).

Ce lemme est ainsi important pour prouver les bornes supérieures sous le mélange des deux types de contraintes sous la perte $\mathbb{L}^1$. Il admet une version similaire pour h^2 (c'est à dire pour $\mathbb{L}^2$ avec f remplacé par $\sqrt{f}$), voir [Sar24a].

3.7. Les moindres carrés

Le problème de l'estimation optimale de la densité reste ouvert pour les autres pertes $\mathbb{L}^q$. Dans un article à venir, je m'intéresse au cas $q = 2$. La rédaction de ce dernier n'est pas complètement terminé donc les résultats ci dessous doivent pour le moment être pris avec une relative précaution. Si l'estimation est faite en dimension d, prenons $d = 1$ ci dessous pour éviter d'introduire des notations supplémentaires.

On peut se demander pourquoi je traite d'abord le cas $\mathbb{L}^1$, puis le cas $\mathbb{L}^2$ au lieu de s'attaquer directement à $\mathbb{L}^q$. La raison est que les deux articles [Sar24a, Sar24b] sur l'estimation $\mathbb{L}^1$ font à eux deux environ 150pages. L'article pour la perte $\mathbb{L}^2$ qui n'est pas finalisé, et qui ne contiendra pas les bornes inf (qui seront dans un papier séparé) avoisine déjà presque les 80pages. La longueur de ces papiers est due aux preuves.

L'idée pour traiter le cas $\mathbb{L}^2$ est simplement de s'appuyer sur les moindres carrés. On sait des travaux de Birgé/Massart que si on considère une collection de modèles $(V_m)_{m\in\mathcal{M}}$ ne contenant pas trop de modèles par dimension, alors on peut construire un estimateur $\hat{f}$ tel que

$$\mathbb{E}\left[\|\hat{f} - f_0\|_2^2\right] \leq c \inf_{m\in\mathcal{M}} \left\{ d_2^2(f_0, V_m) + \|f_0\|_\infty \frac{\dim V_m}{n} \right\}. \tag{3.35}$$

Le terme modèle ici fait référence à espace vectoriel. La norme supérieure de f_0 apparait dans cette inégalité car il n'y a pas d'hypothèse qui garantisse en un certain sens la régularité des V_m (voir (2.12)).

Une telle inégalité ne peut pas être utilisée pour estimer une densité non bornée. Mais, il y a aussi des difficultés pour estimer une densité bornée à support non compact et je ne suis pas capable d'en déduire les bons exposants dans les vitesses. Une manière un peu grossière pour comprendre pourquoi est de remarquer que cette inégalité est très proche de l'inégalité que l'on aurait pour la perte de Hellinger h^2, et qui apparait dans (3.29). Or les vitesses sous h^2 et sous $\mathbb{L}^2$ dans le cas non compact sont très différentes. Le lecteur pourra néanmoins objecter que ce raisonnement a une limite car pour h^2, c'est la fonction $\sqrt{f_0}$ qui est importante et non f_0. Or si la norme $\mathbb{L}^1$ de f_0 vaut 1, c'est la norme $\mathbb{L}^2$ de $\sqrt{f_0}$ qui vaut 1. Mais cela donne une intuition et je renvoie à la Section 2.4 de [Sar24a] pour une comparaison un peu plus détaillée (on peut aussi jeter un coup d'œil aux variances dans les bornes de risque de [BCGC19]).

Il s'avère que l'inégalité (3.35) est problématique même lorsque f_0 est bornée à support compact. Cela ne se voit pas dans les vitesses de convergence mais plutôt dans la dépendance de la borne minimax en la norme sup. Si $f_0 \in \mathfrak{B}^\alpha_{p,\infty}(R)$ avec $\alpha > 1/p - 1/2$, et $p < 2$, une telle inégalité conduit à une borne de l'ordre de $R^{2/(2\alpha+1)}\|f_0\|_\infty^{2\alpha/(2\alpha+1)}n^{-2\alpha/(2\alpha+1)}$. Dans le papier à venir, j'obtiens $R^{2/(2\alpha+1)}\|f_0\|_\infty^{(2/p-1)/(2\alpha+1)}n^{-2\alpha/(2\alpha+1)}$. Si f_0 est à support dans $[0, 1]$, sa norme sup

ne peut être inférieure à 1, et la dernière borne est donc meilleure. Pour information, la condition $\alpha > 1/p - 1/2$ ci dessus est nécessaire, la vitesse minimax n'est plus la même si $\alpha < 1/p - 1/2$.

Ainsi, la résolution du problème de l'estimation optimale sous perte $\mathbb{L}^2$ passe par la démonstration d'une inégalité de sélection de modèle plus fine et plus précise que (3.35). Pour cela, le point clef est de travailler sur la pénalité des moindres carrés. A noter que pour les ondelettes, les moindres carrés nous amènent à sélectionner les coefficients en minimisant pour chaque niveau $j \geq 0$ un critère de la forme

$$\gamma_j(K_j) = -\sum_{k \in K_j} \widehat{\beta}_{j,k}^2 + \widehat{\mathrm{pen}}_j(K_j),$$

où $\widehat{\mathrm{pen}}_j(\cdot)$ est une pénalité à définir. La quantité $\widehat{\mathrm{pen}}_j(K_j)$ doit être connue, et elle doit vérifier une inégalité de la forme suivante : avec « grande probabilité », pour tout K_j « possible »,

$$\mathcal{X}_j^2(K_j) \leq \widehat{\mathrm{pen}}_j(K_j) + \text{terme résiduel}.$$

Ci dessus, $\mathcal{X}_j^2(K_j)$ désigne la statistique du chi-deux définie par

$$\mathcal{X}_j^2(K_j) = \sum_{k \in K_j} \left(\frac{1}{n} \sum_{i=1}^n \{\psi_{j,k}(X_i) - \mathbb{E}[\psi_{j,k}(X_i)]\} \right)^2.$$

Une référence incontournable sur le sujet est probablement le Chapitre 7 de [Mas07]. Malheureusement les résultats et arguments décrits dans ce chapitre ne sont pas suffisants pour répondre à mes besoins. Il y a essentiellement deux problèmes. Le premier est que les résultats sont bien adaptés pour gérer des collections finies (et déterministes) d'ensembles K_j et non des collections infinies, et cela engendre des difficultés car les K_j sont à chercher parmi les sous ensembles de $\mathbb{Z}$ (en fait parmi les sous ensembles d'un ensemble fini mais aléatoire). Le second est qu'ils peuvent manquer de précision lorsque les variances ou moments d'ordre deux des $\psi_{j,k}$ sont trop petits. Une des conséquences est que je n'arrive pas en déduire les vitesses optimales dans tous les différents régimes, un cas compliqué étant par exemple celui où f_0 est non bornée même si elle est à support compact.

En estimation $\mathbb{L}^1$, l'erreur avait été contrôlée en faisant du chainage : on applique l'inégalité de Talagrand et on utilise une inégalité maximale pour contrôler l'espérance du supremum empirique (voir la Section 3.6.1). Il s'avère que la statistique du chi-deux peut s'écrire comme un supremum de processus empirique. On peut donc penser à utiliser la même stratégie ici.

Malheureusement, les choses s'avèrent un petit peu plus compliquées que prévu. En effet, j'ai besoin d'étudier l'espérance de

$$Z = \sup_{k \in K_j} \frac{1}{n} \sum_{i=1}^n \{\psi_{j,k}(X_i) - \mathbb{E}[\psi_{j,k}(X_i)]\}$$

où K_j est un ensemble fini ou dénombrable vérifiant $\sup_{k \in K_j} \mathbb{E}[\psi_{j,k}^2(X)] \leq 1/n$. Les techniques que je connais pour contrôler l'espérance d'un supremum (basés sur la théorie VC ou sur des notions d'entropies qu'elles soient uniformes ou à crochets) peuvent être appliquées mais le problème, c'est qu'elles conduisent naturellement à des bornes de l'ordre de $\log n/n$. Il n'est d'ailleurs pas possible,

en général, de faire mieux. Mais cela l'est dans certains cas. Par exemple, le log peut être facilement supprimé si K_j est réduit à un ou quelques éléments (appliquer Bernstein avec des bornes d'union). Pour mes calculs, j'ai besoin de montrer que $\mathbb{E}[Z]$ reste de l'ordre de $1/n$ pour des collections K_j particulières mais possiblement grandes (de taille n par exemple) ou infinies. L'inégalité de Bernstein ne semble alors plus alors assez précise.

En résumé, il y a un travail à faire pour obtenir des inégalités suffisamment précises sur les statistiques du chi-deux. Une fois effectué, on est amené à une nouvelle pénalité pour les moindres carrés. On en déduit alors une inégalité oracle qu'il convient de préciser en fonction des hypothèses sur f_0.

L'estimateur qui en résulte est adaptatif, et pour donner un avant-goût des résultats, voici un aperçu de ses propriétés.

— Cas $p > 2$. Le risque minimax est étudié lorsque $f_0 \in \mathfrak{B}^\alpha_{p,\infty}(R) \cap \mathcal{WT}_\theta(M)$ où $\alpha \in (0, \tau)$ et $\theta \in [0, 1]$. L'estimateur atteint alors soit la vitesse $n^{-2\alpha/(2\alpha+1)}$ soit $n^{-\alpha(2-\theta)/(1-\theta/p+\alpha)}$ sauf pour une valeur particulière de θ où un log apparait. Le point important et novateur ici est l'absence de facteurs logarithmiques sauf dans le cas de frontière. Cela montre en un certain sens que le processus sous-jacent a été contrôlé de manière suffisamment fine.

— Cas $p < 2$. Le risque minimax est étudié lorsque $f_0 \in \mathfrak{B}^\alpha_{p,\infty}(R)$ et sous une hypothèse supplémentaire que f_0 appartient à une boule d'un espace $\mathbb{L}^q$ faible, $q > 2$. Pour faire simple, je me restreint dans ce paragraphe à $\alpha \in (1/p - 1/2, \tau)$ mais le cas général est traité dans le papier. Si $f_0 \in \mathfrak{B}^\alpha_{p,\infty}(R)$ avec $\alpha \geq 1/p$ ou $\alpha < 1/p$ avec q assez grand, on retrouve la vitesse standard $n^{-2\alpha/(2\alpha+1)}$ sans perte de facteurs logarithmiques, et ce phénomène semble nouveau (retrouver la vitesse standard sous une condition sur les singuralités et également quantifier la valeur de q à partir de cela où se produit). Si $\alpha < 1/p$ et q plus petit, on obtient une vitesse qui semble nouvelle dans la littérature (sans logs sauf cas frontière).

  A noter que si $\alpha < 1/p$ et $f \in \mathfrak{B}^\alpha_{p,\infty}(R)$, alors f est dans une boule de cet espace $\mathbb{L}^q$ faible pour un q bien choisi (voir [PL08] quand $p \geq 1$, communication privée de l'auteur quand $p < 1$). On retrouve alors soit la vitesse $n^{-2\alpha/(2\alpha+1)}$ soit $n^{-2(\alpha-1/p+1/2)/(\alpha+1-1/p)}$ sans perte de facteurs logs, sauf cas de frontière. Ce dernier régime apparaissait dans la Section 2.3.5 mais uniquement aux logs près et lorsque l'estimation est faite sur un compact. Ici, l'estimation est faite sur $\mathbb{R}$. A noter que ce qui précède garantit aussi dans certains cas que $\|\hat{f}\|_2$ est un estimateur optimal et adaptatif de la norme 2 de f_0 (incluant certains où je ne connais pas d'alternatives).

3.8. Quelques perspectives

Les idées contenues dans ce chapitre admettent de nombreuses suites logiques. Voici un aperçu très bref.

Autres fonctions de pertes. La première est assez évidente : après s'être attaqué au problème de l'estimation sous $\mathbb{L}^1$, sous h^2, et sous $\mathbb{L}^2$, on peut s'intéresser à la perte $\mathbb{L}^q$ générale. Pour cela, on pourrait modifier le critère, écrit pour la norme $\mathbb{L}^1$, en remplaçant dans (3.15) la norme $\mathbb{L}^1$ par la norme $\mathbb{L}^q$ à la puissance q. Toute la difficulté réside sans surprise dans le contrôle de l'erreur qui serait associée au critère, notamment quand f_0 est non bornée/à support non compact (et que

l'on met une condition faible sur les singularités ou sur les queues). L'extension de $\mathbb{L}^1$ à $\mathbb{L}^2$ n'était pas immédiate car les deux fonctions de perte ont un comportement très différent au niveau des endroits où la fonction diverge.

On peut aussi observer, de manière un petit peu plus subtile, que les bornes supérieures que j'ai démontrées pour la perte $\mathbb{L}^1$ ont en fait été démontrées pour une norme un peu plus grande, la norme de l'espace $\mathcal{B}^0_{1,\infty}$. C'est quelque chose d'attendu car on agit ici directement sur les coefficients d'ondelettes. Si les résultats minimax pour les deux normes semblent coïncider dans la plupart des cas, il peut exister certains, éventuellement extrêmes, pour lesquels ils vont différer. Il pourrait ainsi avoir des différences dans les résultats entre certaines méthodes d'estimation basées uniquement sur les coefficients d'ondelettes (seuillage...) et certaines autres (telles que Grenander, la méthode combinatoire de Devroye et Lugosi, l'estimation via méthode à noyaux et sélection de fenêtre en utilisant un critère à la Lepski).

Bornes minimax en déviation. Si l'on regarde les résultats que j'ai écrits, on peut remarquer que les bornes supérieures minimax sont parfois données sur un événement de grande probabilité et parfois en espérance. Dès fois, certaines de mes bornes de risque sont en espérance, mais les calculs sous-jacents sont en fait faits avec grande probabilité, disons $1 - 1/n^c$ pour un certain $c > 0$.

Un tel raisonnement peut conduire à des résultats optimaux, c'est à dire sans perte de facteurs logarithmiques. C'est le cas par exemple des Théorèmes 11, 13 et 15. Cependant, dans d'autres, ce raisonnement induit un facteur logarithmique dans les bornes de risque. Il pourrait être logique de se demander si cette perte de facteurs logarithmiques peut être une conséquence obligatoire du raisonnement en probabilité. Reformulé autrement, on peut se demander si les vitesses minimax de convergence en espérance ou avec grande probabilité (disons $1 - 1/n^c$) sont toujours les mêmes.

Cette réflexion provient (en autres) du fait que les déviations du processus empirique autour de son espérance dans le cas $\mathbb{L}^2$ peuvent ne pas être négligeables par rapport à l'espérance du processus empirique lui même. Le fait que le risque de l'estimateur pourrait dépendre en quelque sorte de la probabilité sur laquelle on se place fait un peu écho à ce qui se passe pour les estimateurs de la moyenne, voir [DLLO16].

Autres cadres statistiques. L'heuristique telle que décrite dans la Section 3.3.1 est une heuristique visant à sélectionner les coefficients importants dans la décomposition d'une fonction en série d'ondelettes. Il est ainsi naturel d'essayer de l'appliquer à d'autres cadres statistiques telles que les données dépendantes, anisotropes, le modèle de déconvolution éventuellement structuré, la confidentialité locale, l'estimation de l'intensité d'un processus de Poisson, les problématiques de régression (avec des ondelettes « déformées »)...L'intérêt de l'heuristique est qu'elle donne un processus empirique à contrôler et qu'on peut l'utiliser avec n'importe quelle borne. Si celle ci est suffisamment précise, on s'attend à obtenir les vitesses optimales de convergence, sans facteurs logarithmiques supplémentaires et sans hypothèse simplificatrice sur la fonction à estimer.

Mélanger les contraintes. Mes travaux ne sont pas les premiers qui s'intéressent au problème de l'estimation d'une fonction vérifiant à la fois une contrainte de régularité et une contrainte de forme. Le fait qu'il y ait une interaction possiblement bénéfique en termes de vitesses entre les deux semble en revanche plus novateur. Ce qui est intéressant c'est qu'on peut se servir des résultats

minimax que j'ai démontrés pour vérifier l'optimalité ou non d'autres procédures de la littérature. Pour cela, il faudrait voir si on peut calculer leurs risques $\mathbb{L}^1$ ou Hellinger. D'autres extensions sont naturelles : quid des autres pertes, ou des autres cadres statistiques.

Dans les cas où les vitesses ne sont pas connues, un point fastidieux est la démonstration des bornes inférieures car il faut construire une famille sous-jacente adéquate vérifiant les deux contraintes. Le bon coté des choses est que l'on pourra s'appuyer sur les preuves que j'ai faites dans le modèle de densité.

Bibliographie

[Aka12] Nathalie Akakpo. Adaptation to anisotropy and inhomogeneity via dyadic piecewise polynomial selection. *Mathematical Methods of Statistics*, 21 :1–28, 2012.

[AL11] Nathalie Akakpo and Claire Lacour. Inhomogeneous and anisotropic conditional density estimation from dependent data. *Electronic journal of statistics*, 5 :1618–1653, 2011.

[Bar02] Yannick Baraud. Model selection for regression on a random design. *ESAIM : Probability and Statistics*, 6 :127–146, 2002.

[Bar11] Yannick Baraud. Estimator selection with respect to hellinger-type risks. *Probab. Theory Relat. Fields*, 151(1-2) :353–401, 2011.

[Bar21] Yannick Baraud. Tests and estimation strategies associated to some loss functions. *Probability Theory and Related Fields*, 180(3) :799–846, 2021.

[BB09] Yannick Baraud and Lucien Birgé. Estimating the intensity of a random measure by histogram type estimators. *Probab. Theory Relat. Fields*, 143 :239–284, 2009.

[BB16] Yannick Baraud and Lucien Birgé. ρ-estimators for shape restricted density estimation. *Stochastic Processes and their Applications*, 126(12) :3888–3912, 2016.

[BB18] Yannick Baraud and Lucien Birgé. Rho-estimators revisited : General theory and applications. *The Annals of Statistics*, 46(6B) :3767–3804, 2018.

[BBM99] Andrew Barron, Lucien Birgé, and Pascal Massart. Risk bounds for model selection via penalization. *Probability theory and related fields*, 113(3) :301–413, 1999.

[BBS17] Yannick Baraud, Lucien Birgé, and Mathieu Sart. A new method for estimation and model selection : ρ-estimation. *Inventiones mathematicae*, 207(2) :425–517, 2017.

[BC24a] Yannick Baraud and Juntong Chen. Robust estimation of a regression function in exponential families. *Journal of Statistical Planning and Inference*, 233 :106167, 2024.

[BC24b] Yannick Baraud and Juntong Chen. Robust estimation of a regression function in exponential families. *Journal of Statistical Planning and Inference*, 233 :106167, 2024.

[BCGC19] Denis Belomestny, Fabienne Comte, and Valentine Genon-Catalot. Sobolev-hermite versus sobolev nonparametric density estimation on $\mathbb{R}$. *Annals of the Institute of Statistical Mathematics*, 71(1) :29–62, 2019.

[BD14] Rina Foygel Barber and John C Duchi. Privacy and statistical risk : Formalisms and minimax bounds. *arXiv :1412.4451*, 2014.

[BDKS20] Cristina Butucea, Amandine Dubois, Martin Kroll, and Adrien Saumard. Local differential privacy : Elbow effect in optimal density estimation and adaptation over besov ellipsoids. *Bernoulli*, 26(3) :1727–1764, 2020.

[Bel18] Pierre C Bellec. Sharp oracle inequalities for least squares estimators in shape restricted regression. *The Annals of Statistics*, 46(2) :745–780, 2018.

[BF96] Peter J Bickel and Jianqing Fan. Some problems on the estimation of unimodal densities. *Statistica Sinica*, 6(1) :23–45, 1996.

[BGW21] Thomas B Berrett, László Györfi, and Harro Walk. Strongly universally consistent nonparametric regression and classification with privatised data. *Electron. J. Stat.*, 15(1) :2430–2453, 2021.

[BI21] Cristina Butucea and Yann Issartel. Locally differentially private estimation of functionals of discrete distributions. *Adv. Neural Inf. Process. Syst.*, 34, 2021.

[Bir83] Lucien Birgé. Approximation dans les espaces métriques et théorie de l'estimation. *Zeitschrift für Wahrscheinlichkeitstheorie und verwandte Gebiete*, 65(2) :181–237, 1983.

[Bir87] Lucien Birgé. On the risk of histograms for estimating decreasing densities. *The Annals of Statistics*, 15(3) :1013–1022, 1987.

[Bir06] Lucien Birgé. Model selection via testing : an alternative to (penalized) maximum likelihood estimators. *Annales de l'IHP Probabilités et statistiques*, 42(3) :273–325, 2006.

[Bir09] Melanie Birke. Shape constrained kernel density estimation. *J. Stat. Plan. Inference*, 139(8) :2851–2862, 2009.

[Bir13] Lucien Birgé. Robust tests for model selection. *From probability to statistics and back : high-dimensional models and processes–A Festschrift in honor of Jon A. Wellner*, pages 47–64, 2013.

[Bir14] Lucien Birgé. Model selection for density estimation with $\mathbb{L}_2$-loss. *Probability Theory and Related Fields*, 158 :533–574, 2014.

[BM93] Lucien Birgé and Pascal Massart. Rates of convergence for minimum contrast estimators. *Probability Theory and Related Fields*, 97 :113–150, 1993.

[BRH25] Imon Banerjee, Vinayak Rao, and Harsha Honnappa. Adaptive estimation of the transition density of controlled markov chains. *arXiv preprint*, 2025.

[BRS20] Cristina Butucea, Angelika Rohde, and Lukas Steinberger. Interactive versus non-interactive locally differentially private estimation : Two elbows for the quadratic functional. *arXiv preprint*, 2020.

[BSR04] Gilles Blanchard, Christin Schäfer, and Yves Rozenholc. Oracle bounds and exact algorithm for dyadic classification trees. In *International Conference on Computational Learning Theory*, pages 378–392. Springer, 2004.

[BT15] Pierre C Bellec and Alexandre B Tsybakov. Sharp oracle bounds for monotone and convex regression through aggregation. *Journal of Machine Learning Research*, 16(56) :1879–1892, 2015.

[Cas99] Gwénaëlle Castellan. Modified akaike's criterion for histogram density estimation. *Technical report*, 1999.

[CDF92] Albert Cohen, Ingrid Daubechies, and J-C Feauveau. Biorthogonal bases of compactly supported wavelets. *Communications on pure and applied mathematics*, 45(5) :485–560, 1992.

[CDL13] Albert Cohen, Mark A Davenport, and Dany Leviatan. On the stability and accuracy of least squares approximations. *Foundations of computational mathematics*, 13 :819–834, 2013.

[CGS15] Sabyasachi Chatterjee, Adityanand Guntuboyina, and Bodhisattva Sen. On risk bounds in isotonic and other shape restricted regression problems. *The Annals of Statistics*, 43(4) :1774–1800, 2015.

[Cha14] Sourav Chatterjee. A new perspective on least squares under convex constraint. *The Annals of Statistics*, 42(6) :2340–2381, 2014.

[Che20] Xin Chen. *Penalized unimodal spline density estimate with application to M-estimation.* PhD thesis, Colorado State University, 2020.

[Che22] Juntong Chen. Estimator selection for regression functions in exponential families with application to changepoint detection. *arXiv :2212.12954*, 2022.

[Che24] Juntong Chen. Estimating a regression function in exponential families by model selection. *Bernoulli*, 30(2) :1669–1693, 2024.

[CL19] Sabyasachi Chatterjee and John Lafferty. Adaptive risk bounds in unimodal regression. *Bernoulli*, 25(1) :1–25, 2019.

[CL20] Kaikai Cao and Youming Liu. Uncompactly supported density estimation with l^1 risk. *Communications on Pure & Applied Analysis*, 19(8) :4007, 2020.

[CR04] Fabienne Comte and Yves Rozenholc. A new algorithm for fixed design regression and denoising. *Annals of the Institute of Statistical Mathematics*, 56 :449–473, 2004.

[DBB21] Amandine Dubois, Thomas Berrett, and Cristina Butucea. Goodness-of-fit testing for hölder continuous densities under local differential privacy. *arXiv preprint*, 2021.

[DGJ11] I. Dattner, A. Goldenshluger, and A. Juditsky. On deconvolution of distribution functions. *Ann. Statist.*, 39(5) :2477–2501, 2011.

[DJ96] Bernard Delyon and Anatoli Juditsky. On minimax wavelet estimators. *Applied and Computational Harmonic Analysis*, 3(3) :215–228, 1996.

[DJ97] Bernard Delyon and Anatoli Juditsky. On the computation of wavelet coefficients. *Journal of Approximation Theory*, 88(1) :47–79, 1997.

[DJKP96] David L Donoho, Iain M Johnstone, Gérard Kerkyacharian, and Dominique Picard. Density estimation by wavelet thresholding. *The Annals of Statistics*, 24(2) :508–539, 1996.

[DJW18] John C Duchi, Michael I Jordan, and Martin J Wainwright. Minimax optimal procedures for locally private estimation. *Journal of the American Statistical Association*, 113(521) :182–201, 2018.

[DL93] Ronald A DeVore and George G Lorentz. *Constructive approximation.* Springer Berlin, Heidelberg, 1993.

[DL12] Luc Devroye and Gábor Lugosi. *Combinatorial methods in density estimation.* Springer Science & Business Media, 2012.

[DL18] Cécile Durot and Hendrik P. Lopuhaä. Limit Theory in Monotone Function Estimation. *Statistical Science*, 33(4) :547–567, 2018.

[DLLO16] Luc Devroye, Matthieu Lerasle, Gabor Lugosi, and Roberto I Oliveira. Sub-Gaussian mean estimators. *The Annals of Statistics*, 44(6) :2695–2725, 2016.

[Don97] David L Donoho. Cart and best-ortho-basis : a connection. *The Annals of Statistics*, 25(5) :1870–1911, 1997.

[DS24] Céline Duval and Émeline Schmisser. Adaptation to inhomogeneous smoothness for densities with irregularities. *arXiv :2407.10673*, 2024.

[DY90] Ronald A DeVore and Xiang Ming Yu. Degree of adaptive approximation. *Mathematics of Computation*, 55 :625–635, 1990.

[GK06] Evarist Giné and Vladimir Koltchinskii. Concentration inequalities and asymptotic results for ratio type empirical processes. *The Annals of Probability*, 34(3) :1143–1216, 2006.

[GK22] László Györfi and Martin Kroll. On rate optimal private regression under local differential privacy. *arXiv :2206.00114*, 2022.

[GL14] Alexander Goldenshluger and Oleg Lepski. On adaptive minimax density estimation on $\mathbb{R}^d$. *Probability Theory and Related Fields*, 159(3) :479–543, 2014.

[GS15] Adityanand Guntuboyina and Bodhisattva Sen. Global risk bounds and adaptation in univariate convex regression. *Probability Theory and Related Fields*, 163(1-2) :379–411, 2015.

[HH02] Peter Hall and Li-Shan Huang. Unimodal density estimation using kernel methods. *Statistica Sinica*, 12(4) :965–990, 2002.

[HK05] Peter Hall and Kee-Hoon Kang. Unimodal kernel density estimation by data sharpening. *Statistica Sinica*, 15(1) :73–98, 2005.

[HKPT12] Wolfgang Härdle, Gérard Kerkyacharian, Dominique Picard, and Alexander Tsybakov. *Wavelets, approximation, and statistical applications*. Springer Science & Business Media, 2012.

[IK81] IA Ibragimov and RZ Khasminski. More on estimation of the density of a distribution. *Journal of Soviet Mathematics*, 108(194) :198, 1981.

[JLL04] Anatoli Juditsky and Sophie Lambert-Lacroix. On minimax density estimation on $\mathbb{R}$. *Bernoulli*, 10(2) :187–220, 2004.

[Kan92] Yuichiro Kanazawa. An optimal variable cell histogram based on the sample spacings. *The Annals of Statistics*, pages 291–304, 1992.

[Kro20] Martin Kroll. Adaptive spectral density estimation by model selection under local differential privacy. *arXiv preprint*, 2020.

[Kro21] Martin Kroll. On density estimation at a fixed point under local differential privacy. *Electron. J. Stat.*, 15(1) :1783–1813, 2021.

[LC90] Lucien Le Cam. Maximum likelihood : an introduction. *International Statistical Review/Revue Internationale de Statistique*, pages 153–171, 1990.

[LeC73] Lucien LeCam. Convergence of estimates under dimensionality restrictions. *The Annals of Statistics*, pages 38–53, 1973.

[Lec23a] Alexandre Lecestre. Robust estimation for ergodic markovian processes. *arXiv :2307.03666*, 2023.

[Lec23b] Alexandre Lecestre. Robust estimation in finite mixture models. *ESAIM : Probability and Statistics*, 27 :402–460, 2023.

[Lec25] Alexandre Lecestre. Robust label shift quantification. *arXiv preprint*, 2025.

[Lep15] Oleg Lepski. Adaptive estimation over anisotropic functional classes via oracle approach. *The Annals of Statistics*, 43(3) :1178–1242, 2015.

[LM17] Hendrik P Lopuhaä and Eni Musta. Smooth estimation of a monotone hazard and a monotone density under random censoring. *Statistica Neerlandica*, 71(1) :58–82, 2017.

[LM19] Hendrik P. Lopuhaä and Eni Musta. Central limit theorems for the L_p-error of smooth isotonic estimators. *Electron. J. Stat.*, 13(1) :1031–1098, 2019.

[LWLL22] Joseph Lam-Weil, Béatrice Laurent, and Jean-Michel Loubes. Minimax optimal goodness-of-fit testing for densities and multinomials under a local differential privacy constraint. *Bernoulli*, 28(1) :579–600, 2022.

[Mag15] Nelo Molter Magalhães Magalhães. *Validation croisée et pénalisation pour l'estimation de densité*. PhD thesis, Université Paris Sud-Paris XI, 2015.

[Mas07] Pascal Massart. *Concentration inequalities and model selection : Ecole d'Eté de Probabilités de Saint-Flour XXXIII-2003*. Springer, 2007.

[McD89] Colin McDiarmid. On the method of bounded differences. *Surveys in combinatorics*, 141(1) :148–188, 1989.

[Mei09] Alexander Meister. *Deconvolution problems in nonparametric statistics*, volume 193 of *Lecture Notes in Statistics*. Springer-Verlag, Berlin, 2009.

[Mey12] Mary C Meyer. Nonparametric estimation of a smooth density with shape restrictions. *Statistica Sinica*, 22(2) :681–701, 2012.

[MS23] Clément Marteau and Mathieu Sart. Deconvolution for some singular density errors via a combinatorial median of means approach. *Math. Stat. Learn*, 6(1) :51–85, 2023.

[PL08] F Pérez Lázaro. Embeddings for anisotropic besov spaces. *Acta Mathematica Hungarica*, 119(1-2) :25–40, 2008.

[RBRTM11] Patricia Reynaud-Bouret, Vincent Rivoirard, and Christine Tuleau-Malot. Adaptive density estimation : a curse of support ? *Journal of Statistical Planning and Inference*, 141(1) :115–139, 2011.

[RS20] Angelika Rohde and Lukas Steinberger. Geometrizing rates of convergence under local differential privacy constraints. *Ann. Stat.*, 48(5) :2646–2670, 2020.

[Sar14] Mathieu Sart. Estimation of the transition density of a Markov chain. *Annales de l'Institut Henri Poincaré. Probabilités et Statistique*, 50(3) :1028–1068, 2014.

[Sar16] Mathieu Sart. Robust estimation on a parametric model via testing. *Bernoulli*, 22(3) :1617–1670, 2016.

[Sar17] Mathieu Sart. Estimating the conditional density by histogram type estimators and model selection. *ESAIM : Probability and Statistics*, 21 :34–55, 2017.

[Sar21a] Mathieu Sart. Estimating a density, a hazard rate, and a transition intensity via the ρ-estimation method. *Annales de l'Institut Henri Poincaré, Probabilités et Statistiques*, 57(1) :195–249, 2021.

[Sar21b] Mathieu Sart. Minimax bounds for besov classes in density estimation. *Electronic Journal of Statistics*, 15(1) :3184–3216, 2021.

[Sar23] Mathieu Sart. Density estimation under local differential privacy and hellinger loss. *Bernoulli*, 29(3) :2318–2341, 2023.

[Sar24a] Mathieu Sart. About the optimal estimation of a density with infinite support under Hellinger loss. *Electronic Journal of Statistics*, 18(2) :4526–4577, 2024.

[Sar24b] Mathieu Sart. Adaptive and optimal estimation under shape and smoothness constraints. *Hal*, 2024.

[Sar25a] Mathieu Sart. Non-linear wavelet density estimation on the real line. *Bernoulli (to appear)*, 2025.

[Sar25b] Mathieu Sart. Supplementary material to : Non-linear wavelet density estimation on the real line. *Bernoulli (to appear)*, 2025.

[SJ22] Sandra Schluttenhofer and Jan Johannes. Adaptive pointwise density estimation under local differential privacy. *arXiv :2206.07663*, 2022.

[vdV13] Wellner van der Vaart. *Weak convergence and empirical processes : with applications to statistics*. Springer Science & Business Media, 2013.

[VDVVDL03] Aad Van Der Vaart and Mark Van Der Laan. Smooth estimation of a monotone density. *Statistics : A Journal of Theoretical and Applied Statistics*, 37(3) :189–203, 2003.

[Zha02] Cun-Hui Zhang. Risk bounds in isotonic regression. *The Annals of Statistics*, 30(2) :528–555, 2002.